
Chequeo de Normalidad de Datos

Autor: Daniel Firka

Dificultad: Requiere conocimientos básicos de estadística: promedio, desvío estándar, etc.

Objetivo: Describir conceptos de chequeo de normalidad, mostrar porque son necesarios y cuáles son los test más frecuentemente utilizados.

Ilustraciones: Los gráficos usados en el informe son pantallas obtenidas a partir del Sistema para el Aseg. de Calidad - SPAC.

Agradecimientos: Silvia Joeques - Javier Carrizo

Fecha: 7 de Abril de 2004.

¿Porqué es tan normal la curva Normal?

La distribución Normal (o distribución de Gauss) es comúnmente hallada en procesos naturales, y atrajo la atención de académicos desde los albores del estudio de la Estadística (Gauss, Laplace, etc.).

Cuando un proceso es el resultado de una combinación de muchas causas de igual magnitud (donde ninguna de las causas genera un efecto preponderante), es muy probable que el proceso siga una distribución normal.

Esta propiedad que transforma a la curva Normal en una distribución límite de la suma de múltiples efectos fue descubierta teóricamente en el siglo XVIII por DeMoivre y Laplace, y lleva el nombre de "Teorema Central del Límite".

En el área de manufactura, muchas veces encontramos variables cuya distribución frecuencial -aquella que vemos al observar un histograma- se asemeja a una distribución gaussiana.

¿Qué es el chequeo de normalidad de datos?

Chequear la normalidad de los datos significa estudiar si un grupo de datos que estamos analizando puede atribuirse a un proceso cuya distribución es gaussiana.

Buscamos responder a la siguiente pregunta: aquí tengo N datos, ¿es razonable suponer que estos datos provienen de una población normal?.

Para responder con absoluta seguridad (100% de confianza), el único camino es medir todos los individuos de la población y graficar un histograma, que nos mostrará la forma exacta de la distribución de los datos.

En la práctica esto es imposible, y siempre debemos tomar a una decisión con una muestra de la población, lo que implica un riesgo de equivocarnos.

¿Porqué necesitamos chequear la normalidad?

Muchas herramientas estadísticas han sido desarrolladas para mejorar procesos, entre ellas los gráficos de control, índices de capacidad de procesos, etc., y varias de estas herramientas exigen que la distribución de los datos siga una curva normal.

Informe Druida de Estadística y Calidad N°1

Por ejemplo, si la distribución es normal, el intervalo comprendido entre la media y tres desvíos estándar hacia ambos lados contiene el 99,7% de los valores. El índice C_p mide la relación entre seis desvíos estándar y las tolerancias de una característica:

$$C_p = \frac{\text{Tolerancia}}{6\sigma}$$

Si el índice de capacidad C_p supera el valor de uno, la tolerancia puede contener al menos seis veces la desviación estándar del proceso, es decir, el 99,7% de los datos.

Sin embargo, el razonamiento anterior solo es válido si los datos medidos se distribuyen normalmente. Si los datos no siguen una curva normal, no podemos afirmar que 99,7% se halla dentro del intervalo seis sigma, dado que este resultado depende de la distribución subyacente. Moraleja: es importante tener en cuenta si los datos son normales antes de analizar los índices de capacidad C_p y C_{pk} .

Asimismo en los procedimientos de diseño experimental, los resultados obtenidos solo son válidos si los residuos (diferencias entre el valor medido y el promedio) se distribuyen normalmente.

En control de procesos, para poder utilizar eficientemente gráficos de control para valores individuales, es necesario asegurarse que la población sigue una distribución Normal.

Tengo 10 observaciones de mi proceso ¿Ya puedo chequear la normalidad?

Momento! ... en primer lugar es importante tener en cuenta lo siguiente: las observaciones que yo analizo deben provenir de un proceso estable.

Además -y relacionado con la advertencia previa-, es importante que antes de comenzar a analizar la normalidad se responda a la siguiente pregunta: ¿Son los datos una muestra representativa de la población que queremos estudiar?

Si mientras se tomaban datos, causas especiales hacían que el proceso cambiara constantemente su promedio o su dispersión, los resultados que se obtienen no tendrán validez para ningún análisis de tipo preventivo.

Sólo se puede conocer realmente un proceso estable, porque todo proceso inestable involucra una incertidumbre demasiado alta, y esta incertidumbre hace excesivamente frágiles nuestras conclusiones.

Cuando hablamos de estabilidad no nos referimos a que todos los datos den el mismo resultado numérico, sino que el patrón de causas actuantes sea constante (causas comunes de variación) y origine un flujo de datos que oscila de manera aleatoria alrededor de un valor central.

En pocas palabras, tratemos de asegurarnos de que el proceso estudiado esté bajo control estadístico, para que nuestro estudio de normalidad nos permita extrapolar resultados y actuar con “conocimiento profundo” del proceso.

Procedimientos para chequear la normalidad

Como vimos, verificar la hipótesis de normalidad es importante para poder aplicar muchos de los procedimientos estadísticos que habitualmente se manejan. Existen varios procedimientos para validar esta hipótesis.


Inspección visual con Histograma

La simple exploración visual de los datos observados mediante, por ejemplo, un histograma, podrá ayudarnos a decidir si es razonable o no el considerar que lo mismos proceden de una población con distribución normal.

Sobre todo cuando podemos superponer sobre el histograma empírico la campana de Gauss que posee el mismo promedio y desvío estándar, se puede verificar si las clases del histograma siguen a la curva continua.

Uno de los test más populares, creado por Pearson a principios del siglo pasado, utiliza esta diferencia entre las clases y la curva para verificar la normalidad. Nos referimos al test Chi-Cuadrado, que a pesar de su popularidad resulta ser muy débil para detectar si los datos siguen una curva normal o no.


Informe Druida de Estadística y Calidad N°1



Inspección visual con Gráfico Probabilístico Normal

Los gráficos de probabilidad normal constituyen otra importante herramienta gráfica para comprobar si un conjunto de datos puede considerarse o no procedente de una distribución normal.

La idea básica consiste en enfrentar, en un mismo gráfico, los datos que han sido observados con los datos teóricos que se obtendrían de una distribución gaussiana. Si la distribución de la variable coincide con la normal, los puntos se concentrarán en torno a una línea recta, aunque conviene tener en cuenta que siempre tenderá a observarse mayor variabilidad en los extremos.



Informe Druida de Estadística y Calidad N°1

Test de Hipótesis y p-Value

Resulta obvio que los estudios que comentamos previamente nos permiten tener una opinión meramente subjetiva acerca de la posible distribución de nuestros datos, y que es necesario disponer de métodos más rigurosos para contrastar este tipo de hipótesis.

Los test de hipótesis son herramientas estadísticas que buscan verificar una determinada hipótesis (llamada hipótesis nula) a partir de evidencia estadística; si rechazamos esta hipótesis, se deberá aceptar una hipótesis alternativa.

Por ejemplo, un típico test de hipótesis es el siguiente: tengo un proceso cuya característica pH varía continuamente, y creo que la variación se produce alrededor de un valor medio de 6.00; mi hipótesis nula será que el promedio del pH del proceso es 6.00, mi hipótesis alternativa será que el promedio es diferente de 6.00.

Continuando con el test, tomo una muestra de varias observaciones, evalúo el pH de estas observaciones y decido si con una suficiente confianza (por ejemplo 95%), puedo confirmar que la muestra vino de una población cuyo promedio es 6.00, es decir, confirmar la hipótesis nula. Si el pH resultante de la muestra esta estadísticamente muy alejado de 6.00, tendré que rechazar la hipótesis de pH = 6.00 (con un nivel de confianza del 95%).

Hay que destacar que nunca estamos aceptando o rechazando nuestro planteo con 100% de certeza. Cuando acepto un nivel de confianza del 95%, significa que hay un 5% de riesgo asociado con esa decisión. Hay un 5% de riesgo de cometer el error y decir que rechazo la hipótesis nula (en el ejemplo, decir que el pH es distinto de 6.00), cuando en realidad la hipótesis nula era cierta (y el pH de la población es realmente 6.00).

Volvamos ahora a nuestra discusión sobre procesos gaussianos. En esta situación lo que tratamos de ver es si los datos provienen de una distribución normal, que será nuestra Hipótesis Nula, contra una Hipótesis Alternativa de No-Normalidad. Es decir:

H_0 : Los datos provienen de una distribución Normal.

H_1 : Los datos provienen de otra distribución.

Y, cuando tratemos de responder a esta pregunta en forma estadística, siempre tendremos que aceptar un riesgo (llamado nivel de significación) que puede ser 1%, 5%, 10%, etc. El termino “nivel de confianza” se usa como recíproco del riesgo: un riesgo del 5% representa una confianza del 95% (el riesgo es técnicamente llamado error de tipo I y referido con la letra griega alfa).

Para verificar esta hipótesis, se analizan los datos empíricos con distintos procedimientos, y se calcula la probabilidad de que los datos examinados provengan de una distribución normal. En base a esta probabilidad podemos concluir con cierta confianza que los datos provienen de una distribución normal.

Primero se determinan los límites de aceptación/rechazo de la hipótesis nula, es decir, aquellos límites en donde no voy a rechazar la normalidad. Para calcular estos límites se debe establecer un determinado valor de error admisible de tipo I (error alfa).

Este error es la probabilidad de que se rechace la normalidad, a pesar de que los datos siguen una distribución normal.

Si se establece un error tipo I de 0.10 (10%), significa que habrá un 10% de posibilidades de equivocarme rechazando la normalidad cuando en realidad los datos eran normales. Si disminuyo el riesgo al 5%, ahora estoy asumiendo menor posibilidad de equivocarme al rechazar normalidad, con lo cual el test será más “permisivo” en aceptar la normalidad.

Puede pasar que el test rechace al 10%, pero no rechace al 5%, eso significa que si acepto un riesgo (error posible) del 10%, puedo rechazar normalidad, pero si solo

Informe Druida de Estadística y Calidad N°1

quiero asumir un riesgo del 5% en mi decisión, el valor obtenido no se aleja tanto del valor para la curva normal como para rechazar la normalidad.

El valor de p que se puede obtener de los distintos test (p -value) indica la probabilidad de que una curva normal haya producido un resultado del test tal como el obtenido. Esto significa que el p -value se relaciona directamente como el nivel de significación y la confianza.

Si al hacer un test determinado, por ejemplo el test Anderson-Darling, obtenemos un p -Value de 0.07 (7%), tendremos que rechazar normalidad si asumimos un riesgo del 10%, porque el riesgo verdadero es menor al asumido. Sin embargo, si solo queremos asumir un riesgo del 5%, el p -Value obtenido no es lo suficientemente bajo como para rechazar que los datos sean gaussianos, porque el riesgo verdadero es mayor al asumido.

¿Cuáles son los tests más comunes?

A través de los años, fueron surgiendo varios tests para estudiar la normalidad de los datos. Vamos a describir los más comunes, y los recomendados en determinadas situaciones.

Los tests incorporados al SPAC¹ son:

1) Test de Regresión: Shapiro - Wilks

El test de Shapiro Wilks es muy recomendable como test de normalidad. Es muy hábil para detectar desvíos de normalidad en muchas situaciones (es decir, en procesos muy diversos).

Este test fue desarrollado en la década del 60, y todavía sigue siendo uno de los más utilizados en la práctica. Originalmente sólo permitía chequear muestras pequeñas. Actualmente gracias a nuevos métodos puede usarse en muestras de hasta 3000 observaciones.

El test se basa en la correlación entre dos estimaciones diferentes de la dispersión: una basada en los datos (s) y otra derivada de la pendiente del gráfico de probabilidad normal. El parámetro calculado se llama W : valores de W cercanos a uno indican similitud entre las dos estimaciones, y por lo tanto una mayor probabilidad de que la distribución sea normal.

2) Test Anderson - Darling

Algunos investigadores recomiendan este test antes que el de Shapiro-Wilks en muestras grandes (50-2000), porque el test de Shapiro-Wilks fue desarrollado originalmente pensando en muestras de menos de 50 observaciones.

El test está basado en la comparación entre la distribución empírica de frecuencias (EDF) y la distribución esperada si los datos fueran normales, utilizando una función de peso $1/[p(1-p)]$. Es una modificación del test de Kolmogorov-Smirnov (K-S) y da más peso a las colas que el test K-S. El test de K-S es de libre distribución, en el sentido de que los valores críticos no dependen de la distribución específica que es probada, y por esta razón es mucho menos potente que el test de Anderson - Darling para detectar normalidad.

3) Test Chi Cuadrado

Como comentamos previamente, una manera “intuitiva” de ver adecuación de los datos a la curva normal es utilizando un histograma y superponiendo una curva de Gauss graficada para el mismo promedio y desvío estándar que los datos.


¹ Se describen los test que aparecen en el nivel “básico” del Sistema, en las opciones “avanzadas” aparecen otros tests: D’Agostino, Cramer Von Mises, Kolmogorov-Smirnov, LaBreque, Shapiro-Chen, test del Sesgo, test de la Curtosis.

Informe Druida de Estadística y Calidad N°1

El test Chi Cuadrado examina la diferencia entre el histograma empírico (basado en los datos reales) y el histograma ideal (basado en la distribución normal). Cuanto más cerca este la “frecuencia observada” de la “frecuencia esperada”, es más factible que los datos analizados vengan de una distribución gaussiana. El estadístico que se calcula sigue una distribución Chi Cuadrada, de ahí el nombre del test.

El problema principal con este test es su dependencia del número de clases (barras) que vemos en el histograma. Puede ser que el test genere diferentes conclusiones según el número de clases que se grafiquen. Por esta razón este test se comenta más por razones históricas y por su popularidad, que por su utilidad para el estudio de normalidad de datos.

Hay que reconocer que el test Chi Cuadrado es útil en situaciones de “bondad de ajuste” cuando se trabaja con curvas no-normales (gamma, exponencial, etc.).



En este ejemplo, vemos que el test de Anderson-Darling rechaza la normalidad de estos datos al nivel 10, 5 y 1% de riesgo, mientras que el test Shapiro Wilks rechaza al nivel 10% y 5%, pero no le alcanza para rechazar con un 99% de confianza.

¿Qué hacer cuando los datos no son normales?

Supongamos que, luego de estudiar estadísticamente los datos, resolvemos que debemos rechazar la hipótesis de normalidad, ¿y ahora?.

En primer lugar es fundamental asegurarse que el proceso está bajo control y funcionando establemente, porque muchas veces la anormalidad proviene de la acción de causas especiales, y el origen del problema no está en la variable estudiada sino en la intervención de los operarios o ingenieros de los procesos (sobreajuste, sistema de medición empleado, u otros motivos). La primera pregunta que debemos hacer es “¿hay alguna causa que este produciendo “anormalidad” en la variable?”

Por ejemplo, si el “peso neto” de un producto es la variable controlada estadísticamente, y previamente a la etapa de inspección, el proceso pasa por una balanza que automáticamente segrega aquellas unidades por debajo de un determinado umbral de peso. La distribución de

Informe Druida de Estadística y Calidad N°1

peso “antes” de la balanza era normal, pero la distribución “después” de la balanza estará “recortada” y es claramente no-normal.

En segundo lugar: hay una serie de métodos utilizados para “transformar” datos no-normales en normales. Cada dato es transformado aplicando una función matemática del tipo $x_i = f(x)$, y la distribución que se obtiene de x_i muchas veces satisface los requerimientos de normalidad.

Las transformaciones más conocidas son:

- Exponencial
- Logarítmica
- Johnson
- Box-Cox

Muchas veces, luego de transformar la variable original siguiendo alguno de estos algoritmos, el histograma obtenido sigue una distribución gaussiana, permitiendo el uso de las herramientas estadísticas tradicionales.

De todos modos, utilizar gráficos de control estándar para variables “transformadas” implica trabajar con escalas numéricas artificiales, que ninguna relación guardan con los valores de la variable en el proceso, y esto lleva fácilmente al error en la interpretación de las señales de inestabilidad y dificulta el análisis de los datos. Por esta razón es generalmente desaconsejado el uso de la transformación de la variable, y si se utiliza se debe proceder con extremo cuidado.

Finalmente, otra alternativa es utilizar métodos específicamente desarrollados para procesos no-normales. En vez de usar gráficos de control con variables transformadas, conviene utilizar gráficos de control para características no-normales u otras formas de control. Por ejemplo, existen fórmulas para calcular versiones especiales de los índices de capacidad de proceso Cp-Cpk en casos poblaciones no-normales. En algún futuro en el “reporte Druida de Estadística y Calidad” nos dedicaremos a estos temas de capacidad de procesos no-normales.

Informe Druida de Estadística y Calidad N°1

Referencias y notas

Interesante e instructivo artículo de Pyzdec se puede encontrar en:

<http://www.qualitydigest.com/dec99/html/nonnormal.html>

Recomendable es el “Engineering Statistics e-Handbook” publicado on line por NIST en <http://www.itl.nist.gov/div898/handbook/>, en él se puede encontrar:

Explicación del Test Anderson-Darling

<http://www.itl.nist.gov/div898/handbook/eda/section3/eda35e.htm>

Explicación del Test Chi-cuadrado

<http://www.itl.nist.gov/div898/handbook/eda/section3/eda35f.htm>

Explicación del Test Kolmogorov-Smirnov

<http://www.itl.nist.gov/div898/handbook/eda/section3/eda35g.htm>

Un libro dedicado exclusivamente al chequeo de Normalidad es:

- Testing for Normality, Henry Thode, Marcel Dekker, 2002.

El siguiente libro es un clásico en el área de “Bondad de Ajuste” en general:

- Goodness-of-fit techniques, Ralph D’Agostino, Marcel Dekker, 1986.

Recientemente Chen y Shapiro presentaron un nuevo test (QH) que aparentemente tiene mucha potencia para detectar anormalidad:

- Chen, L. and Shapiro, S. (1995) An Alternative test for normality based on normalized spacings. *Journal of Statistical Computation and Simulation* 53, 269-287.
-