
AQC 2004 - Tamaño de la muestra - Análisis de Normalidad

Temas:

- Resumen de las principales presentaciones realizadas en el 58° Congreso Anual de la ASQ realizado en Toronto durante mayo de 2004.
- Determinación del tamaño de la muestra en poblaciones normales.
- Respuesta a inquietudes surgidas a partir del informe anterior "Normalidad de Datos".

Autor: Daniel Firka

-

Colaboración: Javier Carrizo

Agradecimientos: Juan Carlos Salas (Industria de Alimentos Dos en Uno SA - Sgo. de Chile) y Gustavo Ferrari (Estirenos SA - San Luis) por sus comentarios con problemáticas observadas en la práctica sobre el chequeo de normalidad.

Fecha: 12 de Julio de 2004.

AQC 2004 - Introducción

El AQC (Annual Quality Congress) es un de los dos mayores eventos anuales en el área de calidad (el otro es el congreso anual de la asociación europea para la calidad - EOQ) y atrae a cientos de participantes de todo el mundo. Los temas que se tratan aquí muestran generalmente cuáles son los tópicos más novedosos en el área de calidad y aplicaciones estadísticas a la calidad. A continuación se detallará una reseña de algunas de las presentaciones del AQC.

From Infancy to Maturity: Rethinking the role of ISO 9000 standards, TQM and Business Excellence Models – T. Conti

Tito Conti nos visitó el año pasado para el seminario Seis Sigma organizado por Fundece, y en ese encuentro expuso los lineamientos principales de su análisis de la relación entre ISO y TQM. Su presentación en la ASQ fue una profundización de este análisis.

Conti plantea que ISO 9000 se diferenció desde su origen de modelos orientados a TQM (Total Quality Management). Uno de los factores principales que dieron origen al modelo de premio Malcom Baldrige(USA) fue el incremento de la competencia entre productos japoneses y occidentales. Por esa razón, la satisfacción del cliente estuvo en primer lugar a la hora de construir este modelo. En contraste, ISO 9000 tiene sus raíces en la norma de defensa inglesa BSI 5750, donde el cumplimiento de expectativas no es una meta principal.

Además, el modelo ISO fue posicionado erróneamente como un modelo de mejora de la calidad, antes que un mecanismo que regula las relaciones entre empresas y entre empresas y gobierno.

Otro problema fue la despereja calificación de auditores que produjo una variación excesiva de la calidad de la certificación. Esto tiene como consecuencia un decremento de la confianza que provee la posesión de una certificación ISO. En un artículo donde estoy analizando la situación de Seis Sigma, planteo que el mismo inconveniente está surgiendo en la difusión de

Informe Druida de Estadística y Calidad N°2

la metodología Seis Sigma, donde este problema empeora por la ausencia de un ente centralizado que pueda acreditar a los entrenadores.

Conti no cree que la nueva versión ISO 9000-2000 mejore las perspectivas; en sus propias palabras: “un estándar más exigente no implica un estándar mejor aplicado”. Por esta razón, destaca la criticidad de reestablecer la confianza en las normas ISO.

Relacionado con los modelos de premios, comentó la euforia que durante los 90’ se generó respecto al proceso de autoevaluación o “self-assessment”, y el riesgo que esto implica cuando la evaluación se realiza solo con el objetivo de obtener un número. Esta tergiversación del sentido de la autoevaluación va totalmente en contra de uno de los 14 puntos de Deming (Punto 11: no basar la administración en números). Es mucho mejor cuando la autoevaluación solo implica un diagnóstico, y el número no se convierte en su razón de ser.

Propone el uso de un ciclo PDCA (*Plan-Do-Check-Act*) corporativo, donde la autoevaluación del modelo del premio sería fundamental para la etapa “C” de chequeo.

Otra propuesta interesante planteada por Conti es establecer “grados de cumplimiento” para armonizar los resultados obtenibles con ISO conjuntamente con aquellos que se pueden obtener en los premios. Estos grados podrían ser “Insuficiente-suficiente-bueno-sobresaliente (*sufficient-insufficient-good-outstanding*) y deberían ser reconocidos públicamente.

Un proceso de planeamiento de calidad requiere un balance entre estandarización y diferenciación. Los núcleos más internos de la empresa son aquellos que la definen competitivamente, posesionándola y brindando ventajas estratégicas. Este núcleo está fundamentalmente unido a la diferenciación, y por lo tanto su contenido principal se relaciona con conceptos de TQM. A medida que nos alejamos de este núcleo hacia áreas mas cercanas al medio ambiente externo, como clientes, proveedores, etc., el grado de diferenciación disminuye, mientras que el grado de estandarización se incrementa. Las normas ISO aparecen en las fases mas externas de este modelo.

The impact of Corporate Governance in the Quality of Management an approach to the evaluation of a Board of Director – H. Strachan and M. Bertin.

Nuestro país también estuvo presente en el congreso, a través de la presentación de Hugo Strachan y Marcos Bertin. Los autores presentaron un sistema de evaluación cuantitativa de consejos directivos. Este sistema consiste en una matriz donde se vuelcan numericamente una serie de atributos que reflejan el desempeño del consejo directivo. Esta evaluación se realiza con criterios de buenas prácticas de gobierno corporativo de varias instituciones, como el programa del premio nacional Malcom Baldrige, los principios de gobierno de OECD, etc. El objetivo es brindar un marco evaluativo cuantitativo que permita ubicar un consejo dentro del espectro de buenas prácticas, para diagnosticar puntos débiles e identificar fortalezas.

Promote Global Peace and Understanding: Build Bridges among Quality Organizations - Miraflora Gatchalian

En la misma sesión, Miraflora Gatchalian de Filipinas abogó por crear más puentes de comunicación entre organizaciones de calidad. Uno de los factores que impide salir de la pobreza y el subdesarrollo es la baja productividad, que a su vez es un efecto de muchos factores: baja calidad de materiales, baja calidad en la educación, malas condiciones laborales, etc. Miraflora expuso su creencia de que la colaboración entre organizaciones de calidad de países desarrollados, especialmente la ASQ (asociación americana para la calidad) y EOQ (organización europea para la calidad), con una actuación de soporte de la academia internacional de la calidad IAQ, podría ayudar a través de asesoría y soporte a subsanar muchos de estos factores inhibidores del desarrollo.

Informe Druida de Estadística y Calidad N°2

FMEA as a Gap Analysis / Transition Tool (ISO 9001:2000/TS16949:2002) – M. Ellis

Para empresas que están evaluando la transición entre ISO 9000-1994 a ISO 9000-2000, Michelle Ellis presentó un método de evaluación de la discrepancia actual de la compañía (gap-analysis) utilizando AMFE (análisis del modo de fallas y sus efectos). Su argumento gira en torno al nuevo énfasis de ISO 9000-2000 en procesos antes que en los elementos individuales. Hay cuatro aspectos de AMFE que la transforman en una herramienta adecuada para este análisis de Gap:

- 1- Es naturalmente una herramienta centrada en procesos, que trata de hallar posibles fallas (gaps) en un proceso.
- 2- Aunque la responsabilidad se asigna a un individuo, AMFE debe ser encarada por un equipo.
- 3- El proceso de armado de AMFE lleva automáticamente a establecer prioridades. La asignación de RPN (números de priorización de riesgo o *risk prioritization numbers*) permite identificar los puntos que deben ser considerados en primer lugar.
- 4- Provee mecanismos para documentar las acciones tomadas y sus responsables.

Batch Average Control Chart – J. Sun and L. Xu

El profesor Jin Sun, de la universidad de Beijing, presentó un gráfico de control adaptado especialmente para procesos autocorrelacionados, llamado BACC (*Batch Average Control Chart*). La ventaja de este gráfico es su similitud al familiar gráfico Shewhart. La desventaja es su poca sensibilidad a pequeños cambios en la media del proceso. Respecto de este último punto, un gráfico que resulta de más utilidad es el gráfico EWMA (*exponentially weighted moving average*) que ha sido recomendado para procesos autocorrelacionados.

On the path to Six Sigma through DOE – C. Vivacqua and A. Santos de Pinho

Carla Almeida Vivacqua y André Luís Santos de Pinho, de la Universidad de Rio Grande do Norte presentaron una aplicación del modelo DMAIC de Seis Sigma a un problema de producción de baterías.

Dos puntos destacaron en su presentación:

- 1- Para determinar las variables que más influyen en el problema, se realizó primero un proceso de tormenta de ideas (*brainstorming*). Este proceso arrojó 29 variables candidatas, pero esta cantidad impide aplicar económicamente métodos de diseño de experimentos. Entonces se utilizó un método para reducir el número de variables, asignando \$100 a cada integrante del equipo de mejora, y haciendo que cada uno “apueste” estos \$100 en las 29 variables de acuerdo a la importancia que le asigna. De esta manera se pudo realizar una “subasta de variables”, y reducir el número de variables a 6.
- 2- Las condiciones prácticas hacían imposible correr las 64 (2^6) combinaciones en forma aleatoria. Entonces se recurrió a un diseño llamado de “bloque particionado” (split block) que recuerda al diseño de “vectores internos y externos” de Taguchi.

Informe Druida de Estadística y Calidad N°2

A Fast-track to Performance Excellence: Creating World-class Organizations through a Benchmarking initiative – N. Grigg and R. Mann

R. Mann y N. Grigg del Centro de investigación sobre la Excelencia Organizacional de Nueva Zelanda, presentaron una iniciativa llamada New Zeland Benchmarking Club.

Para que una empresa pueda avanzar en el terreno de la competencia de clase mundial, es preciso primero poseer una definición operativa que permita cuantificar la situación actual y el grado de avance. En la iniciativa llevada a cabo en Nueva Zelanda la definición de competitividad de clase mundial es “lograr un mínimo de 700 puntos contra los criterios de excelencia del Malcom Baldrige (CPE: *Criteria for Performance Excellence*). Se toman dos ejes principales para avanzar en el proceso de mejora:

- Autoevaluación que :
 - - establece métricas objetivas que permiten evaluar los avances.
 - se realiza siguiendo un criterio numérico (basado en Malcom Baldrige o EFQM).
 - permite priorizar áreas con oportunidades de mejora.
- Benchmarking interno y externo que permite desarrollar mejores prácticas.

En el año 2001, con el objetivo de promover la competitividad de industrias en N. Zelanda, se creó el COER: *Centre for Organisational Excellence Research*. Su objetivo es integrar distintas iniciativas para ayudar a organizaciones en la mejora de la performance de sus negocios.

Una de los resultados del COER fue la creación del club de benchmarking de N. Zelanda, que agrupa 15 compañías líderes y cuyo objetivo es “ayudar a sus miembros a trabajar para lograr más de 700 puntos en el criterio Baldrige”.

Las principales razones por las cuales se organizó como un “club” son:

- Crea sinergia a través del esfuerzo común.
- Acelera mejoras en los procesos comunes.
- Crea confianza entre los miembros.
- Permite respetar sensibilidades comerciales
- Los miembros deciden en la dirección, velocidad, prioridades, etc.

El club intenta lograr un incremento de 50 puntos en la autoevaluación de acuerdo al CPE cada año. Para ello se organizan reuniones regulares, soporte para la implantación de buenas prácticas, identifican socios de *benchmarking* fuera del club, visitas de aprendizaje a las compañías con excelencia en ciertas prácticas, etc.

Transactional Kaizen: Process Improvement Events in an Office Environment - M. Upton

Malcom Upton, del George Group, sugirió una modificación al esquema DMAIC de Six Sigma, que llama “Kaizen transaccional”. En líneas generales, los principales cambios que propone son:

- 1- Unificar las etapas M/A, Medir y Analizar: dice que generalmente hay mucha superposición entre las actividades de estas dos etapas, lo que hace difícil evaluar las puertas de pasaje entre ambas.

Informe Druida de Estadística y Calidad N°2

-
- 2- Subdividir la etapa I (Mejora) en dos subetapas;
 - i. Diseño del nuevo proceso o plan de implementación, y ejecución piloto de la mejora.
 - ii. Implementación de la mejora
 - 3- Asignar al líder de proyecto mayor responsabilidad durante las últimas etapas del proyecto (a partir de la etapa *Improve*), liberando los recursos de *black belts* que pueden tomar otros proyectos.
-

Determinación del tamaño de la muestra en poblaciones normales

A continuación presentamos un método para estimar el tamaño de la muestra para un lote de cierta cantidad de unidades, suponiendo que la característica que medimos es una variable y se distribuye normalmente. El método que aquí describimos no es aplicable a cualquier lote, y rogamos evaluar bien las suposiciones, en lo posible con ayuda de una persona con sólidos conocimientos en estadística.

Supongamos que nos hallamos frente a un lote de producto, compuesto por unas 1000 unidades, y queremos verificar la hipótesis de que el peso promedio corresponde al objetivo que fijamos (valor target u objetivo de Peso).

La primera pregunta que surge es ¿cuántas unidades debo pesar? Es obvio que para tener total certeza necesito medir las 1000 unidades, pero esto es muy costoso en tiempo y dinero. Por lo tanto debemos recurrir a analizar un grupo de unidades tomadas al azar, pero... ¿cuántas?.

Vamos a suponer lo siguiente:

- 1- En base a los histogramas, gráfico de probabilidad y test de normalidad que vemos en SPAC, podemos decir que la característica peso tiene una distribución normal.
- 2- Podemos hacer una estimación de los límites de variación del proceso. Quizás a partir del desvío estándar que vemos en SPAC, o a través de un límite máximo y mínimo para el proceso¹.

Siempre que tomamos una muestra, estamos aceptando un riesgo de equivocarnos en las conclusiones. Entonces, antes de decidir cuál es el tamaño de la muestra, debemos decidir cuánta incertidumbre aceptamos en nuestra decisión, y cuál es el máximo error admisible para el promedio estimado. Si no queremos aceptar un margen de incertidumbre, tendremos que inspeccionar toda la población.

Hay tres cantidades que debemos definir antes de calcular el tamaño de la muestra:

- 1- El máximo error admisible E es la máxima diferencia entre el valor del promedio hallado y el promedio real de la población (μ). Muchas veces podemos arreglarnos estableciendo que el máximo error sea un determinado porcentaje de la dispersión, por ejemplo $E = 0.5 \sigma$ (como veremos, si elegimos esta forma del error admisible, no necesitaremos el valor de σ en la fórmula).

¹ Por ejemplo, si decimos que el peso varía entre 100g y 140g, una aproximación práctica es considerar el desvío estándar como Rango dividido 4, o sea $40g / 4 = 10g$.

Informe Druida de Estadística y Calidad N°2

2- Cuando tomemos la decisión, podemos cometer dos tipos de errores:

2.1: Decir que el peso es igual al Target, aunque en realidad el peso es distinto (riesgo beta). Este riesgo se llama generalmente Riesgo del Consumidor, porque nos hace aceptar el lote, aunque esta defectuoso.

2.2: Decir que el peso es distinto del Target, aunque realmente el peso promedio es igual al target (riesgo alfa). Este riesgo se llama riesgo del Productor, porque le rechazamos el lote, siendo que en realidad deberíamos aceptarlo.

Valores que generalmente se asumen en la practica son $\alpha = 0.1$ y $\beta = 0.05$, pero cada situación requiere evaluar el riesgo que uno aceptaría. Cuanto mayor riesgo, más pequeña la muestra.

Siguiendo con nuestro ejemplo, supongamos que el desvío estándar obtenido observando los datos en SPAC es de 4.00 g, y el máximo error admisible para el promedio obtenido sea de $\pm 2g$, es decir $E = 2g$.

La fórmula para hallar el número de unidades en la muestra si conocemos σ es²:

$$n = \left(\frac{(z_{\alpha/2} + z_{\beta}) \cdot \sigma}{E} \right)^2$$

Donde:

- $z_{\alpha/2}$: El valor de Z para un intervalo de confianza $(1 - \alpha/2).100\%$ Este valor es de 1.96 para un intervalo del 95%. En Excel la fórmula que provee este valor es `NORMINV( $\alpha/2, 0, 1$ )`; en nuestro ejemplo, usando 0.05 para α tendremos `NORMINV(0.025, 0, 1) = -1.959961082`
- z_{β} : El valor de Z para un intervalo de confianza $(1 - \beta).100\%$ Este valor es de 1.64 para un intervalo del 95%. En Excel, usando 0.10 para β tendremos `NORMINV(0.05, 0, 1) = -1.644853`
- σ : El desvío estándar estimado.
- E : El semi-ancho del intervalo.

Calculándolo en nuestro ejemplo:

$$n = \left(\frac{(1.96 + 1.64) \cdot 4.00g}{2g} \right)^2 = 51.84 \approx 52$$

Es interesante observar que si usamos para el Error E un valor relativo a la desviación estándar, como $E = 0.5 \sigma$, la fórmula se transforma en

$$n = \left(\frac{(z_{\alpha/2} + z_{\beta}) \cdot \sigma}{0.5 \cdot \sigma} \right)^2 = \left(\frac{(z_{\alpha/2} + z_{\beta})}{0.5} \right)^2$$

² Fórmula presentada en Breyfogle: "Implementing Six Sigma", Wiley IS, 2001, y Diamond, "Practical Experiment Designs for Engineers and Scientists". Van N. Reinhold, NY 1989

Informe Druida de Estadística y Calidad N°2

Lo que nos evita estimar el desvío estándar.

Es fundamental que las n unidades sean representativas, es decir, que cada unidad del lote tenga exactamente la misma probabilidad de ser incorporada en la muestra.

Cuando la muestra es muy grande respecto del tamaño de la población, por ejemplo, si la muestra es mayor del 5% de la población, es necesario realizar una corrección para muestras finitas, usando un factor llamado FPC (*Finite Population Correction factor*), obteniendo la siguiente fórmula para el tamaño muestral corregido:

$$n^* = \left(\frac{n}{1 + \frac{n}{N}} \right)$$

Respuestas en relación al boletín anterior "Chequeo de Normalidad"

Hemos tenido algunas consultas relacionadas con series de datos que parecen muy "gaussianas" en el histograma, pero que de acuerdo a los test más comunes de normalidad (Anderson Darling o Shapiro-Wilks) no son normales. Generalmente estas series de datos eran muy grandes, produciendo histogramas con muchas clases, que superpuestos a la campana teórica de Gauss se ven muy adecuados.

El problema es que los test de normalidad se hacen cada vez mas sensibles a medida que el número de unidades analizadas se incrementa. Como los test se basan en la distribución normal teórica, si el conjunto de datos que analizamos es muy grande, es muy probable que obtengamos como resultado un RECHAZO DE NORMALIDAD, a pesar de que la forma que se ve en el histograma parece totalmente normal.

En el otro extremo, tener una exigua cantidad de datos (<10) hace que los test sean muy poco efectivos, porque no tienen suficiente información para evaluar la normalidad. La real efectividad de los test aparece en rangos intermedios, cuando tenemos unas pocas decenas de datos, que sabemos positivamente que han venido de un proceso estable, y dudamos al mirar el histograma si podemos considerar al proceso normal.

En SPAC es fácil elegir un gran intervalo de tiempo, y analizarlo con cualquiera de los test, pero seguramente esto generará falla de la normalidad debido a la gran sensibilidad de los test para muchas observaciones. Los test de Sesgo o de Curtosis, disponibles en las <Opciones Avanzadas>, son mas insensibles al número de observaciones, y por eso puede dar una mejor indicación de normalidad para grandes conjuntos de datos. Otro test recomendado para muchos datos es el Jarque Bera.

En primer lugar, es fundamental definir para qué estoy verificando la normalidad.

Por ejemplo:

1- Deseo evaluar el comportamiento de una variable, y solo puedo tomar un dato por vez. Como los gráficos de control de valores individuales son muy sensibles a la normalidad, tengo que asegurarme que la variable siga una distribución normal.

Informe Druida de Estadística y Calidad N°2

>> En este caso lo que se debe hacer es realizar una serie de ensayos consecutivamente, tratando de mantener el proceso lo mas estable posible, y estudiar la normalidad de estos datos (es importante que solo actúen causas comunes de variación).


2- Tengo dudas sobre la aplicabilidad del concepto de Pp y Ppk en mis datos. Quiero establecer si todo un conjunto de datos correspondientes (por ejemplo durante un mes) se distribuye normalmente.

>> En este caso se puede ver gráficamente el ajuste de la campana de Gauss al histograma, o estudiar la linealidad del gráfico de probabilidad normal, adicionando los tests de normalidad más aplicables cuando hay muchos datos mencionados anteriormente.

No hay un consenso generalizado sobre cual es el mejor test de normalidad. El programa SAS recomienda usar Kolmogorov-Smirnov para más de 2000 datos, y Shapiro-Wilks cuando hay menos de 2000. El programa NCSS recomienda Shapiro-Wilks y Anderson-Darling. Sin embargo, algunos investigadores argumentan que el test de Shapiro fue desarrollado para grupos de menos de 50 observaciones, y recomiendan que para muestras mayores se utilice el test de Anderson-Darling o D'Agostino.

En resumen, como para muestras muy grandes existe una mayor probabilidad de que los tests de normalidad rechacen la hipótesis de Curva Normal, se sugiere investigar simultáneamente el gráfico de probabilidad normal, o tambien superponer la campana normal sobre el histograma de los datos, y de esta forma si poder asegurar que los datos corresponden a una distribución gaussiana.

Otro caso interesante se relaciona con la influencia del proceso de medición. Observemos el siguiente histograma :



Informe Druida de Estadística y Calidad N°2

Vemos que todos los test de normalidad fallan la hipótesis de proceso normal, aunque aparentemente los datos siguen a la curva normal superpuesta. Este problema se puede generar por la siguiente paradoja:

- 1- La distribución Normal es una distribución de variable continua, es decir, no existen “saltos” discretos entre los valores que asume la variable.
- 2- El sistema de medición utilizado no puede medir con infinita precisión, es decir, debe “cortar” el valor medido en valores discretos determinados por su resolución.

El instrumento medirá 16.2, 16.3, etc. cuando si usáramos un instrumento super-preciso el valor resultante sería 16.23123... , 16.31332... Los test de normalidad reaccionarán a esta discretización, rechazando normalidad. Esta situación se agrava cuando tenemos muchos datos, porque las observaciones comienzan a “acumularse” de acuerdo a la escala y resolución del sistema de medición.³

³ Notar que sólo se verifica esto visualmente cuando aumentamos mucho la cantidad de clases del histograma, y se empiezan a segregar clases de acuerdo a la resolución del instrumento.