

Evaluación de Sistemas de Medición

Temas:

- [Evaluación de sistemas de medición en ensayos destructivos.](#)
- [Evaluación de sistemas de medición en atributos.](#)
- [Ejemplo de evaluación de un sistema de medición para ensayos destructivos.](#)

Autor: **Daniel Firka**

Fecha: **10 de Mayo de 2005.**

Ilustraciones: Los gráficos usados en el informe son pantallas obtenidas a partir del módulo para análisis de sistemas de medición del SPAC (Sistema para el Aseg. de Calidad).

Evaluación de sistemas de medición para ensayos destructivos

Introducción

El presente texto intenta describir algunos métodos sugeridos para analizar sistemas de medición cuando los ensayos son destructivos. La información esta tomada de varias fuentes, pero principalmente de un artículo de enero de la revista *Journal of Quality Technology*¹

Cuando medimos una serie de unidades, la variación que queremos identificar es la correspondiente a las unidades medidas. Pero dado que no existen mediciones perfectas, siempre habrá una variación o “ruido” incorporada por el proceso de medición. Cuanto mayor es el ruido introducido por el sistema, más difícil es identificar claramente la señal de variación proveniente del producto.

Los principales objetivos de los estudios denominados **GR&R** son:

- 1- Determinar la magnitud de la variación observada en una serie de mediciones, debida al instrumento utilizado.
- 2- Identificar las fuentes de variación que influyen en el proceso de medición:
 - a. Variación debida a las unidades medidas.
 - b. Variación debida a que diferentes operadores han medido las unidades (u otras condiciones).

¹ De Mast, J & Trip, A: *Gauge R&R Studies for Destructive Measurements*. **Journal of Quality Technology**, Jan. 2005.

Informe Druida de Estadística y Calidad N° 3

- c. Variación debida a la forma en que los operadores miden las distintas piezas. Nos referimos a cuando los distintos operadores miden de diferente forma las distintas piezas o unidades. Esta variación se denomina interacción operador-pieza en los estudios RyR, y es muy perniciosa.
 - d. Variación debida a los distintos valores reportados por el instrumento de medición.
- 3- Verificar la capacidad del instrumento para medir el mensurando.

El método recomendado para realizar estos estudios es el análisis de *componentes de varianza*². En este estudio se toma una serie de unidades, y se miden varias veces por un grupo de operadores. El análisis estadístico permite descomponer la varianza total en los componentes 2.a , 2.b, 2.c y 2.d, detallados anteriormente y así evaluar la adecuación del sistema de medición.

Como conclusión, podemos decir entonces que analizando los resultados de un estudio GR&R podremos descubrir cuánta variabilidad es aportada por el sistema de medición. Esta variabilidad comúnmente se divide en dos partes: variabilidad del instrumento cuando mide bajo las mismas condiciones (mismo operador, misma pieza, mismo instrumento), llamada repetibilidad (2.d) , y variabilidad “entre diferentes condiciones” (por ejemplo entre operadores, entre laboratorios, etc.) llamada reproducibilidad (2.c + 2.b).

Un buen sistema de medición tiene baja variabilidad tanto respecto de la dispersión del proceso que debe medir (lo que se evalúa con un indicador llamado número de distintas categorías, o NDC), como respecto de la tolerancia o especificación (medido generalmente por un indicador llamado PTR o *precision to tolerance Ratio*)

Los primeros métodos desarrollados para evaluar sistemas de medición utilizaban estimaciones de la variabilidad basadas en los *rangos* entre mediciones. Estos métodos (expuestos en los manuales de AIAG³) son actualmente desaconsejados, siendo preferible estimar la variabilidad utilizando el Análisis de Varianza (ANOVA) descrito previamente.

Suposiciones de los estudios GR&R

En todo R&R, hay una serie de suposiciones que se deben dar por ciertas para que los resultados obtenidos sean válidos:

A) Constancia de Bias, tanto en el tiempo como en la escala.

Definimos **bias** (o error de justeza, o tendencia, o sesgo) como la diferencia entre el promedio de una gran cantidad de mediciones sobre **una misma unidad**, y el valor de referencia considerado verdadero. También se lo llama error sistemático de una medición. Suponer constancia de Bias implica:

² Varianza es un parámetro estadístico asociado a la dispersión. En este caso, la dispersión de los resultados de cada medición. En rigor, el método se denomina ANOVA de dos factores aleatorios, operadores y unidades o partes.

³ AIAG: Measurement System Analysis, 3rd Edition.

Informe Druida de Estadística y Calidad N° 3

- I. el error no cambia a lo largo de la escala de variación normal de los productos que medimos (linealidad). Por ejemplo, si una balanza mide el peso mostrando un valor 0.01 gr por encima del valor de referencia, esta diferencia o Bias sera igual tanto para un producto liviano como para un producto pesado.
- II. el Bias es constante en mediciones en distintos momentos de tiempo (estabilidad).

B) Homogeneidad del error de medición.

La distribución del error de medición es constante para **todas las unidades**, es decir, el instrumento no tiene distinta variabilidad según que pieza mida. Si la balanza tiene una variación interna o repetibilidad de 0,1 g, este “ancho de variación” no cambia según el peso del producto que mide.

Si tenemos una sola medición de una pieza, es imposible estimar la variación. Por eso estamos condenados a realizar una serie de mediciones y estimar la variación a partir de ellas. Ahora bien, para que estas distintas mediciones reflejen la variación del Sistema de Medición, es necesario hacer dos suposiciones más:

C) Estabilidad temporal de las mediciones.

El momento en que realizo la medición no afecta el resultado, esto me permite medir varias veces en distintos momentos a las piezas, y seguir obteniendo un resultado válido para la variación del sistema de medición.

Es fácil comprender esto con un ejemplo: quiero hacer un GR&R de un termómetro para medir la temperatura del agua con que tomo mate (soy muy quisquilloso y quiero siempre cebar con agua en la temperatura ideal de $85^{\circ}\text{C} \pm 2^{\circ}\text{C}^4$). Para mi estudio tendré tres operadores (mi madre, mi hermana y yo, todos expertos cebadores), cuatro unidades (cuatro pavas de mate recién calentadas), y tres repeticiones (cada operador mide tres veces la temperatura en cada pava). ¿Cual es la falla de este diseño? La pava se enfría con el tiempo, por lo tanto las variaciones de temperatura medida no se deben solo al termómetro o la habilidad para tomar la temperatura, sino a la inestabilidad temporal de las mediciones. Fallo de la suposición C.

D) Robustez a las mediciones.

Las mediciones consecutivas no modifican lo que estoy midiendo (el mensurando), esto me permite medir varias veces la misma unidad, y considerar que todas estas mediciones son equivalentes.

Esta suposición es mas problemática de lo que puede suponerse. Por ejemplo, si para medir la altura de un bizcochuelo utilizo un calibre, quizás hago presión excesiva con el calibre y modifico el mensurando, violando la suposición D. Los resultados evaluados incluirán no sólo la variación del calibre, sino también las modificaciones realizadas sobre el bizcochuelo.

⁴ El autor no ha realizado un experimento controlado para detectar esta temperatura ideal. Si alguno de los lectores de este boletín lo ha hecho, seria interesante que comparta su experiencia, que será incluida en futuras ediciones.

Problemas en ensayos o mediciones destructivas

Las mediciones llamadas **destructivas** son aquellas donde estas dos últimas suposiciones claramente no son cumplidas. Podemos evidenciar que no se cumple la suposición D, en el siguiente ejemplo: medimos el contenido de un ingrediente en forma de polvo que se deposita en forma de una banda en frascos de tomate al natural, y para ello debemos quitar todo el polvo y pesarlo. La medición afecta al mensurando y no podemos volver a medir el mismo frasco.

La única solución para el caso de ensayos destructivos es reemplazar las suposiciones C y D con otras que si podemos asumir. Veamos entonces una serie de suposiciones alternativas que nos permiten **simular** una homogeneidad entre piezas que nos dejan realizar el estudio GR&R:

E) Podemos tomar una serie de objetos que consideramos idénticos entre sí respecto al sistema de medición.

En el ejemplo del polvo en el frasco de tomate, supongamos que asumimos que cuatro frascos tomados consecutivamente tienen una variación despreciable en el peso del polvo, y podemos considerarlos idénticos. En este caso usaríamos el método estándar de RyR, con los siguientes cambios de interpretación:

N° de Piezas: en realidad, será el número de “grupos de piezas”, cada grupo contendrá una serie de piezas que consideramos idénticas. El número de unidades reales en cada grupo es igual al número de mediciones requeridas multiplicado por el número de operadores. Por ejemplo, si en mi estudio deseo medir 10 “piezas” tres veces por tres operadores distintos, debo tener 10 grupos de 9 piezas lo más similares entre sí que pueda.

N° de Repeticiones: este será el número de mediciones que queremos que tome cada operador de cada grupo de piezas indicado anteriormente.

F) Podemos encontrar una serie de objetos o unidades alternativas que proveen la misma distribución del error.

Supongamos que podemos crear en condiciones de laboratorio una serie de frascos patrones donde depositamos una cantidad muy precisa de polvo. Podremos utilizar estos frascos patrones para estudiar el sistema de medición.

El estudio es similar al realizado en el caso E.

Tanto en los casos E como F, hay parte de la variación del sistema de medición que viene de la variación entre las distintas piezas que destruimos, dado que no son perfectamente idénticas. Es importante tener esto en cuenta cuando realizamos el análisis. La variación del instrumento es levemente “inflada” por las diferencias entre las piezas.

G) Podemos asociar un patrón a la variación entre los objetos que vamos a medir.

Esto significa que podemos conocer como varía el producto (por ejemplo, en el ejemplo de la pava de mate, podemos asumir una disminución lineal de la temperatura con

Informe Druida de Estadística y Calidad N° 3

el tiempo, y luego incorporar en el modelo las correcciones necesarias), o si medimos en varias filas diferentes el producto que es depositado, podemos decir que hay una diferencia fija y constante entre las distintas filas.

En estos casos recurrimos a diseños experimentales más complejos y específicos: para el crecimiento o decrecimiento del primer caso utilizamos el modelo ANCOVA (análisis de la covariancia); para el segundo caso podemos utilizar un esquema de cuadrados latinos, con la salvedad que no podremos calcular las interacciones, si las hubiera.

H) Existe un procedimiento de medición diferente para el cual podemos asumir la suposición D (la pieza no se modifica al medirla).

En este caso, lo que haremos es tomar una serie de unidades y hacer un R&R usando este método alternativo, lo que nos permitirá estimar el valor de la variación de producto en las unidades. Luego, los mismos objetos son medidos usando el procedimiento destructivo, y calculando la varianza. Podemos así estimar la varianza del sistema de medición restando la varianza total calculada de la varianza del producto resultante del primer estudio.

Como un ejemplo, imaginemos la detección del espesor de una capa de fósforo en una pantalla. Esto se puede hacer usando un método con haces luminosos que nos permiten medir la opacidad sin destruir la pantalla. Pero este método no se puede usar en el proceso de producción, donde se utiliza un método destructivo quitando el fósforo y luego pesándolo. Para estudiar este sistema de medición se puede utilizar el método recién descrito.

I) Hay un procedimiento patrón muy preciso que nos permite hallar los valores de referencia de las mediciones.

Supongamos que podemos hallar con un procedimiento muy delicado la cantidad exacta de polvo en los frascos. El procedimiento consistirá en tomar una muestra grande de frascos, y dividirla en dos. La primera submuestra se evalúa con el procedimiento muy preciso, y a partir de este método se obtiene una estimación de la variación del proceso. La otra submuestra se evalúa usando el procedimiento corriente y a la variación obtenida, se le resta la variación del proceso, obteniendo la variación del sistema de medición.

En todos los casos antes señalados, generalmente en vez del modelo ANOVA convencional, se utiliza un modelo con un factor anidado (*nested*) debido a que cada operador mide piezas que son diferentes. Sin embargo, el análisis gráfico (análisis de efectos principales, de interacciones, y los distintos gráficos sugeridos por Wheeler en su clásico libro "Evaluating the measurement process" del 89).

Bibliografía

De Mast, J & Trip, A: Gauge R&R Studies for Destructive Measurements. Journal of Quality Technology, Jan. 2005.

Montgomery D.: Design of Experiments, 6 edition, Wiley, 2004

Informe Druida de Estadística y Calidad N° 3

Wheeler, D. and Lyday: Evaluating the measurement process. SPC Press, 1989

Burdick et al, 2003: A Review of Methods for Measurement Systems Capability Analysis, Journal of Quality Technology, Oct. 2003.

Evaluación de sistemas de medición en atributos

Como dijimos, los estudios GR&R buscan identificar cuánto “ruido” genera el sistema de medición en lo que estamos midiendo. En mediciones cuantitativas, cuando el resultado es un número, los métodos ANOVA nos permiten estudiar e identificar las distintas fuentes de variación. Sin embargo, existen muchas mediciones en donde el resultado solo puede expresarse como OK / NO OK, o Cumple/No Cumple, etc.

No existen hasta el momento métodos estándar y mayoritariamente aceptados para evaluar la capacidad de sistemas de medición cuando las características son de tipo Atributo. Describiremos aquí tres métodos propuestos, y adjuntamos algunas planillas en el boletín para que los interesados puedan realizar estos cálculos.⁵

El factor más importante para asegurar la adecuación del sistema de medición es tener una clara definición operativa del atributo, es decir, el método para juzgar si el atributo observado esta OK, o NO OK.

Método propuesto por Thomas Pyzdec⁶

Thomas Pyzdec propone las siguientes métricas para hacer un pseudo RyR de atributos:

Repetibilidad

Cuando un inspector evalúa el mismo ítem muchas veces en un período corto de tiempo, y siempre le asigna la misma categoría o el mismo valor de Ok-No Ok, podemos hablar de repetibilidad del sistema de medición del atributo.

Entonces, si el operador, en un corto período de tiempo, mide 10 veces una misma unidad, identificandola 8 veces como OK, y dos como NO OK, podremos calcular:

$$R = \frac{\text{Nro.Veces Que Concuerda la Evaluacion}}{\text{Nro. de Evaluaciones}}$$

⁵ Se adjuntan dos planillas, una confeccionada por el autor, la otra se puede bajar gratuitamente desde <http://www.isixsigma.com/st/msa/>

⁶ Pyzdec, Thomas, 2002: The Six Sigma Handbook, McGraw Hill

Informe Druida de Estadística y Calidad N° 3

Reproducibilidad

Decimos que el sistema de medición de atributos es reproducible, cuando todos los inspectores analizan un determinado ítem y lo asignan a la misma categoría, ya sea Ok, o NO OK.

$$R = \frac{\text{Nro. Veces Que Concuerdan todas las Evaluaciones}}{\text{Nro. de Evaluaciones}}$$

Linealidad

Si un inspector mide ítems cubriendo todo el grupo de categorías posibles, sus clasificaciones son consistentes en las distintas categorías. Esto puede servir para identificar si hay “interacción” entre las categorías y el inspector. Por ejemplo, puede ser que el inspector identifique muy consistentemente las unidades OK, pero tenga problemas para identificar las unidades NO OK... es decir: el *instrumento de medición* mide de manera diferente unidades en los dos puntos posibles de la escala.

Si podemos encontrar un experto (o panel de expertos) que examine las unidades seleccionadas luego de que el operador realizó la inspección, determinando cuáles están OK y cuales NO OK. Así, podemos encontrar un valor de referencia, y calcular el porcentaje correctamente identificado por cada operador, es decir, una idea de la “exactitud” de la medición.

Otro tipo de estudio se denomina “round robin”. Consiste en tomar una serie cuidadosamente seleccionada de objetos cubriendo el rango total de posibilidades para el atributo.

Luego se siguen los siguientes pasos:

- 1- cada ítem es evaluado por un experto y se guarda su decisión,
- 2- cada ítem es evaluado por cada inspector al menos dos veces. En este caso se calculan las siguientes métricas:
 - Porcentaje correcto por inspector
 - Repetibilidad por inspector
 - Reproducibilidad por inspector
 - Linealidad del inspector
 - Estabilidad (la variabilidad de los parámetros anteriores a través de varios estudios RyR).

Si no es posible tener un experto que pueda decidir cuál es el resultado Ok-No Ok, se puede hacer un estudio concurrente entre inspectores, siguiendo los mismos pasos que

Informe Druida de Estadística y Calidad N° 3

en el anterior, con la única diferencia que no se puede evaluar la “exactitud” de las apreciaciones de los inspectores, al no tener valores de referencia.

La matriz recomendada para realizar el estudio es la siguiente:

Parte/Unid. medida	Valor de Ref.	Insp. A	Insp. B	Insp. C	Fecha Turno	Reproducible	Exacto
1	1	1	1	1	01/01/05 Mañana	1	1
1	1	0	1	1	01/01/05 Tarde	0	0
2	0	0	0	0	01/01/05 Mañana	1	1
2	0	1	1	1	01/01/05 Tarde	0	1

En este ejemplo, el valor 1 significa OK, y 0 es NO OK. El *valor de referencia* es el indicado por el experto. La columna *reproducibile* vale 1 si los tres inspectores dan el mismo resultado (sea correcto o no). La columna *exacto* es 1 si los tres inspectores clasifican el objeto correctamente.

La exactitud individual de cada operador se determina comparando la clasificación de cada inspector respecto al valor de referencia. Por ejemplo, si el inspector A toma la decisión correcta 8 veces de 10 inspecciones, su exactitud es 80%.

La repetibilidad se puede evaluar así: supongamos que el estudio se hace a la mañana y a la tarde durante cinco días de cinco semanas consecutivas (por ejemplo, todos los lunes durante cinco semanas). Si el inspector dijo que está OK a la mañana y NO OK a la tarde en dos de esos cinco días, su repetibilidad es 3/5.

Reproducibilidad a pares es la comparación de cada inspector con todos los otros inspectores chequeando la misma parte el mismo momento del mismo día. Por ejemplo, si el inspector A tomo la misma decisión que el operador B en la misma oportunidad 6 de 10 veces, la reproducibilidad a pares es de 60% entre operador A y B. Con esto se puede calcular una matriz cruzada entre operadores.

Medidas generales: La repetibilidad general puede tomarse como el promedio de la repetibilidad de los operadores, la reproducibilidad como el promedio de las razones de reproducibilidad por cada día combinadas (suma de 1s y 0s de la columna reproducible de todo el día, dividido por el total de filas de ese día, y esos valores promediados entre los días).

Metodo de AIAG / Michael George ⁷

Tanto la AIAG como el George Group utilizan el cálculo del coeficiente Kappa, generalmente utilizado en análisis estadístico de datos categoriales dicotómicos.

Los pasos recomendados para el estudio son:

- Si solo hay dos categorías: OK y NO OK, se deben tener entre 20 y 50 unidades de cada tipo, tratando de tener 50% de cada tipo. Conviene elegir diferentes grados de OK y NO OK, cubriendo las situaciones que aparecen comunmente.
- Si hay mas de dos categorías, una de las cuales es OK y el resto son distintos modos de defectos, hacer el 50% OK y tener un mínimo de 10% de items en cada defecto, combinando algunos defectos como "otros". (no puede haber solapamiento entre categorías)
- Hacer que cada evaluador evalúe la misma unidad al menos dos veces.
- Calcular el Kappa para cada evaluador,
- Calcular el Kappa entre evaluadores
- Interpretar los resultados:
 - o Si $Kappa < 0.7$, el sistema de medición no es adecuado (0.75 en el caso de AIAG)
 - o Si $Kappa > 0.9$ el sistema de medición es excelente

El coeficiente Kappa se define como:

$$K = \frac{P_{observado} - P_{chance}}{1 - P_{chance}}$$

P_{observado}: proporción de unid. en que ambos evaluadores coinciden (tanto en que es OK como NO OK).

P_{chance} : proporción de coincidencia debida al azar, calculada como; (proporción que evaluador A dice que es OK * proporción que evaluador B dice que es OK) + (proporción que evaluador A dice que es NO OK * prop. eval. B dice que es NO OK)

Para evaluar Kappa de repetibilidad del mismo operador, comparamos las dos mediciones realizadas por el mismo operador sobre todas las piezas, realizando una grilla como la siguiente:

⁷ AIAG, Measurement System Analysis, 2ed, 2002.

George, M. et al, 2002, The Lean Six Sigma Toolbook, A

Informe Druida de Estadística y Calidad N° 3

		Operador N°1 - 1ra. Medición		
		OK	NO OK	
Operador N°1 2da. Medición	OK	50%	10%	60%
	NO OK	05%	35%	40%
		55%	45%	

Notemos que la información que colocamos en las celdas no es la cantidad absoluta, sino el porcentaje respecto del total de unidades en el estudio. Por ejemplo, si en total se analizaron 100 unidades, la primera celda indica que el operador identificó 50 unidades como OK en ambas mediciones.

P_{observado} es la suma de la diagonal $0.5 + 0.35 = 0.85$

P_{chance} es la suma cruzada $(0.6 \cdot 0.55) + (0.4 \cdot 0.45) = 0.51$

$$K = (0.85 - 0.51) / (1 - 0.51) = 0.693$$

El valor de K obtenido esta cerca del valor aceptable 0.7.

Para medir la reproducibilidad, realizamos la misma tabla comparativa, pero esta vez comparando dos operadores:

		Operador N° 1		
		OK	NO OK	
Operador N° 2	OK	9	3	12
	NO OK	2	6	8
		11	9	

Transformando los valores absolutos en relativos:

		Operador N° 1		
		OK	NO OK	
Operador N° 2	OK	0.45(45% de 20)	0.15	
	NO OK	0.1	0.3	

$$P_{\text{observado}} = 0.45 + 0.3$$

$$P_{\text{chance}} = 0.51$$

$$K = 0.489$$

Informe Druida de Estadística y Calidad N° 3

El valor de K está muy por debajo del límite admisible. Los dos operadores miden de manera muy diferente.

Este método ha sido muy criticado por las debilidades del coeficiente Kappa. El uso de la proporción de chance o acuerdo esperado es solamente válido en el caso de absoluta independencia de los jueces, lo que se da raramente. Otras características estadísticas hacen que el valor de *kappa* no sea comparable entre diferentes estudios, procedimientos o poblaciones (Thompson&Walter, 1988, Feinstein&Cichetti, 1990).

El valor de kappa puede dar muy bajo aunque haya altos niveles de acuerdo, y esto disminuye el valor del coeficiente para evaluar el sistema de medición. La decisión sobre qué valor de Kappa sea considerado bueno o malo depende del modelo que uno asuma sobre cómo toman decisiones los jueces (Uebersax, 1988). No he encontrado las justificaciones teóricas que utiliza AIAG o M. George para considerar 0.7 como umbral para considerar válido el sistema de medición.

Razón de Chances, (Odds ratio)

Para medición de atributos Pasa / No Pasa, una métrica considerada mucho más apropiada se denomina Razón de Chances u Odds Ratio. Esta métrica es muy utilizada en epidemiología, cuando se desea establecer, por ejemplo, cuánto se incrementan las chances de contraer una enfermedad entre un grupo expuesto o tratado con antibióticos, respecto a las chances que tiene un grupo control sin antibióticos.

El concepto de las chances que tenemos es familiar y proviene de los juegos de azar, podemos decir que las chances de que el equipo gane un partido son 3 a 1, y esto significa que la probabilidad de que el equipo gane es tres veces mayor que la probabilidad de que pierda. Es decir: las chances miden la probabilidad de que un evento suceda dividido por la probabilidad que no suceda.

Otro ejemplo, queremos saber si cuando nos invitan a comer, comemos más que cuando pagamos nosotros, y para ello construimos la siguiente tabla que mide la asociación entre la cantidad de comida ingerida y si la alimentación fue por cuenta propia (pago con su plata) o fue gratuita (fue invitado):

Comida		Gratis	Pagó	Total
Come más de 2 platos	Si	59	33	92
	No	17	44	61
Total		76	77	153

La probabilidad de haber comido gratis para aquellos que consumieron más de dos platos es $59/92 = 0.641$, mientras que la probabilidad de haber pagado y consumido más de dos platos es $33/92 = 0.359$. Entonces las chances de comer gratis para aquellos que comieron más de dos platos es $59/92 / 33/92 = 1.79$. Si las chances son mayores que uno, el evento es mas probable que suceda (es decir, si comió más de dos platos, es mas creible que haya comido gratis)

Informe Druida de Estadística y Calidad N° 3

También podemos calcular las chances de que comió gratis si no comió más de dos platos = $17/44 = 0.386$

EL OR (odds ratio) se usa para comparar las chances de dos grupos, dividiendo las chances de un grupo sobre las chances del otro. Por ejemplo, el OR para haber comido gratis entre aquellos que comieron más de dos platos es: $OR = (59/33) / 17/44 = 4.63$

Este OR es mayor que uno por esto concluiremos que en aquellos que comieron más de dos platos es significativamente más probable que haya sido gratis.

Llevando este método al plano de control de la calidad, podemos utilizar esta medida como un substituto más robusto de la métrica Kappa, por ejemplo para verificar si hay acuerdo entre dos jueces evaluando una muestra de unidades entre Ok y No OK. Lo primero que debemos hacer es construir una tabla como la siguiente:

		Juez N° 2	
		OK	No OK
Juez N° 1	Ok	A	B
	No OK	C	D

Por definición, el Odds Ratio es

$$OR = \frac{\left[\frac{a}{a+b} \right] / \left[\frac{b}{a+b} \right]}{\left[\frac{c}{c+d} \right] / \left[\frac{d}{c+d} \right]}$$

que se reduce a:

$$OR = \frac{\left[\frac{a}{b} \right]}{\left[\frac{c}{d} \right]} \quad (2) \text{ es decir: } OR = \frac{ad}{bc}$$

En la ecuación (2), el numerador a/b es la chance de que el segundo juez decidió Ok en vez de No OK cuando el segundo juez dijo OK. El denominador c/d es la chance de que el segundo juez diga positivo respecto de No OK, cuando el primer juez dijo No OK.

Informe Druida de Estadística y Calidad N° 3

OR es el cociente de ambas chances, indica cuanto las chances del segundo juez haciendo una elección de OK se incrementan en los casos en que el primer juez dice OK. Entonces OR puede interpretarse como una medida de asociación entre ambos jueces.

Q de Yule

OR puede ser transformado en una escala de -1 a 1 usando el parámetro Q de Yule:

$$Q = \frac{OR - 1}{OR + 1}$$

Log(OR)

En general es más conveniente trabajar con el logaritmo de OR, dado que nos permite hallar el error estandar del logaritmo, y a partir de él el intervalo de confianza:

$$\sigma_{\text{Log}(OR)} = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

Dado que podemos identificar la dispersión, podemos también calcular intervalos de confianza utilizando la siguiente fórmula:

$$\text{Log}(OR) \pm z_L \sigma_{\text{Log}(OR)}$$

Donde z_L es el valor de la variable normal estándar Z para el nivel de confianza requerido: 1.645 para 90% o 1.96 para 95%

Bibliografía

Agresti, A. : Categorical data analysis. New York, wiley, 1990.

Bland J.M. / Altman D.G. The odds ratio. British Medical Journal 320, 1468.

Feinstein & Cicchetti, 1990: High agreement but low kappa: I. The problems of two Paradoxes. Journal of Clinical Epidemiology 43(6): 543-9

Thompson & Walter, 1988: Kappa and the concept of independent errors. J.C.E. 41, 969-70

Uebachs, 1988: Diversity of decision-making models and the measurement of interrater agreement. Psychological Bulletin, 101, 140-146.

Pyzdek, Thomas, 2003: Six Sigma Handbook. Mc Graw Hill, New York, 2003

George, Michael, 2002: The Lean Six Sigma ToolBook, Mc Graw Hill, NY, 2002

Ejemplo de evaluación de un sistema de medición para ensayos destructivos

Veamos un ejemplo, donde queremos estudiar si nuestro equipo de medición de dureza es apto. Para medir la dureza, se utiliza una punta que presiona sobre una probeta, y el valor de dureza se obtiene de la profundidad alcanzada por la punta. Recordando nuestras suposiciones, aquí claramente no se cumple la suposición (D) :

D) Robustez a las mediciones: Las mediciones consecutivas no modifican lo que estoy midiendo (el mensurando)

Dado que al medir la dureza, perforamos e inutilizamos esa probeta, no podemos utilizarla para realizar una replica de la medición.

Supongamos que tenemos tres analistas, Juan, Pedro y Antonio, y queremos realizar dos “replicas” sobre seis probetas que representan el rango normal de variación de la dureza que mide el equipo. Utilizaremos el método E:

E) Podemos tomar una serie de objetos que consideramos idénticos entre sí respecto al sistema de medición.

Tomamos 6 grupos de probetas muy similares entre sí, cada grupo se compone de 6 unidades, y son medidas por tres analistas (Juan, Pedro y Antonio). Cada Analista mide dos unidades de cada grupo de seis.


Es muy importante que las mediciones se hagan al azar, es decir:

- 1° Dato: Juan realiza la primera medición de una probeta del grupo 4.
- 2° Dato: Pedro realiza la primera medición de una probeta del grupo 1.
- 3° Dato: Juan realiza la primera medición de una probeta del grupo 2.
- 4° Dato: Antonio realiza la primera medición de una probeta del grupo 3.
- etc. etc. etc.

Como se ve, la asignación de la probeta, y quién la mide, es totalmente al azar, y esto permite realizar el análisis de los resultados (este procedimiento se llama aleatorización, y se puede consultar cualquier texto de diseño experimental para un completo tratamiento del tema).

Informe Druida de Estadística y Calidad N° 3


Veamos algunos resultados:



A pesar de que la variabilidad de las distintas unidades “infla” la estimación del error, el análisis gráfico nos permite analizar el sistema de medición de la manera tradicional:


- El gráfico de promedios debe estar claramente “fuera de control”. Cuantos más puntos fuera de los límites naturales (o límites de control), mayor es la aptitud del sistema de medición. Cuando el ensayo es destructivo, los límites naturales de variación tienen incorporado el “ruido” debido a que no estamos midiendo varias veces la misma pieza, sino distintas piezas. Ese “ruido” agranda la franja entre los límites de control.
- El gráfico de rangos nos da una idea de la dispersión en las mediciones de cada operador. En este gráfico no deseamos que ocurran puntos Fuera de Control, dado que representan señales de excesiva variación cuando el operador midió. Aquí también los límites naturales para los rangos están “inflados” por la variabilidad del ensayo destructivo, pero se pueden estudiar patrones o puntos claramente diferentes.

Informe Druida de Estadística y Calidad N° 3



- En el gráfico de promedios apilados (también llamado de interacción) podemos verificar si los operadores miden de la misma forma las distintas partes (lo que se reflejaría en líneas paralelas entre los puntos medidos). También podemos ver si algún operador tiene un corrimiento determinado (o bias) (por ejemplo, por errores de paralelismo o mal uso de un calibre).
- El gráfico de rangos apilados nos permite contrastar la dispersión entre los distintos operadores. Vemos que Antonio tuvo alta dispersión (rango) al medir las probetas etiquetadas "Parte 4".

Informe Druida de Estadística y Calidad N° 3



- Tanto el gráfico de dispersión (referido como scatterplot por el manual de AIAG), como el gráfico de Corrida por Parte nos permiten verificar que no haya datos excesivamente alejados, y verificar que las distintas probetas que componen nuestra “parte” son similares entre sí, pero diferentes de las que componen otras “partes”.


Para analizar estadísticamente los componentes de variación del Sistema de Medición en ensayos destructivos, a veces se recomienda utilizar un diseño factorial anidado (*nested*), con el argumento que las partes son diferentes entre sí, y cada operador mide diferentes partes.

Un problema con estos diseños anidados es que no permiten determinar la componente de interacción entre parte y operador. Este indicador es crucial para evaluar la aptitud del sistema de medición, porque nos permite ver si los distintos operadores son inconsistentes entre ellos al medir partes de diferente tamaño.

Sin embargo, si podemos considerar las seis probetas “iguales” por la similaridad entre ellas, cuando Juan mide la “parte 1” está midiendo la “misma” parte que cuando Antonio mide la “parte 1”, aunque físicamente corresponden a diferentes probetas. Esto nos permite analizar la experiencia con un diseño experimental ANOVA de factores aleatorios cruzados.

Informe Druida de Estadística y Calidad N° 3

Por último, y para resaltar que el análisis gráfico es lo más importante en los estudios de aptitud de instrumentos, veamos algunos de los indicadores tradicionales de MSA:



Vemos que un 9% de la variación observada se relaciona con el sistema de medición, lo que generalmente se expresa mediante el indicador “relación S/N” o “Señal vs. Ruido”:

$$SNR = \frac{\sqrt{V_P}}{\sqrt{V_M}}$$

V_M : Varianza del Sistema de Medición, obtenida por el método ANOVA.

V_P : Varianza de las Partes Medidas

Cuanto mayor es la relación Señal-Ruido, menos “ruido” sera aportado por el sistema de medición, y mejor podremos identificar las señales provenientes del proceso.

El número de distintas categorías es:

$$ndc = \sqrt{\frac{2 \cdot V_P}{V_M}}$$

Informe Druida de Estadística y Calidad N° 3

Este número se relaciona con la cantidad de diferentes categorías que puede discernir el sistema de medición. En el manual de AIAG (Measurement System Analysis, 3rd ed), un valor por debajo de 2 se considera inaceptable, un valor por encima de 4 se considera aceptable.

Analizando respecto de la tolerancia, tenemos el indicador “Precision to Tolerance Ratio”, que se calcula como:

$$PTR = \frac{k\sqrt{V_M}}{Tolerancia}$$

El valor de k vale 6 (correspondiente a un ancho de seis sigma) o 5.15 (relacionado con una cobertura de las mediciones con un 95% de confianza). En este caso se utilizó el valor de k=6.

Algunos autores consideran aceptable el sistema de medición si $PTR < 10\%$ (AIAG, Montgomery, Runger), otros hablan del 20% como máximo aceptable (Mader, Wheeler) y finalmente Barrentine considera inaceptable el Sistema si $PTR > 30\%$.

Volvamos a repetir que en estos indicadores hay una parte de la variación asignada al Sistema de Medición debida a la diferencia entre las probetas que consideramos iguales.

Esta “confusión” siempre estará presente en estudios destructivos, no podemos eliminarla, pero si podemos tenerla en cuenta al analizar los resultados y planificar el experimento R&R.
