
Informe Druida de Estadística y Calidad N°5

Estimados Amigos,

en este quinto informe intentamos exponer el concepto de Regresión Logística para entornos relacionados con la calidad en la industria.

Por otro lado, hacemos una mención al último encuentro de Sameco por la mejora continua y comentamos dos interesantes artículos sobre la implementación de Seis Sigma.

A todos aquellos que les interese participar con alguna nota o comentario en el boletín, o sugerir algún tema, los escuchamos en info@druida.biz.

Nos despedimos hasta el próximo informe y aprovechamos la oportunidad para desearles un excelente 2006.-

El equipo de DRUIDA.-

ALGUNAS NOTICIAS

10° Encuentro Argentina de Mejora Continua

El pasado 29 y 30 de Septiembre de 2005, en el reconocido Centro Cultural General San Martín de la Ciudad de Buenos Aires, se llevó a cabo el "10° Encuentro de Mejora Continua", organizado por la Sociedad Argentina pro Mejoramiento Continuo (SAMECO) y auspiciado por la Dirección General de Tecnología del Gobierno de la Ciudad de Buenos Aires. Al evento, cuyo objetivo es el de "Promover y Difundir la Práctica del Mejoramiento Continuo" concurrieron más de 750 personas pertenecientes a 200 empresas e instituciones.

Durante estas dos intensas jornadas se cubrió un extenso Programa que incluyó trabajos realizados por Grupos de Mejora, Ponencias Técnicas sobre temas afines y Conferencias Plenarias. Las experiencias de mejora y los trabajos técnicos fueron previamente evaluados y seleccionados por Comités Técnicos creados a tal efecto, constituidos por prestigiosos especialistas.

Los temas abordados -de distintos grados de complejidad- mostraron el amplio alcance que tiene la Mejora Continua. Se presentaron experiencias de pequeñas, medianas y grandes empresas, instituciones públicas y privadas, como escuelas, universidades, municipios y cámaras empresarias; abordando temáticas tan diversas como Procesos, Calidad, Medio Ambiente, Trabajo en Equipo, Innovación, etc. y compartiendo investigaciones y desarrollos concretos de herramientas de gestión.

Informe Druida de Estadística y Calidad N°5

Las Conferencias estuvieron a cargo de importantes y reconocidas instituciones como el IRAM, la Fundación Premio Nacional (Fundapre) y la Universidad Gral. Sarmiento (UNGS) en conjunto con SAMECO.

Las jornadas se desarrollaron en un clima propicio que no sólo permitió recoger experiencias expuestas por los propios protagonistas, sino también compartir un espacio de integración e intercambio que se continuó en la cena de camaradería.

Como todos los años, el Encuentro promovió el reconocimiento de los verdaderos hacedores de la Mejora Continua, "*la gente, centro del desarrollo de las empresas*", representados en esta oportunidad por los participantes de los grupos de mejora y trabajos técnicos, integrados por personas de distintos niveles jerárquicos.

El evento se finalizó con la convocatoria al próximo XI Encuentro Anual en el 2006.

Para mayor información sobre los detalles de este evento y futuras actividades de SAMECO, pueden escribir a sameco@frgp.utn.edu.ar

ARTICULOS

Seis Sigma en PYMEs

Un reciente artículo aparecido en Inglaterra¹ analiza el grado de aplicación y los resultados obtenidos en PYMEs que utilizan la metodología Seis Sigma en el Reino Unido. Existe bastante evidencia acerca de las ventajas obtenidas por grandes compañías -General Electric, American Express, Texas Instruments, etc.- al aplicar los conceptos de Seis Sigma.

Típicamente estas ventajas se expresan en los resúmenes corporativos de las respectivas empresas, o son utilizados como ejemplos por los principales consultores de la metodología. Sin embargo, aún no hay muchos trabajos dedicados al grado de "aplicabilidad" o "compatibilidad" de Seis Sigma en PYMEs; el artículo aquí descrito intenta disminuir esa brecha de conocimiento.

Los autores obtuvieron una muestra aleatoria de 400 empresas pequeñas y medianas a partir de un catálogo de industrias. A estas compañías se les envió una encuesta para evaluar el grado de conocimiento e implementación de la metodología. Es destacable que la encuesta sólo fue respondida por 66 compañías de las 400 (16.5%), lo que refleja la dificultad para obtener información sobre PYMEs..

Analizando los resultados, en general se encontró un bajo porcentaje de empresas que conocían la metodología. En otros casos a pesar de conocer la metodología, las empresas consideraban que no poseían recursos suficientes su implementación. Respecto a este último aspecto, algunos autores/consultores proponen una aproximación diferente al tradicional concepto de "cinturones negros" (*black belt*) y "campeones" (*champion*). Por ejemplo, Mikel Harry propone utilizar "cinturones blancos" (*white belts*) con una curricula diferente que trabajan en pos de obtener tasas de retorno altas en muy poco tiempo (Harry and Crawford, 2004).

¹ Jiju, Antony; Maneesh, Kumar; Christian, N. Madu. "*Six sigma in small- and medium-sized UK manufacturing enterprises: Some empirical observations*". International Journal of Quality & Reliability Management, V.22-8.pp. 860 - 874

Informe Druida de Estadística y Calidad N°5

Otros autores (Snee y Hoerl,) descartan que sea necesario ningún cambio para hacer beneficiosa la aplicación de Seis Sigma en PYMEs, argumentando que el problema de fondo es la forma en que las consultoras de 6S han organizado la currícula y el modo de abordar la puesta en marcha.

Burton (Burton, 2004) propone modelos de implementación de Seis Sigma diferentes que permiten una puesta en marcha pausada que logra beneficios sin un excesivo compromiso de recursos ni la estructura tradicional de la metodología.

En el estudio se encontró que Lean Six Sigma es mucho menos popular que la versión más tradicional de Seis Sigma. Lean Six Sigma es una variante de la metodología que incorpora dentro de las herramientas utilizadas en los proyectos de mejora técnicas de manufactura esbelta o Lean.²

Según el estudio, las empresas ya embarcadas en Seis Sigma identificaron los siguientes factores como críticos para el éxito de la metodología en PYMEs:

- ***Participación Gerencial.***
- ***Enlazar Seis Sigma con los requerimientos del cliente***
- ***Enlazar Seis Sigma con la estrategia del negocio.***

A la pregunta "razones por las cuales no se embarcaron en Seis Sigma", la mayoría de los respondientes arguyo falta de conocimiento, y en segundo lugar falta de recursos.

Por otro lado, las tres herramientas más utilizadas en los proyectos, en orden de importancia:

- ***Mapa de procesos.***
- ***Histograma***
- ***Diagrama de causa y efecto.***

El artículo nos pareció sumamente interesante, y esta disponible online (pero a través de suscripción al servicio Emerald, en [esta página](#))

Bibliografía

- Burton, T. (2004), "Six sigma for small and medium sized businesses" (www.isixsigma.com)
- Harry, M. and Crawford, J.D. (2004), "Six sigma for the little guy", Mechanical Engineering, Vol. 126 No. 11, pp. 8-10.
- Snee, R.D. and Hoerl, R. (2003), Leading Six Sigma, Prentice-Hall, Upper Saddle River, NJ.
- Waxer, C. (2004), "Is six sigma just for large companies? What about small companies?", (www.isixsigma.com)
- Womack, J & Jones, D, 2003: Lean Thinking : Banish Waste and Create Wealth in Your Corporation. Free Press; 2nd Rev&Up edition
- Jiju, Antony; Maneesh, Kumar; Christian, N. Madu. "Six sigma in small- and medium-sized UK manufacturing enterprises: Some empirical observations". International Journal of Quality & Reliability Management, V.22-8.pp. 860 - 874

² Para una excelente explicación de los conceptos Lean recomendamos el libro de Womack "Lean Thinking" (Womack, J & Jones, D, 2003).

Seis Sigma en Taiwan

En el Foro Seis Sigma de la Sociedad Americana para la calidad³ apareció un trabajo comparativo de empresas que implementan Seis Sigma en Taiwan. El trabajo analiza Seis Sigma tanto desde el punto de vista de gerenciamiento como de performance obtenida, y compara resultados entre dos grupos:

- empresas locales (taiwanesas)
- empresas transnacionales con plantas en Taiwan.

En este caso se tomó una muestra de 160 empresas miembros de la Sociedad China para la Calidad en Taiwan (CSQ). Solo se eligieron empresas con cierto grado de implementación de la metodología, y finalmente se procesaron cuestionarios de 19 firmas, 10 taiwanesas y 9 transnacionales.

Los tres principales obstáculos encontrados para implementar Seis Sigma fueron:

- Falta de entrenamiento y educación
- Falta de presupuesto para Seis Sigma
- Falta de participación de los ejecutivos.

Los autores concluyen que una pieza clave para promover actividades de Seis Sigma en ambientes taiwaneses, es establecer una comprensión clara de la metodología dentro de la organización, permitiendo que todos los empleados tengan una misma visión.

Regresión Logística

Autor: Daniel Firka

Fecha: 17 de Enero de 2005.-

Objetivo: Descripción y aplicación del modelo de Regresión Logística.

Requisitos: Conocimiento y uso del concepto de Regresión Lineal.

Agradecimientos: Elbio Avanzini (Dulciora SA) por permitirnos realizar algunos comentarios sobre un proyecto por el llevado a cabo, para ejemplificar y dar mayor claridad al presente documento.

Introducción

El problema que intenta resolver la regresión logística surge cuando deseamos medir la *influencia* de una o más características de calidad sobre la aparición de una característica tipo *atributo* (ok / no ok, pasa / no pasa, etc.).

Por ejemplo, supongamos que fabricamos mermelada, y consideramos el atributo "untabilidad". La mermelada puede ser untable o no, pero no tenemos una variable continua que mida el "grado de untabilidad".

³ Cheng Jung-Lang: Comparative Study of Enterprises Implementing Six Sigma in Taiwan. ASQ- Six Sigma Forum (www.asq.org/sixsigma) , en la sección *Champions*


Informe Druida de Estadística y Calidad N°5

Lo primero que debemos hacer es verificar que tenemos una buena *definición operativa* del atributo en cuestión. Una buena definición operativa es aquella que minimiza la ambigüedad para decidir si una muestra de mermelada es untable o no.

En el *informe druida N°3* hablamos acerca de la *evaluación de sistemas de medición* en el caso de atributos. En muchos casos una mala definición operativa se manifiesta en este tipo de estudios, a través de valores bajos de repetibilidad y reproducibilidad⁴.

Supongamos que tenemos una buena definición operativa validada mediante una evaluación RyR, que nos brinda seguridad sobre los resultados de nuestras mediciones. Ahora queremos estudiar si la velocidad de la línea de producción *influye* en la untabilidad. En otras palabras queremos ver la untabilidad como *variable dependiente*, y la Velocidad de Línea como *variable independiente*


Para investigar nuestra hipótesis tenemos una serie de datos tabulados de la siguiente manera:



FECHA	VELOCIDAD	UNTABLE?
1-1-2000 12:23	23,	SI
1-1-2000 14:33	21,	SI
1-1-2000 15:33	18,	SI
1-1-2000 16:12	43,	SI
1-1-2000 18:21	23,	NO
1-1-2000 20:31	13,	NO
1-1-2000 23:11	92,	NO
2-1-2000 03:12	13,	SI
1-1-2000 04:41	35,	NO
1-1-2000 05:22	36,	SI
1-1-2000 06:12	10,	NO

Para realizar análisis bivariados o multivariados, seleccione la variable de respuesta y luego seleccione las variables independientes utilizando Ctrl-Click

Si la untabilidad fuese una variable numérica continua, lo primero que haríamos es un diagrama de dispersión (*scatter diagram*) para ver la variación de la untabilidad en función de la velocidad. Veamos el gráfico resultante (codificando el atributo untable con los números 1=Si Untable y 0=No Untable):




⁴ La repetibilidad mide la concordancia del inspector consigo mismo y Reproducibilidad la concordancia entre distintos inspectores


Informe Druida de Estadística y Calidad N°5

Este gráfico nos indica que aparentemente hay una relación entre la velocidad y la untabilidad: cuanto más rápido va la línea, mayor es la cantidad de muestras que resultaron untables; pero no es fácil comprender cómo funciona esta relación. A pesar de que en general hay más “untables” al aumentar la velocidad, todavía a velocidades altas se encuentran muestras “no untables”.

El panorama se aclara un poco si agrupamos la velocidad en categorías, por ejemplo velocidad baja, media y alta, colocando en el eje de ordenadas la proporción de muestras untables hallada en cada rango de velocidades. Así obtendríamos un gráfico como el siguiente:



En este gráfico se nota más claramente la influencia de la velocidad. Si siguiéramos un análisis tradicional de regresión lineal, nuestro próximo paso sería tratar de ubicar una recta que se adecue lo máximo posible a los datos observados, y que nos permita predecir el porcentaje de mermelada untable en función de la velocidad:



Sin embargo, aquí chocamos con dos inconvenientes:

- 1 El porcentaje untable hallado sólo puede variar entre 0 y 100%, sin embargo, la recta nos permitiría hallar velocidades para obtener más de 100% untable. Sería extraño que untemos 5 galletitas con mermelada, encontrando 7 galletitas untables debido a que corrimos a altísima velocidad la máquina.

Informe Druida de Estadística y Calidad N°5

- 2 El segundo problema es que realmente la recta no cubre correctamente los puntos observados. Si miramos el gráfico sin la recta, vemos que los puntos siguen una curva con forma de S inclinada, que se acerca a 0% a la izquierda, y a 100% a la derecha.

La diferencia fundamental es que el porcentaje untable posee peculiaridades que invalidan el análisis de regresión lineal.

El modelo logístico

Lo que estamos buscando es la influencia de los distintos valores de la velocidad, en la posibilidad de obtener una mermelada untable. Traducido estadísticamente, buscamos respuesta a la pregunta:

¿Cual es la probabilidad de que la mermelada sea untable cuando la velocidad de la línea es X m/s?

En regresión logística, esta probabilidad se modela a través de la distribución logística, cuya expresión matemática es:

$$\pi(x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

¿Que quiere decir esto? supongamos que los coeficientes β_0 y β_1 valen 2 y 3, respectivamente, y evaluamos la función para la velocidad 0,2 m/s:

$$\pi(x) = \frac{e^{2+3 \cdot 0.2}}{1 + e^{2+3 \cdot 0.2}} = 0.931 = 93.1\%$$

La proporción esperada de mermelada untable que se obtendría cuando la línea corre a 0.2 m/s es 93,1%.

¿Significa esto que cada fila en nuestra tabla de datos que muestre 0.2 m/s como velocidad va a tener como resultado 93,1% de untabilidad? ... No!

Recordemos que estamos en el reino de la incertidumbre, y todo modelo tiene que considerar una componente de error, que incluye todas aquellas causas y factores que no son explicados por la velocidad de la línea. Nuestro modelo en realidad es :

$$y = \pi(x) + \varepsilon$$

Donde el valor agregado al final corresponde a este "error" o "diferencia" no explicada por nuestro modelo, normalmente llamado "residuo". Si encontramos una experiencia donde la velocidad de la línea fue de 0.2 m/s , y la proporción untable observada fue 88%, el residuo para esta experiencia es:

$$\varepsilon = y - \pi(x) = 0.880 - 0.931 = -0.051 = -5.1\%$$

Informe Druida de Estadística y Calidad N°5

Volviendo a nuestro modelo, surge la pregunta ¿cómo sabemos que β_0 y β_1 valen 2 y 3? Para ello utilizamos métodos estadísticos de ajuste, que nos permiten descubrir los valores de β_0 y β_1 que más se adecuan a nuestras observaciones.

Un error que se comete generalmente en regresión logística es aplicar el valor obtenido a un único caso específico. Debemos recalcar que el resultado para un determinado valor de X es una estimación de la proporción de veces que se obtiene mermelada untada cuando la línea corre a la velocidad X.

Para los amantes de estadística que estén leyendo esto:

- 1 A diferencia del modelo tradicional de regresión lineal, donde el error es una variable con distribución normal, en el modelo de regresión logística el error se considera una variable con distribución binomial.
- 2 Por otro lado, la varianza del error es igual a $\pi(x)(1 - \pi(x))$ y el error depende del valor de x, lo que implica heterocedasticidad⁵ e invalida el análisis de regresión lineal.
- 3 Otra diferencia se relaciona con la forma de buscar los coeficientes β_0 y β_1 . En regresión lineal utilizamos el método de mínimos cuadrados, mientras que en regresión logística debemos maximizar la función de verosimilitud (*maximum likelihood*)

Nota sobre la fuente de los datos a analizar

En entornos de manufactura, es común poseer sistemas automáticos que almacenan información sobre variables de proceso o del producto, y muchas veces lo primero que el practicante quiere hacer es un análisis de regresión logística para estudiar las influencias sobre un determinado atributo. Pero cuidado!, cuando un proceso está fuera de control estadístico, los valores que asume son impredecibles y la variabilidad del proceso puede ser tan grande y fluctuante que es difícil y hasta contraproducente utilizar estos conglomerados de datos para tomar decisiones.

En el informe previo, Javier Carrizo describió la tradicional técnica de Gráficos de Control, que nos permite colocar un proceso bajo control estadístico, haciendo predecible su salida. Bajo estas circunstancias, nos encontramos ante la situación ideal para analizar correctamente los datos y realizar inferencias sobre las variables del proceso o producto.


En muchas situaciones no sabemos cuál es el estado del proceso, una posibilidad en la práctica es recolectar los datos del experimento en un plazo muy corto de tiempo, para minimizar influencias exógenas o cambios que introduzcan mucho ruido en nuestras mediciones.

En otros casos tenemos una cierta cantidad de información histórica que queremos evaluar, pero sabemos que mientras se tomaban estos datos el proceso quizás estuvo fuera de control. En estos casos hay que prestar mucha atención a los residuos del modelo, tratando de identificar aquellos residuos demasiado diferentes que indiquen datos incorrectamente cargados o demasiado excepcionales que distorsionan el resultado.

⁵ Heterocedasticidad es la existencia de una variancia no constante en las perturbaciones aleatorias de un modelo.

¿Que indican los coeficientes de la Regresión Logística?

Observemos el resultado de nuestro análisis:



Vemos que la respuesta puede indicarse como:

$$\text{Logit}(Y) = -1.499 + 0.042 \times \text{Velocidad}$$

Donde :

$$\beta_0 = -1.499$$

$$\beta_1 = 0.042$$

En la práctica lo primero que uno mira es el signo del coeficiente β_1 : si es positivo, indica que un aumento en esa variable esta asociado a mayor probabilidad de ocurrencia del atributo. Un valor negativo, por el contrario, indica que al crecer la variable, la probabilidad de ocurrencia del atributo disminuye.

Los coeficientes beta que estimamos en regresión logística son similares a los coeficientes b que se calculan en regresión lineal, pero su interpretación es distinta: el valor de β_1 , a diferencia de lo que ocurre con la regresión lineal, **no** representa el grado de incremento de la untabilidad ante un incremento unitario de la velocidad (es decir, el incremento de Y, variable dependiente, ante un cambio unitario de X, variable independiente). En regresión logística este coeficiente indica el cambio del "logaritmo de chances" (Log Odds) a medida que la velocidad cambia.

Un valor más simple de interpretar es e^{β_1} (el número e elevado al valor del coeficiente), que representa el efecto del cambio de la velocidad en la "Razon de Probabilidades" u Oportunidad Relativa (odds ratio) de la untabilidad. La Oportunidad Relativa mide la razón entre la probabilidad del evento (untable) sobre la probabilidad del no-evento (no untable). En castellano: si e^{β_1} es igual a dos, un cambio unitario en la velocidad de línea duplica las chances de que la mermelada sea untable. Si e^{β_1} es igual a uno, la velocidad de línea no tiene efecto sobre la untabilidad de la mermelada. Finalmente, si e^{β_1} es menor a uno, el aumento de la velocidad disminuye las chances de que la mermelada sea untable.

Verificación de la Bondad de Ajuste del modelo

El análisis de bondad de ajuste nos ayuda a responder a la siguiente pregunta:

¿Como sabemos si el modelo que utilizamos realmente me explica los cambios de untabilidad?

Es posible que mediante los algoritmos matemáticos obtengamos los coeficientes, y sin embargo al aplicar el modelo a nuestro set de datos, haya muy poco ajuste entre lo que el modelo predice (aplicando la fórmula) y lo que observamos empíricamente.

Se han desarrollado varios métodos para verificar la bondad de ajuste en regresión logística, entre ellos:

Hosmer-Lemeshow: este test mide el grado de ajuste entre las proporciones predichas por el modelo, y las proporciones observadas. Para ello agrupa los datos en categorías y realiza un test Chi Cuadrado. Si el resultado es significativo (por ejemplo, $p\text{-value} < 0.05$) implica una falta de ajuste, porque lo observado es significativamente diferente de lo esperado.

Test G, también llamado "test de razón de verosimilitud" (likelihood ratio test), responde a la pregunta : ¿puede ser que todos los coeficientes sean cero? (es decir, no hay ninguna influencia detectada por el modelo): es simplemente la diferencia entre el modelo con solo la constante (llamado nulo) y el modelo completo (incorporando la velocidad de línea), y calcula así el incremento de la adecuación del modelo por el agregado de la variables predictoras. El valor obtenido se distribuye aproximadamente como Chi Cuadrado. Si el resultado es significativo (por ejemplo, $p\text{-value} < 0.05$) al menos uno de los factores es significativo.

Significatividad de los parámetros.

Si además de la velocidad, tenemos otras variables que consideramos pueden afectar la untabilidad, debemos realizar una regresión logística múltiple. El procedimiento es similar al previo, pero tendremos una serie de coeficientes beta calculados para cada variable.

En palabras sencillas, decir que un coeficiente es "significativo" es afirmar que "vale la pena" tenerlo en cuenta en nuestro modelo. Cuando un coeficiente *no es significativo*, rechazamos la hipótesis nula de que tenga influencia en la untabilidad (la variable dependiente).

Una forma de determinar si el coeficiente beta es significativo es utilizando el test de Wald, que resulta en un valor distribuido como Chi Cuadrado. Cuanto más bajo el $p\text{-value}$ obtenido de este test, más confianza tenemos en que la variable es significativa.

En la cancha se ven los pingos...⁶

La descripción hasta ahora fue en general teórica. Es importante que toda herramienta de calidad pueda ser aplicada brindando soluciones a problemas reales. Una forma de medir esto es buscando artículos publicados en revistas relacionadas con estadística y calidad (como Quality Engineering, Journal of Quality Technology, etc.) para ver si hay artículos que exponen problemas resueltos mediante esta herramienta.

⁶ Dicho rioplatense de neto origen campero que expresa que los caballos -pingos- realmente buenos demuestran su calidad en el momento de la carrera. Podría equivaler al dicho el movimiento se demuestra andando <http://usuarios.lycos.es/interdesign/DICHOS%20Y%20REFRANES.html>

Informe Druida de Estadística y Calidad N°5

Hay muchas aplicaciones de Regresión Logística en el campo de la Epidemiología y la Medicina, pero recién últimamente comienzan a aparecer casos prácticos en ambientes industriales. Aquí comentamos dos artículos recientes:

Regresión Logística y Porcentaje Defectuoso

Una empresa de semiconductores basada en India (Joseph & Adya, 2001) uso regresión logística para predecir el porcentaje de rechazo en sus líneas de producción.

La planta industrial produce una gran diversidad de circuitos impresos, y el porcentaje defectuoso varía en función de la complejidad de cada tipo (la complejidad está asociada a varias características como número de capas, espaciado entre elementos, tipo de orificios, etc.).

En el trabajo se modela el porcentaje de rechazo como función de estas características asociadas a la complejidad.

Los resultados fueron útiles para poder planificar la cantidad a producir de determinado circuito, teniendo en cuenta el pedido del cliente y el porcentaje de rechazo previsto de acuerdo a la ecuación logística.

En este estudio, la fuente de información usada para el análisis fue el registro histórico de calidad del sistema informático, y utilizaron datos de un año de producción.

Apertura de latas de Aluminio

La empresa de cerveza Coors inventó las latas reciclables de aluminio en el año 1959. En el 2004 publican un artículo en Quality Engineering (Gojanovic & Sidor, 2004) utilizan Regresión Logística para estudiar un problema en la apertura de las latas: en algunas situaciones, cuando se presionaba la tapa para abrirla, en vez de abrir hacia el interior, la tapa se abría hacia el exterior, produciendo salpicaduras y exponiendo el filoso aluminio.

No se conocían claramente las causas del problema, por lo que se diseñó un experimento para evaluar las distintas variables que podían afectar: la orientación del grano en el aluminio, la altura del menisco que presiona, tres modelos diferentes de tapas, etc.

Para determinar estas variables se realizaron tormentas de ideas con expertos en el proceso productivo.

A diferencia del caso anterior, donde se tomaron datos de calidad históricos, aquí se diseñó un experimento y se realizaron pruebas industriales de todas las combinaciones posibles, lo que posibilitó un detallado estudio de regresión logística. La variable dependiente fue el porcentaje de "tapas que abren hacia afuera" en función de las variables supuestamente importantes.

Los autores subrayan la utilidad del análisis gráfico, que permitió comunicar claramente los resultados, y los inconvenientes que tuvieron para seleccionar el tamaño muestral: ellos eligieron 20 tapas, y al terminar el trabajo, vieron que en algunos casos para poder obtener un porcentaje adecuado hubiesen necesitado más muestras, y en otras situaciones con menos muestras hubiese alcanzado. En conclusión, el trabajo permitió elegir un nuevo modelo de lata que eliminó prácticamente el problema.

Extensiones de la Regresión Logística

Ya comentamos que los modelos logísticos pueden utilizarse para estudiar respuestas de varias variables independientes sobre una variable dependiente.

Las variables independientes pueden ser variables binarias o categóricas, pero en estos casos es necesario "transformarlas" en variables numéricas que permitan incorporarlas en la ecuación, por ejemplo, una variable binaria llamada "Tanque de Mermelada" que tiene dos valores "Tanque A" y "Tanque B" se transforma en una variable numérica que vale cero cuando la muestra viene del tanque A, y vale uno cuando viene del tanque B.

Hemos descrito la regresión logística considerando que la variable explicada o dependiente tiene solo dos valores posibles, pero hay otros modelos logísticos que se aplican a variables categoriales que pueden tener varios resultados, como el nivel de calidad, el matiz de color, etc. Dejamos la explicación de estos casos para un futuro boletín.

Otra variante de la regresión logística se produce cuando la variable dependiente es resultado de una función de Gauss o Normal aplicada a la combinación lineal de las variables de entrada o independientes. Este análisis se denomina Normit o Probit, y resulta en diferentes coeficientes e interpretaciones.

Conclusión

La Regresión Logística es una herramienta muy interesante para evaluar este elusivo tipo de características que solo admiten dos valores.

En nuestra experiencia hemos constatado que es asombrosamente más rica y productiva la información obtenida con variables numéricas, debido a las poderosas herramientas gráficas y analíticas que se han desarrollado. Sin embargo, siempre habrá casos donde la única salida medible es una variables binaria, y en estos casos es donde brilla la Regresión Logística.

Bibliografía en español sobre regresión logística.

Hemos hallado los siguientes datos sobre información en castellano sobre Regresión Logística. Dado que se inició en el entorno de ciencias de la salud, la mayoría de la información disponible corresponde a sujetos de Epidemiología y Bioestadística.

- Silva Ayçaguer (1995) Excursión a la regresión logística en ciencias de la salud .Ed. Díaz de Santos, Madrid
- Explicación en <http://www.uoc.edu/in3/e-math/docs/RegLogistica.pdf>

Bibliografía

- Joseph & Adya, 2001: "Prediction of Yield in a Multiproduct Batch Production Environment". Quality Engineering, 14(1), 153-159 (2001-02)
 - Gojanovic & Sidor, 2004: "Using Logistic Regression to Evaluate New Lid Designs" QUALITY ENGINEERING_ Vol. 16, No. 4, pp. 541-549, 2004
 - Hosmer, D.W., & Lemeshow, S. (2000). Applied logistic regression (2nd Edition). New York: Wiley: *El Clasico Libro sobre el tema.*
 - Long, J.S. (1997). Regression models for categorical and limited dependent variables. Thousand Oaks, CA: Sage.
 - O'Connel, A.A. (2006). Logistic regression models for ordinal response variables. Thousand Oaks: Sage. QASS #146.
 - Doran, H. (1989): "Applied Regression Analysis in Econometrics". Ed. Marcel Dekker, Inc.
-