

Estimados Amigos

Lo sabemos... paso mucho tiempo desde el último boletín; no es que nos olvidamos, sino que tuvimos un año ocupadísimo, y en lugar de preparar temas precariamente, preferimos esperar un poco más de tiempo y desarrollarlos con mayor profundidad.

Este boletín es interesante porque toca tres temas que cubren aspectos muy diversos del mundo de la calidad:

- *Herramientas Estadísticas: Javier Carrizo complementa su artículo sobre Regresión Lineal expuesto en el boletín 9, con las [técnicas de Regresión Múltiple](#).*
- *Observación y Experimentación: Daniel Firka nos describe la [diferencia entre estudios observacionales y experimentos](#), y los riesgos que corremos cuando confundimos ambos tipos.*
- *Seis Sigma: Daniel Firka presenta los resultados de una investigación sobre la [evolución de Seis Sigma en Argentina](#) en diversas compañías.*

Lo interesante es que a pesar de tratar temas tan distantes conceptualmente, todos tienen áreas de contacto, y dedicamos un apartado a mostrar las relaciones entre ellos.

Este año tuvimos la suerte de participar y asistir a varios congresos. En el próximo boletín presentaremos un resumen de las exposiciones más interesantes a las que asistimos.

Aprovechamos la oportunidad para desearles muy felices fiestas!!

El equipo de Druida.

Análisis de Regresión Múltiple

Autor: Javier Carrizo

Introducción

En el informe anterior vimos en que consiste el análisis de regresión simple, en esta oportunidad estudiaremos su extensión natural que es la **regresión múltiple**, uno de los métodos estadísticos más utilizados.

Recordemos que el análisis de regresión es el **procedimiento estadístico que estudia la relación funcional entre variables, con el objetivo de predecir una en función de otras**. Lo que intentamos hacer es determinar la ecuación de regresión lineal para predecir los valores de la variable dependiente (Y) en base a las variables independientes (X). En la regresión simple teníamos una sola variable independiente, en la regresión múltiple serán varias.

Caso de Estudio: “Producción de Combustible”

En esta oportunidad elegí un ejemplo real¹ desarrollado en una compañía petrolera, donde sospechaban que el volumen de producción de combustible (Y) estaba explicado o dependía de las propiedades de destilación de cierto tipo de petróleo crudo.

Estas propiedades son:

X_1 = Gravedad del Petróleo Crudo

X_2 = Presión de Vapor del Petróleo Crudo

X_3 = Temperatura de Evaporación Parcial de Líquido

X_4 = Temperatura de Evaporación Total de Líquido

La variable dependiente es la cantidad de combustible producido y está expresada como porcentaje del total del petróleo crudo procesado.

A partir de esta sospecha plantearon un modelo, es decir, recurrieron a la regresión múltiple para intentar **confirmar que la variación de la producción de combustible efectivamente depende de las variables que ellos proponen**. En primer lugar, vamos a definir nuestra ecuación de acuerdo al modelo lineal general:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon$$

Los coeficientes β son desconocidos para nosotros, por lo tanto debemos estimarlos, lo que se hace a través de un método denominado “mínimos cuadrados ordinarios”. Este método hace mínimas las diferencias entre los datos medidos y la función del modelo de regresión. Esas diferencias **se denominan residuos**. Podemos interpretar el residuo de cada observación como el “error” o la “parte no explicada” de nuestro modelo.

¹ N.H. Prater, *Estimate gasoline yields from crudes*, Hydrocarbon Processing, Mayo 1956.

Informe Druida de Estadística y Calidad N° 10

No desarrollaré este método en el presente informe, quien lo desee puede consultarlo en los libros de D. Montgomery (capítulo 15) ó el de G. Box, W. Hunter y J. Hunter (capítulo 14), que aparecen al final de este documento en las referencias bibliográficas.

Ingresamos entonces el set de datos² a un software estadístico³ para estimar los coeficientes, al hacerlo obtenemos la siguiente información respecto del modelo:

Análisis de Regresión sobre [Producción de Combustible]

Abrev.	Variable Predictora
X1	Gravedad del Petróleo Crudo
X2	Presión de Vapor del Petróleo Crudo
X3	Temperatura de Evaporación Parcial de Líquido
X4	Temperatura de Evaporación Total de Líquido

Y =	t	p-Value	VIF
-6,821	-0,67	0,51	
+0,227 X1	2,3	0,031	1,969
+0,554 X2	1,5	0,15	5,826
-0,150 X3	-5,1	0,000022	7,476
+0,155 X4	24	<0,00001	1,255
[X1] ² [X2] ²			
[X1] ² [X3] ²			

SSR	3429	R ² ajustado	0,957
SSE	135	F:	
SST	3564		pValue:
		172	0,000000

Incorporemos los coeficientes obtenidos a nuestra ecuación:

$$Y = -6.821 + 0.227X_1 + 0.554X_2 - 0.15X_3 + 0.155X_4$$

En el análisis de regresión múltiple se realizan dos tipos de pruebas, una prueba global y otras parciales. **La prueba global (F)** nos indicará que al menos uno de los coeficientes de regresión (los que acompañan a las variables predictoras), es distinto de cero, de alguna forma nos dice que el modelo que elegimos parece servir, es decir, que hay regresión.

Para ello nos planteamos una hipótesis nula donde decimos “Todos los coeficientes de regresión β son igual a cero”. Si el p-Value de la prueba F es menor a 0,05 rechazamos esta hipótesis, por lo que consideramos que al menos un coeficiente es diferente de 0, por lo tanto **la combinación lineal propuesta es significativa para explicar la variación en la producción de combustible.**

Excelente, ya sabemos que al menos uno de los coeficientes es distinto de cero, ahora con **las pruebas parciales (t)** vamos a determinar cuáles son significativos para el modelo elegido. **Aquellos que tengan un p-Value menor a 0,05 sí son significativos**, por lo tanto son

² El set de datos en una planilla de MS Excel está disponible en www.druida.biz/download/Boletin10.xls.

³ En la mayoría de los paquetes estadísticos se puede realizar un análisis de regresión múltiple. Usaré para este ejemplo el SPAC, en particular el Módulo para Estudios Fuera de Línea.

Informe Druida de Estadística y Calidad N° 10

válidos para el modelo. Si alguno de los coeficientes no es significativo podemos sacarlo del modelo e inclusive ir en busca de otros que si lo sean. Podemos dejarlos también, pero no estaríamos en condiciones de predecir valores, es decir, inferir que el modelo es apropiado para el futuro, solo nos serviría para analizar una situación pasada

En nuestro caso, β_0 y β_2 (p-Value>0,05) no son significativos por lo que podríamos sacarlos de la ecuación⁴, veamos que sucede:

Análisis de Regresión sobre [Producción de Combustible]

Abrev.	Variable Predictora
X1	Gravedad del Petróleo Crudo
X2	Presión de Vapor del Petróleo Crudo
X3	Temperatura de Evaporación Parcial de Líquido
X4	Temperatura de Evaporación Total de Líquido

Quitamos X2 del modelo.

Y =	t	p-Value	VIF	
☐ +0.274 X1	☒	6.9	<0.00001	1.967
☐ X2	☐			
☒ -0.179 X3	☒	-20	<0.00001	0.713
☒ +0.157 X4	☒	25	<0.00001	1.170
☐ [X1][X2]	☐			
☐ [X1][X3]	☐			
☐ [X1][X4]	☐			
☐ [X2][X3]	☐			

SSR: 3416 R² ajustado: 0.956 F: 336 pValue: 0.000000

SSE: 148 SST: 3564

Ver Modelo Distribucion Predicción Otros

Observamos que luego de sacarlos, los restantes coeficientes siguen siendo significativos.

Nuestra nueva ecuación, luego de eliminar del modelo la variable no significativa <Presión de Vapor X_2 > será la siguiente:

$$Y = 0.274X_1 - 0.179X_3 + 0.157X_4$$

El **coeficiente de determinación R_2** informalmente nos **indica el porcentaje de variación de la variable dependiente explicada por el modelo propuesto**, en nuestro ejemplo, el 95,6% de la variación de la producción de combustible, está explicado por las tres variables

⁴ NOTA: Si bien en el ejemplo se elimina el β_0 , generalmente es recomendable dejarlo en el modelo aunque no sea significativo, esto se relaciona con el sesgo de los coeficientes y también con asegurar que los residuos del modelo tengan media cero.

Informe Druida de Estadística y Calidad N° 10

independientes incluidas en el modelo. Podemos apreciar, que al sacar la variable presión de vapor de nuestro modelo, el R_2 no disminuyó.

Entre aquellos que son significativos **debemos estudiar cuanto aportan al modelo** para ver si es conveniente incluirlos. En el software con el que estemos trabajando seguramente podemos probar que pasa al incorporar o no una variable predictora, **evaluando si el aporte que hace al modelo es importante**, mejorando el coeficiente de determinación R_2 , o si no lo hace, en cuyo caso podemos descartarlo.

También podemos probar que sucede con **los efectos de dos variables independientes**. En muchas ocasiones una variable no es significativa por si sola, pero si puede serlo el producto de esta variable con alguna de las restantes.


Finalmente, puede ser muy tentador induir muchas variables independientes en el modelo para intentar alcanzar un alto coeficiente de determinación R_2 , sin embargo **cuan to más simple sea el modelo menor será el error acumulado**.

Bien, continuamos "con alegría". Supongamos que estamos satisfechos con el modelo elegido, bueno, ahora tendremos que chequear algunas cosas. En primer lugar que haya ausencia de autocorrelación.

La autocorrelación podría definirse como correlación de una variable consigo misma. Usualmente se encuentra en series de tiempo, se dice que los datos tienen "memoria" porque la variación de la regresión no es independiente de un periodo a otro.

Cuando sucede esto, no son buenos los estimadores de los coeficientes que obtenemos en el modelo, usando el método MCO (Minimos Cuadrados Ordinarios), ya que si bien siguen distribuyéndose normalmente, estos dejan de ser MELI, es decir, los Mejores Estimadores Lineales Insesgados.

Un método popularizado para detectar autocorrelación, es el de **Durbin-Watson** que busca rechazar la hipótesis nula de inexistencia de autocorrelación. En nuestro ejemplo, no hay autocorrelación:



Otro problema que se nos puede presentar es la **multicolinealidad**, lo que significa que hay una relación lineal o cuasilineal entre dos variables independientes, esto nos dice que **parte sustancial de la información en una o más de estas variables es redundante** y haría que los estimadores que se obtengan sean poco precisos, aunque sigan conservando la propiedad de lineales, insesgados y óptimos

Informe Druida de Estadística y Calidad N° 10

Si bien la presencia de multicolinealidad no afecta la capacidad predictiva del modelo, si **representa un grave problema si su propósito fundamental es evaluar la contribución individual de las variables explicativas.**

Hay dos tipos de multicolinealidad, la **exacta**, que indica la existencia de una relación perfectamente lineal entre dos variables, que sólo puede aparecer por un error en la especificación, cometido por quien propuso el modelo, que ignora esta igualdad entre variables. Sin embargo, más comúnmente puede aparecer la multicolinealidad **aproximada**, debida a relaciones de causalidad o bien de forma “casual” sin que exista ningún contenido teórico en la misma.

Un método difundido para detectar multicolinealidad consiste en calcular el **VIF** (Variance Inflation Factor), **factor de inflación de la variancia**, una regla general es considerar que no hay multicolinealidad cuando el VIF que se obtiene para cada variable predictora es menor a 10. En nuestro ejemplo observamos valores chicos, los que nos deja tranquilos con relación a este supuesto.

Y =		t	p-Value	VIF
+0.274 X1	☒	6.9	<0.00001	1.967
X2	☐			
-0.179 X3	☒	-20	<0.00001	0.713
+0.157 X4	☒	25	<0.00001	1.170
[X1][X2]	☐			
[X1][X3]	☐			
[X1][X4]	☐			
[X2][X3]	☐			

Finalmente, antes de chequear el modelo empíricamente y de ponernos a predecir con una alegría desenfrenada, debemos analizar el comportamiento de los residuos.

En primer lugar **los residuos deben distribuirse normalmente**, podemos chequearlo con algún análisis de normalidad como los de Anderson-Darling o Shapiro-Wilks y complementarlo observando el gráfico probabilístico normal.



Test de normalidad de Anderson-Darling





Gráfico probabilístico normal

El valor del p-Value (0,526) nos indica que los residuos en nuestro caso se distribuyen normalmente, si fuera menor a 0,05 deberíamos rechazar esa afirmación. El gráfico nos muestra los puntos cercanos a la recta, lo que nos ayuda a confirmar la normalidad visualmente.

Informe Druida de Estadística y Calidad N° 10

Es conveniente también analizar los residuos contra los valores estimados, contra el orden de las muestras y contra cada una de las variables independientes que forman parte del modelo como vemos a continuación:



Si estos gráficos no presentan patrones extraños, es decir, que los puntos se distribuyen aleatoriamente, se puede garantizar la **independencia de los residuos** y la **homogeneidad de variancias**. La dispersión entre las muestras se mantiene constante, uno de los supuestos importantes que debemos cumplir.

Como conclusión, podemos decir que **el modelo de regresión lineal múltiple propuesto resulta adecuado para ajustar los datos de producción de combustible**.

$$Y = 0.274X_1 - 0.179X_3 + 0.157X_4$$

Donde:

Y = Producción de Combustible

X_1 = Gravedad del Petróleo Crudo

Informe Druida de Estadística y Calidad N° 10

X_3 = Temperatura de Evaporación Parcial de Líquido

X_4 = Temperatura de Evaporación Total de Líquido

A la hora de presentar las conclusiones de nuestro análisis es fundamental explicitar las limitaciones de nuestro modelo, por ejemplo:

- Cuáles fueron las restricciones al tomar los datos que afectan el alcance de nuestro análisis.
- Cómo se definió la población, y qué cambios o variables exógenas podrían afectar la validez de nuestros resultados.
- Cuáles son los rangos permisibles para las variables independientes (para no alejarnos del entorno investigado al realizar predicciones).

Bibliografía

- Neter J., Wasserman W., Kutner M., 1996. "Applied Linear Statistical Models". McGraw-Hill/Irwin; 4 edition
 - Montgomery D.C., 2004. "Design and Analysis of Experiments". John Wiley & Sons; 6 edition
 - Canavos G., 1984. "Applied Probability and Statistical Methods". Little, Brown
 - Box G., Hunter W., Hunter, S., 1999. "Statistics for Experimenters. An introduction to Design, Data Analysis, and Model Building" John Wiley & Sons
 - Miller. I, Freund, J., Johnson, R., 1992. "Probability and Statistics for Engineers", Prentice Hall Inc., 4 edition
 - Mandell, J. 1982, "Use of the singular value decomposition in regression analysis". The American Statistician
-

Distinción entre estudios Exploratorios y estudios Confirmatorios

Autor: Daniel Firka

Caso de Estudio: Problemas de Fechado en Línea 3.

Resumen de las minutas de Reunión del Equipo de Mejora 121.

Problema: alta cantidad de defectos de fechado (estampado de la fecha sobre el producto) en línea 3 (línea de alta velocidad).

Reunión 1: Se conforma el equipo de mejora, se define claramente el problema, y se excluyen los defectos de fechados en otras líneas, decidiéndose concentrar en la línea 3 donde se producen los productos “estrella” de la compañía.

Reunión 2: El equipo está formado por expertos de la línea, operarios de mantenimiento y personal de calidad. Se discute el problema; cada persona opina sobre las causas involucradas. Se esboza un árbol de causas y luego de una votación se determina la causa más probable: mala alineación de las unidades en la cinta transportadora, que determina errores al estampar la fecha.

Reunión 3: Se analizan distintos modos de corregir el problema de alineación. Luego de una tormenta de ideas se llega a dos soluciones posibles. Una solución exige una inversión significativa comprando alineadores especiales e instalándolos aguas arriba en la línea productiva. La segunda solución propuesta consiste en aplicar “elementos redirectores” diseñados internamente por la gente de mantenimiento. Esta última solución no requiere inversión alguna y es fácil de implementar, pero no estamos tan seguros que vaya a funcionar.

Reunión 4: Se decide realizar un estudio confirmatorio para verificar si la solución “barata” es efectiva. Se realizará el siguiente experimento:

Con la línea trabajando a régimen constante en uno de los productos que mayores defectos genera, se medirá la ocurrencia de defectos de fechado cada 1000 unidades. La prueba se realizará durante tres turnos. Cada turno funcionará las primeras 4 horas sin cambios, tomando muestras, y en las segundas 4 hrs. se instalarán los elementos redirectores tomando nuevas muestras.

Reunión 5: Luego de realizado el experimento, se analizan estadísticamente los datos recolectados, y lamentablemente estos no arrojan un resultado positivo: el nivel de defectos no disminuyó significativamente al colocar los elementos redirectores (con un nivel de confianza del 95%). Se decide implantar la segunda solución: se solicita la aprobación del gasto y se inician las gestiones para realizar la inversión.

Reunión 6: Tema de la reunión: ¿porqué a pesar de haber instalado los nuevos alineadores, sigue habiendo un nivel altísimo de defectos de fechado?

Pregunta: ¿Dónde ve usted un problema en el recorrido que siguió este equipo de Mejora?

Respuesta: Al final del Artículo.

En el marco de metodologías de resolución de problemas – como el ciclo PDCA, el modelo DMAIC, etc.- es crítico entender la diferencia entre análisis exploratorios y confirmatorios.

En general, todo problema que amerite un tratamiento estructurado como DMAIC puede estudiarse como un sistema donde actúan causas (Xs) y efectos (Ys). Una condición base para resolver el problema consiste en descubrir aquellas causas que tienen mayor influencia sobre las variables críticas de salida.

Informe Druida de Estadística y Calidad N° 10

Pero antes de poder experimentar para verificar si ciertos factores causales son críticos, es necesario identificar estos factores candidatos. Un **experimento** es por definición un estudio acotado donde se trata de mantener el contexto bien constante (*ceteris paribus* como dicen los economistas) y variando sólo los factores que me interesan⁵. Pero esta coerción del contexto elimina grados de libertad que actúan durante el normal desempeño del proceso; es decir, en un experimento estamos **restringiendo** el funcionamiento del proceso para verificar o confirmar una hipótesis. Para que esto sea lógico, tenemos que estar seguros que los factores que dejamos fijos no tienen un efecto significativo (o sí lo tienen pero conscientemente decidimos dejarlos aparte del experimento).

A diferencia de un experimento, que es el ámbito de la confirmación o la verificación de hipótesis, en **estudios exploratorios u observacionales** analizamos el proceso en su **ambiente natural**, dejando que varíe libremente para que los factores influyentes salgan a la luz como características salientes en el set de datos.

Los **estudios confirmatorios** requieren que tengamos hipótesis a comprobar. Estas hipótesis pueden surgir de distinto modo:

- 1) A partir de “corazonadas” o ideas preconcebidas.
- 2) Luego de un proceso de análisis deductivo por parte de expertos en el problema.
- 3) Como resultado de características salientes encontradas en un estudio exploratorio.

La metodología DMAIC utilizada en Seis Sigma nos impide caer en el error de considerar solamente el método (1). Sin la guía del DMAIC corremos el riesgo de usar preconceptos o ideas previas, intentando aplicar “pseudosoluciones” al problema sin suficiente análisis científico.

¿Qué es una hipótesis? Es una conjetura que aventuramos basada en nuestro conocimiento del problema e información recolectada.

Los estudios exploratorios buscan identificar variables dependientes (Y) e independientes (X) que pueden resultar de interés para comprender o resolver un problema bajo estudio. Estos estudios no siguen reglas fijas codificadas, son más flexibles y especulativos; sin embargo, siempre parten de información recopilada sobre el problema en cuestión, y atraviesan tres etapas:

- 1) Graficar la información
- 2) Determinar características salientes
- 3) Interpretar las características salientes.

El principal objetivo de estos estudios es explorar con un espíritu abierto, buscando detalles inesperado sobre el set de datos y tratando de desentrañar la estructura escondida en el mar de números. Por esa razón las herramientas más utilizadas son gráficas, aprovechando la asombrosa capacidad de reconocimiento de patrones que todos tenemos.

⁵ Como es imposible dejar todo el resto de factores constantes, la única solución posible es aceptar que hay variación no controlada, pero eliminarla utilizando el procedimiento de aleatorización, donde la forma de realizar el experimento asegura que los factores no considerados se promedian entre sí y no contaminan los resultados del experimento.

Informe Druida de Estadística y Calidad N° 10

En los estudios confirmatorios en general imponemos modelos sobre los datos, en base a nuestro conocimiento del problema, y estos modelos nos permiten estimar que error cometemos al sacar conclusiones. Esto agrega ciertas restricciones que deben ser verificadas; por ejemplo, en análisis como ANOVA se asume que las discrepancias respecto al modelo se distribuyen normalmente. Si esta suposición no se verifica, las conclusiones pierden validez estadística.

En pocas palabras, los estudios exploratorios **generan** hipótesis sobre el problema, los estudios confirmatorios **confirman** estas hipótesis.

Luego de un estudio Confirmatorio puedo decir:

*“En base a mi análisis, puedo concluir que el Factor “temperatura del horno” es **significativo**, con un 95% de confianza”*

Luego de un estudio Observatorio puedo decir:

*“En base a mi análisis, considero que el Factor “temperatura del horno” **puede ser una causa importante para comprender mi problema.**”*

Leyendo ambos tipos de conclusión vemos que los estudios exploratorios carecen del rigor y objetividad que encontramos en los estudios confirmatorios, pero lo suplantamos con mayor libertad de opciones y apertura a diferentes interpretaciones. Las discusiones entre expertos y cruce de opiniones protagonizan el análisis exploratorio.

Como dice Wheeler: “Un estudio observacional es como prestar atención a un león en su hábitat salvaje en vez de investigarlo encerrados en una jaula... aunque podemos aprender ciertas cosas observando al león enjaulado, nuestro conocimiento puede ser mucho más completo si los observamos en libertad”⁶

En un estudio observacional o exploratorio, es importante estudiar detalladamente los datos ordenados cronológicamente, para descubrir señales que nos hablen de ciclos o comportamientos tendenciosos en las variables estudiadas. Posteriormente, cuando realicemos estudios confirmatorios, nos interesa que el tiempo no juegue un papel preponderante, porque no es un factor que podemos controlar en el proceso⁷.

Es importante recalcar que sólo podemos identificar efectos de factores que midamos y hayan variado durante el proceso de recolección de datos. Por esta razón en la fase exploratoria es fundamental dejar libre el proceso e incluir con cada medición la mayor información posible sobre variables controlables y no controlables del contexto.

En el flujo DMAIC, los estudios exploratorios surgen en la etapa M (Medir) y se extienden sobre la etapa A (Análisis). En muchos proyectos se da un proceso iterativo de ida y vuelta entre estas dos etapas, dado que el análisis puede conducir a nuevas mediciones y recopilación de información observacional que sugiere nuevos factores a tener en cuenta.

⁶ <http://www.spcpress.com/pdf/ExpRandoObs.pdf>

⁷ por eso se presta tanta atención al análisis de residuos ordenados en función del tiempo al analizar resultados de experimentos. Cuando vemos una tendencia en los residuos, significa que algún factor no controlado afectó a nuestro proceso a medida que el tiempo pasaba, y deberemos examinar que influencias externas pueden haber causado esta tendencia.

Informe Druida de Estadística y Calidad N° 10

En la etapa de análisis se produce el pasaje del estadio exploratorio al confirmatorio; cuando se han identificado factores candidatos, los estudios confirmatorios asociados frecuentemente a experimentos nos permitirán mensurar el efecto que estos factores tienen y descartar aquellos que no impactan significativamente.

Cuando el número de factores es muy grande incluso después del proceso exploratorio, técnicas como el diseño experimental factorial fraccional del tipo 2 k-p son herramienta valiosísimas para descartar factores de poca influencia.

En procesos transaccionales y servicios no disponemos generalmente de factores cuantitativos mensurables o susceptibles de experimentación. En estos casos cuando la exploración descubre muchos factores candidatos, algunas opciones son:

- Volver a la definición del problema, puede ser que el proceso involucrado sea muy complejo y debe ser subdividido en subprocesos acotados que nos permitan acercarnos a la solución en forma gradual.
- Priorizar los factores utilizando mecanismos más cualitativos como tormenta de ideas, votación, método Delphi, etc.
- Confirmar mediante pruebas pilotos donde se varían controladamente algunos factores causales.

Las herramientas gráficas más utilizadas en los estudios exploratorios son:

- Gráfico **Multivari** para estratificar los datos siguiendo diferentes criterios. El objetivo es buscar patrones de distribución que salten a la vista.
- **Histograma**: para ver si la distribución es unimodal o aparenta ser una mezcla de dos o más poblaciones identificables.
- **Gráfico de Control**: cuando los datos pueden ordenarse temporalmente, permite desentrañar tendencias o mediciones producidas por causas especiales de variación). Permite también verificar la homogeneidad del set de datos.
- Gráfico **probabilístico Normal**: permite identificar desviaciones respecto a la curva normal.
- **Diagrama de dispersión**, para analizar la relación entre dos variables.
- **Box Plot**, para determinar la influencia distintiva de distintos niveles de un factor sobre una variable.

El Dr. De Mast⁸, en un reciente artículo sobre el tema (DeMast, 2007), recomienda prestar particular atención a desvíos de la normalidad al investigar datos de estudios exploratorios. Veamos porque...

Si un proceso es el resultado de una serie de varios factores de similar importancia, la acción simultánea de estos factores produce un resultado aditivo cuya distribución es normal. Es

⁸ El Dr. Jeroe De Mast trabaja en el Inst. de Negocios y Estadística Industrial de la Univ. De Amsterdam. La siguiente entrevista (en inglés) puede resultar interesante, sobre todo a aquellos que trabajan en empresas de Servicios o áreas transaccionales de empresas Manufactureras: <http://www.onesixsigma.com/lean-six-sigma-community/interviews/jeroen-de-mast>

Informe Druida de Estadística y Calidad N° 10

decir que la suma de efectos disuelve los efectos individuales, generando una respuesta con forma de campana de Gauss donde es imposible individualizar los factores intervinientes.

Invirtiendo el razonamiento, cuando la distribución observada es normal, no nos brinda información sobre los efectos individuales actuantes. Por otro lado, la falta de normalidad habla de factores con diferente preponderancia actuando sobre el proceso. Esta es la razón por la cual se sugiere en estudios exploratorios buscar desvíos respecto a la normalidad.

Una vez identificadas características salientes, cosa que puede hacer un experto en estadística, es necesario interpretarlas para aventurar hipótesis. Esta interpretación exige el conocimiento del contexto en que se manifiesta el proceso. Por lo tanto, a la hora de entresacar hipótesis de estudios exploratorios, necesitamos incorporar en el análisis la mayor cantidad de expertos en el proceso involucrado, que nos permitan interpretar las características salientes descubiertas, y a partir de allí aventurar hipótesis a confirmar posteriormente.

Conclusión

Es importante conocer técnicas estadísticas: gráficos de control, ANOVA, DOE, etc. Pero aún más importante es saber aplicarlas sabiamente a un problema determinado. Mucho dinero y tiempo se pierde cuando salteamos la etapa exploratoria pasando directamente a tratar de confirmar nuestras corazonadas.

La próxima vez que mires un set de datos que te muestra un analista, la primera pregunta que tiene que surgir es : ¿Corresponde a un estudio exploratorio o confirmatorio? Porque las conclusiones y análisis que puedas hacer dependen de cómo fue obtenida la información que tienes ante tus ojos.

Referencias

- De Mast, J. & Trip, A. (2007): Exploratory Data Analysis in Quality-Improvement Projects. Journal of Quality Technology. Vol 39. No 4. Artículo del mes pasado donde el autor propone un camino para realizar estudios exploratorios (particularmente cuando las variables son cuantitativas)
- Tukey, John (1977), Exploratory Data Analysis, Addison-Wesley. J. Tukey es reconocido como el fundador de la línea de análisis exploratorio (EDA: Exploratory Data Analysis), como camino para construir hipótesis para testear.
- NIST/Sematech (2004): NIST Handbook: <http://www.itl.nist.gov/div898/handbook>
Un recurso gratuito con documentación exhaustiva sobre las técnicas de análisis exploratorio.

Respuesta al Caso 1: El inconveniente se debe a que la hipótesis sobre la causa del problema surge sólo a partir del conocimiento de expertos. No se realizaron estudios observacionales, que permitirían entresacar otras hipótesis posibles; descubrir incidencias mayores en determinados períodos de tiempo, efectos diferentes sobre distintos productos, etc. Podrían haber conducido a nuevas hipótesis causales que se deberían corroborar antes de saltar al proceso de buscar la acción correctiva/preventiva. Esto originó una pérdida de tiempo, dinero y motivación, y a fin de cuentas se debe volver a pensar en la causa del problema después de la reunión 6, a la que sólo asisten la mitad de los integrantes del equipo, no hay posibilidad de pedir más dinero para solucionar este problema, y hay tres proyectos más en marcha simultáneos.

Trabajo sobre la Evolución de Seis Sigma en la Argentina

Autor: Daniel Firka

En el año 2004, bajo la órbita del Instituto Argentino Para la Calidad (IACC), realizamos un estudio sobre la metodología Seis Sigma en el país, con entrevistas en profundidad en empresas que aplicaban la metodología. Esta investigación fue presentada con el título “Six Sigma within Transitional Economies: The Argentinean Case” en el 48° Congreso Anual de la EOQ (European Quality Organization) en Moscú, 2004. La metodología consistió en entrevistas en profundidad a protagonistas dentro de las compañías, buscando las características principales del despliegue y los desafíos particulares encontrados en economías en transición como la Argentina.

Ahora, tres años después realizamos un seguimiento para contrastar los resultados con las conclusiones del trabajo previo. El nuevo trabajo se presentó en Octubre en el congreso de la asociación Asia Pacífico para la Calidad (APQO), en Shanghai⁹.

Resumimos aquí algunas de las principales conclusiones del trabajo:

- 1) Si analizamos la situación de Seis Sigma en una empresa como resultado de una serie de factores causales, es decir $Y=f(x)$, descubrimos que estos factores incluyen - además de los tradicionales aspectos estáticos como soporte gerencial, recursos humanos comprometidos, portafolio de proyectos en curso, etc. - dependencias tales como:
 - a. El despliegue inicial (Y_0)
 - b. La historia previa del programa (Y_{t-1})
 - c. La percepción de los actores sobre cuál es el futuro del programa. (Y_{t+1})

Esta dependencia temporal - acción del pasado y futuro dentro de la misma organización- hace que la función que rige la evolución de Seis Sigma tenga un comportamiento muy complejo; no lineal y con alta autocorrelación¹⁰, mas relacionado con teorías de la complejidad que con sistemas determinísticos lineales. Esto limita la aplicabilidad de recetas simples y exige prestar mucha atención al contexto y la historia de la propia compañía para establecer estrategias relacionadas con el despliegue de Seis Sigma.

- 2) Luego de cuatro a seis años de iniciado el despliegue de Seis Sigma, la gran diversidad de experiencias hace difícil hablar de un modelo único. La cantidad de factores actuando en cada experiencia y su peso relativo crea caminos únicos para lo que las empresas llaman Seis Sigma. Esto dificulta la comparabilidad entre compañías, y se corre el riesgo de caer en una visión reduccionista y simplista que enumera sólo los aspectos macro de cada situación, con generalizaciones que no

⁹ “Six Sigma Evolution within transitional economies”, Asia Pacific Quality Organization Congress, Shanghai, October 2007.

¹⁰ Este tipo de sistemas es más susceptible de investigación con teorías de dinámica no lineal y caos que con herramientas tradicionales de análisis lineal (regresión, GLM, etc.)

Informe Druida de Estadística y Calidad N° 10

aportan demasiado a la hora de construir una teoría de los procesos de mejora continua.

- 3) En el contexto de economías en transición o países en desarrollo, hay una serie de factores particulares que añaden mayor complejidad a la hora de analizar el derrotero de la metodología dentro de una organización:
 - a. Inestabilidad macroeconómico y la adaptación del comportamiento de los actores organizacionales de acuerdo a la percepción sobre el futuro desempeño de la micro y macro economía.
 - b. Excesiva concentración en resultados a corto plazo.
 - c. Desconfianza o escepticismo implícito por diversas razones:
 - i. Programas previos de mejora que no lograron resultados exitosos (cero defectos, reingeniería, etc.).
 - ii. Desconfianza mayor como característica sociocultural, que predispone al individuo a descreer de nuevas propuestas.
 - 4) Algunas características observadas en el común de los casos:
 - a. Desarrollo y evolución del proceso de selección de proyectos. Cada compañía atraviesa un período de aprendizaje acerca de como filtrar los proyectos candidatos para identificar aquellos más adecuados a la metodología DMAIC y al set de recursos disponibles en la organización (Black Belts, Green Belts, infraestructura de soporte, etc.). En este sentido, tanto la tipología de proyectos elegidos en cuanto a alcance y contenido son criterios que evolucionan de manera particular en cada empresa.
 - b. Aumento de las herramientas estadísticas y de mejora de procesos disponibles para los practicantes. La robusta currícula del programa de capacitación en DMAIC, junto a la aplicación práctica de lo aprendido en proyectos concretos, genera un incremento en el bagaje de técnicas incorporadas al conocimiento organizacional. Como ejemplo particular, el análisis de sistemas de medición fue visto como una herramienta clave e innovativa que en varios casos desembarcó gracias al despliegue de Seis Sigma.
 - 5) No se evidenciaron efectos negativos como consecuencia del despliegue. En los casos que se suspendió el despliegue de la metodología el único efecto adverso fue un incremento en el escepticismo hacia eventuales nuevas metodologías de mejora continua.
 - 6) El soporte a nivel gerencial es un factor crítico durante las etapas tempranas del despliegue, permitiendo alocar recursos y alinear estratégicamente Seis Sigma. Sin embargo, luego de varios años de experiencia con Seis Sigma, el Criterio de Selección y Depuración de proyectos pasa a brillar como el factor más importante
-

Informe Druida de Estadística y Calidad N° 10

para la continuidad del programa. Podemos considerar que una forma de medir la madurez de Seis Sigma en una compañía es a través del modo como selecciona y asigna proyectos DMAIC.

Es importante entender el papel del Benchmarking: es un ejercicio importante, pero no debe copiarse a la empresa tomada como ejemplo, sino induir el conocimiento adquirido junto a un análisis introspectivo de la situación particular.

Tomando prestada terminología metrológica, podemos decir que en toda organización Seis Sigma debe ser

- **Calibrado** respecto a estándares de buenas prácticas externos (consultores, empresas ejemplares, bibliografía)
- **Ajustado** de acuerdo al propio ambiente interno, el pasado y las expectativas futuras.

Relación con teoría de Toma de Decisiones de Snowden y Boone

En la edición de noviembre de la revista *Harvard Business Review*¹¹, los profesores Snowden y Boone exponen una teoría que avala y complementa las conclusiones a las que hemos llegado en nuestro trabajo sobre Seis Sigma.

La síntesis de su investigación es la siguiente: antes de actuar ante una determinada situación, todo líder debe reconocer el contexto que la gobierna, y tomar acciones de acuerdo al mismo.

La nueva perspectiva planteada por Snowden/Boone se basa precisamente en la ciencia de la Complejidad, y divide todo contexto en cuatro tipos:

- Contextos **simples**, caracterizados por la estabilidad y relaciones de causa-efecto. Las acciones a tomar frente a cada situación son evidentes y comprensibles para todos los actores.¹²
- Contextos **complicados**, donde sigue existiendo relaciones causa-efecto, pero pueden existir múltiples respuestas correctas y no todos los involucrados pueden verlas. Es el reino de los expertos que pueden sopesar distintas soluciones alternativas, a veces con consecuencias disímiles.¹³
- Contextos **complejos**, donde no existen respuestas exactas, altamente dinámicos y donde rigen los flujos y la impredecibilidad. Es el reino de los patrones emergentes, donde las decisiones deben surgir no tanto a partir de un análisis lineal de causa-efecto, sino a partir de pruebas exploratorias y decisiones consensuadas con alta interacción y comunicación entre los involucrados.
- Contextos **caóticos**, donde no se pueden buscar respuestas adecuadas, no hay patrones manejables ni relaciones causa-efecto comprensibles. Lo primero que debe

¹¹ Snowden, D. & Boone, M.: *A Leader's Framework for Decision Making*. Harvard Business Review. Nov. 2007.

¹² En general, en el marco de proyectos Seis Sigma, este contexto simple se logra en la etapa C (control) del ciclo DMAIC, cuando el proceso es conocido, bajo control y se establecen los mecanismos para restaurar el statu-quo ante ausencias de control.

¹³ Encontramos contextos complicados en las etapas M y A del ciclo DMAIC, cuando requerimos la asistencia de expertos para comprender el problema y establecer las distintas X's e Y's.

Informe Druida de Estadística y Calidad N° 10

hacerse es tratar de establecer orden, al menos un poco de estabilidad que transforme el contexto en complejo, para poder luego identificar patrones emergentes que puedan prevenir crisis futuras y discernir nuevas oportunidades. La comunicación tiene que ser directamente Top-Down porque simplemente no hay tiempo para buscar consenso. Estas situaciones son excepcionales, no pueden representar la respuesta rutinaria de los líderes ante cualquier problema.

- El último contexto, desorden, aplica cuando la situación no puede ser asignada a ninguno de los otros contextos; en este caso se debe buscar partir la solución en componentes manejables y asignar cada uno a la categoría correspondiente.

Comentábamos en nuestra conclusión N°1 que la situación de Seis Sigma en una empresa se presta más al análisis desde la teoría de la Complejidad. Coincidentemente los autores del artículo expresan que en las empresas actuales el contexto predominante es el contexto complejo, y los líderes deben aprender a lidiar con situaciones que no se rigen con el tradicional método de “manejar y controlar” (*command and control*).

...“Los líderes que tratan de imponer orden en un contexto complejo fallarán, pero aquellos que establezcan un escenario, den un paso hacia atrás, permitan la emergencia de patrones, y determines cuáles de ellos son deseables verán el éxito. Podrán discernir muchas oportunidades para la innovación, creatividad, y nuevos modelos de negocios”¹⁴

Empresas con implementaciones maduras de Seis Sigmas podrían aprovechar el marco planteado para seleccionar el estilo de toma de decisiones más apropiado de acuerdo al contexto imperante.

Utilizando la terminología descrita, podemos decir que el despliegue de Seis Sigma genera un contexto **complejo** para tratar problemas **complicados**.

Referencias

- Firka, D. (2004): Six Sigma Implementation within Transitional Economies-The Argentinean Case. *Transactions of the 48th European Quality Congress. Moscow 2004.*
- Firka, D. (2007): Six Sigma Evolution within Transitional Economies-The Argentinean Case. *Transactions of the 10th Asia-Pacific Quality Organization Congress. Shanghai 2007.*
- Snowden, D. & Boone, M (2007).: A Leader's Framework for Decision Making. *Harvard Business Review*. Nov. 2007

¹⁴ Ibid, p.74 (T.del A.)

Relación entre los tres temas del Boletín

En este boletín tratamos tres temas que aunque parezcan muy disímiles entre sí tienen puntos de contacto y relaciones que queremos subrayar:

Regresión Múltiple y Estudios Observacionales/Experimentales

Los estudios de Regresión múltiple son útiles tanto en estudios observacionales como en experimentos, pero es importante señalar la diferencia en perspectiva que cada tipo de estudio implica.

Si estamos realizando un estudio observacional, analizando un set de datos de información histórica¹⁵, debemos recordar nuestra falta de control sobre el **contexto** donde se tomaron los datos. Esto implica que en la mayoría de los casos encontraremos datos espurios o extraordinarios, resultantes de errores de tipeo, fallas impredecibles, cambios de turno, instrumentos de medición, etc. Estos datos se evidencian en el análisis de los residuos, y en vez de descartarlos tenemos que buscar la causa y ver si nos ayudan a comprender mejor el fenómeno estudiado. Recordemos que en esta instancia estamos **buscando** hipótesis explicativas.

En un estudio experimental, tenemos mayor control sobre el contexto, y en base a las hipótesis que **ya tenemos en la cabeza** seleccionamos un grupo de variables independientes X y planificamos el experimento. El set de datos resultante confirmará o refutará nuestras hipótesis. Aquí, luego de observar los residuos para cerciorarnos de la aptitud del modelo, pasaremos a investigar los coeficientes Beta y los niveles de significación obtenidos. El planteo final de la ecuación de regresión y la predicción de valores es un producto generalmente de esta instancia experimental.

No significa que no se puede plantear la ecuación de regresión en estudios observatorios. Sin embargo, cuando sólo disponemos de datos históricos debemos prestar mucho más atención a las debilidades del modelo, a que variables pueden estar afectando aunque no las hayamos medido, y a la falta de certidumbre estadística cuantificable a la hora de predecir los valores de la variable dependiente. Y todo esto debe estar claramente detallado al exponer las conclusiones de nuestro análisis.

Regresión Múltiple y Evolución de Seis Sigma

La regresión Múltiple forma parte de la mayoría de los planes curriculares de Seis Sigma. En general estos métodos son explicados en la etapa A de análisis, cuando buscamos extraer variables independientes que afectan nuestras características críticas (CTQs: críticas para la calidad, CTCs: críticas para el costo, etc.)

También vuelve a aparecer el análisis de regresión lineal en la etapa de Mejora (fase I del DMAIC), cuando realizamos experimentos para validar la adecuación de las soluciones propuestas o realizar experimentos multifactoriales o de mezclas para determinar condiciones óptimas de operación.

¹⁵ Por ejemplo si recuperamos del SPAC En Línea todos los ensayos realizados en la Línea X durante esta semana, para estudiar que variables nos afectan en la Característica Crítica Y.

Informe Druida de Estadística y Calidad N° 10

Dado que estas técnicas son bastante avanzadas, se necesita práctica y experiencia para ir desarrollando el *know-how* necesario; nunca son suficientes las 15 slides que muestra el profesor y el experimento de la catapulta hecho en el curso de Seis Sigma; ni siquiera el primer modelo realizado con el proyecto inicial. Esta **experiencia acumulada en el contexto específico de la empresa** es la diferencia clave entre el rol de MBB (Master BlackBelt) y BB (Black Belt).

Estudios Observacionales/Experimentales y Evolución de Seis Sigma

Si nos restringimos al proceso DMAIC, creemos que no se presta suficiente atención a la distinción entre estudios observacionales y experimentales durante la capacitación de Seis Sigma. Esta distinción debería quedar muy clara al practicante al finalizar la segunda semana del ciclo de Black Belt, para no cometer errores de interpretación sobre datos históricos similares a los expuestos en el ejemplo del capítulo respectivo.

¿Qué pasa si miramos el proceso integral de despliegue de Seis Sigma en una compañía?

¿Qué tipo de estudio podemos realizar?

Claramente podemos observar la experiencia previa para buscar hipótesis causales que expliquen la realidad actual, los problemas que se experimentan y los resultados positivos. Sin embargo, dado que generalmente el entorno es **complejo**, nos será muy difícil determinar relaciones causales nítidas. En estas situaciones, sólo podremos utilizar nuestra capacidad de análisis para detectar patrones emergentes que nos ayuden a esbozar acciones correctivas o preventivas que alineen la situación a nuestras expectativas.

No podremos experimentar en el sentido estricto de la palabra, pero podremos aplicar medidas en entornos reducidos para testear la validez de nuestras observaciones. Estas pruebas no serán cuantificables estadísticamente, pero ratificarán o rectificarán nuestras suposiciones.
