

*Estimados,*

*comenzamos el 2010 con un breve boletín para no perder la costumbre.*

*Muchos de nosotros, ya sea por vocación, convicción, imposición o coerción, nos enfrentamos con información que debemos analizar estadísticamente. Una cosa es ver datos de manera superficial, y otra muy diferente observarlos tratando de determinar características salientes o relaciones de asociación o causalidad.*

*El analista de datos es un detective buscando los patrones ocultos en información recolectada, y como tal tiene que afrontar ciertos riesgos que pueden apartarlo del camino correcto llevándolo a conclusiones equivocadas.*

*Por esa razón, en este boletín se comenzará una serie de entregas con sugerencias y recomendaciones para los “detectives estadísticos”.*

*Les mandamos un gran saludo, un excelente 2010 y les recordamos (por 13ava. vez) que pueden sugerirnos temas o enviarnos ideas.*

*Hasta el informe Nro. 14!!*

*El equipo de Druida.*

*Frase del Boletín:*

***“Lo importante no es saber, sino tener el teléfono del que sabe”.***

*Les Luthiers*

|                                                                                   |                                                                                                                                         |
|-----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
|  | <b>Curso de Introducción al Diseño Experimental con SPAC FL</b>                                                                         |
|                                                                                   | <p>Organiza: <a href="#">Druida</a></p> <p>Fecha: <b>25 y 26 de febrero de 9:00 a 17:00 hs.</b></p> <p>Docente: <b>Daniel Firka</b></p> |

### Audiencia

Usuarios del Sistema SPAC y SPAC FL interesados en conocer los pasos de realización de un diseño de experimentos con la herramienta informática.

### Requisitos

- Conocimiento de conceptos estadísticos básicos: parámetros estadísticos, histogramas, gráficos de control, índices de Capacidad de Procesos.
- Poseer una notebook con SPAC FL instalado. Al menos una cada dos asistentes. De ser necesario, solicitar su instalación previa al curso, enviando un mail a [info@druida.biz](mailto:info@druida.biz)

### Objetivos

- Describir los pasos para la **planificación, ejecución y análisis** de experimentos en entornos industriales.
- Brindar un amplio **abanico de técnicas** de Diseño Experimental que permitan al participante seleccionar aquella más apropiada para problemas específicos.
- Conocer la aplicación de un DOE a través de la herramienta SPAC FL
- Permitir una alta **interacción** con los participantes creando un espacio de diálogo abierto.

### Sumario del Contenido

El curso se dará en dos jornadas intensivas, cubriendo los siguientes aspectos:

- Repaso y Actualización de Conceptos Estadísticos básicos.
- Planificación. Determinación de tamaños muestrales. Identificación de riesgos  $\alpha$  y  $\beta$
- Sugerencias para la ejecución de experimentos. Aleatorización. Tiempos y costos.
- Experimentos comparativos. Bloques.
- Experimentos Factoriales 2k y 2 k-p. Confusión de Factores.
- ANOVA. Verificación de supuestos y análisis de residuos.
- Diseño Experimental y Capacidad de Procesos.
- Herramientas gráficas para el análisis de datos.

### Disertante

**Daniel Firka** Ingeniero Industrial (ITBA), Magister en Ingeniería Biomédica (Universidad Favaloro), Lic. En Sociología (Univ. Del Salvador) Ingeniero Certificado en Calidad (CQE), Fiabilidad (CRE), Calidad de Software (CSQE) de la American Society for Quality (ASQ), CCT (Certified Calibration Technician/Metrology), CMQ/OE (Certified Manager of Quality/Organizational Excellence) (ASQ) Presidente de Druida. Miembro del Consejo Directivo del IAPC. Senior Member de ASQ.

**Precio Clientes Druida: \$490/asistente.**

**Pre Inscripción: [info@druida.biz](mailto:info@druida.biz)**

|  | Curso de Control Estadístico de Procesos                                                                                                                     |
|-----------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                   | <p>Organiza: <a href="#">Aliar - Gestión Alimentaria</a></p> <p>Fecha: <b>19 y 26 de marzo de 9:00 a 17:00 hs.</b></p> <p>Docente: <b>Javier Carrizo</b></p> |

**Destinado a:** personal de Gestión de Calidad; de Laboratorios, Líderes de Calidad, Supervisores, Ingenieros de Proceso, etc.

### Contenidos:

#### Jornada 1 - 19 de marzo:

- Principios del pensamiento estadístico.
- Conceptos estadísticos básicos.
- Interpretación y uso de Gráficos de Control (variables y atributos).
- Causas comunes y especiales de variación.
- Normalidad e Histogramas.
- Capacidad de Procesos (Indices Cp/Cpk y Pp/Ppk).
- Diagramas de Pareto.

#### Jornada 2 - 26 de marzo:

- Conceptos del Análisis Multivariado.
- Análisis de Regresión Lineal Simple y Múltiple. Supuestos.
- Técnicas de Pre-experimentación (Gráfico MultiVari).
- Introducción a la comparación de medias y ANOVA One Way.
- Métodos no paramétricos de Comparación y Bloques.
- Introducción a la Evaluación de Sistemas de Medición (R&R).

**Arancel: \$590 (las dos jornadas)**

**\$350 (solo una jornada).**

[Inscripción](#)

**Nota:** Se requiere el uso de una notebook o de al menos una cada dos asistentes, con SPAC FL instalado. Puede **solicitar una licencia gratuita temporal** a [info@druida.biz](mailto:info@druida.biz)

Más información en: <http://aliargestiona.com/>



## Sugerencias para Detectives Estadísticos (1° Entrega)

Autor: Daniel Firka

Dado que estás leyendo estos párrafos, presumo coincidirás en que la estadística es una herramienta poderosa para resolver problemas de la práctica industrial: podemos pensar que la estadística es el martillo que nos permite “dar en el clavo” hallando soluciones mediante el análisis riguroso de datos.

Pero cuidado! usar un martillo siempre implica riesgos:

- Riesgo 1: podemos martillarnos un dedo, recordando a todos los parientes del fabricante del martillo.
- Riesgo 2: podemos tratar de utilizar el martillo para desenroscar una tuerca (fin que no le corresponde, lo que hará muy difícil aprovecharlo... quizás terminaremos rompiendo la tuerca a martillazos).

Estos riesgos, llevados a nuestro campo del análisis de datos, se traducen en:

- Riesgo 1: extraer una conclusión incorrecta en base al análisis, gastando recursos y lastimando tanto las finanzas de la empresa como nuestra reputación.
- Riesgo 2: usar la herramienta estadística incorrecta para intentar resolver nuestro problema.

Comentaré algunas precauciones y recomendaciones que debe tomar todo analista cuando desea estudiar con rigor estadístico un problema determinado (material basado en los excelentes libros que se enumeran al final del artículo y mi propia elaboración).

### **Distinguir entre estudios observacionales y experimentales.**

Con la ubicuidad de poderosas herramientas informáticas, cada vez es más fácil abrir un set de datos históricos y empezar a clicar y desclicar, arrastrando y pegando hasta encontrar alguna palabra mágica como “p-Value significativo”. Podríamos llamar a este comportamiento el “síndrome del video-juego”, aunque a veces se conjuga con la “patología-de-mostrar-algo-para-que-el-proyecto-6-sigma-sea-aprobado”, y puede interactuar con “cuadro-de-angustia-por-demostrar-que-el-curso-estadístico-tomado-no-fue-en-vano”.

La primera distinción que debe hacer el analista al enfrentarse a un set de datos es sobre el origen de estos datos: ¿proviene de información histórica (estudio

---

observacional) o es el resultado de un experimento llevado a cabo sobre el proceso (estudio experimental)?

Cuando poseemos datos históricos tenemos que cuidarnos de tomar decisiones basadas en p-values, porque en estas situaciones generalmente no se cumplen los supuestos que dan validez a estas probabilidades (aleatorización, determinación de las condiciones ambientales de contorno, bloqueo si es necesario, replicas bajo condiciones similares, etc.). Todos los programas nos van a tirar alegremente los análisis y tablas ANOVA... pero esta alegría es muy ingenua, porque asume que los datos fueron recolectados siguiendo muchas precauciones que en la práctica no se dan.

En resumen, en estudios observacionales es más seguro utilizar métodos gráficos (diagramas de dispersión, multi-vari, etc.) en vez de los resultados digeridos que resultan de cálculos cuya validez es discutible.

Algunas de las bacterias nocivas que se pueden colar en nuestro estudio observacional y “arruinarnos el puchero” son:

- **Sesgo (*bias*) de Selección:** al elegir los datos, involuntariamente (o no) seleccionamos información que nos empuja hacia una u otra solución.
    - **Situación:** estoy investigando uno de nuestros proveedores; me entero que en los últimos meses la línea uno utilizó materia prima del proveedor que me interesa, mientras que la línea 2 utilizó materias primas de otros proveedores. Entonces recupero la información y comparo la performance del producto elaborado en Línea 1 respecto al elaborado en Línea 2.
    - **Ocurrencia de Sesgo:** resulta que la línea 1 trabaja con una máquina de fabricación más moderna, que incrementa mucho la performance del producto: algo que no tiene nada que ver con el proveedor pero me influye en mi conclusión.
    - **Moraleja:** en este caso el sesgo al seleccionar la fuente de información hará que mis conclusiones sobre el proveedor pueden ser inválidas porque los datos están contaminados con otros factores que afectan mi decisión.
  - **Sesgo (*bias*) de Información:** los datos medidos no reflejan la realidad por un problema del sistema de medición utilizado.
    - **Situación:** para investigar un defecto que está apareciendo y cuya causa desconocemos, tomamos los ensayos de la última semana y hacemos un pareto por envasadora, identificando la envasadora X que generó el mayor número de unidades defectuosas.
    - **Ocurrencia de Sesgo:** resulta los inspectores de planta ya tenían la sospecha sobre la envasadora X. Entonces, dado que el defecto no
-

tiene una definición operativa muy objetiva, los inspectores estaban más propensos a identificar la ocurrencia del defecto cuando el material venía en particular de esta envasadora X.

- **Moraleja:** en este caso el sesgo en la información hará que investiguemos erróneamente qué pasa con la envasadora X.
- **Confusión:** Una variable oculta que no medimos está actuando en nuestro proceso, afectando tanto las condiciones como los resultados que analizamos. Si sospechamos que alguna variable pueda estar afectando de esta manera nuestro proceso, la mejor alternativa es “estratificar” los datos, analizando separadamente los datos según los diferentes valores de la variable en cuestión.
  - **Situación:** Con datos del último semestre, encontramos una alta correlación entre la acidez de nuestro producto y la posterior “vida útil” del mismo hasta su fecha de vencimiento.
  - **Ocurrencia de Confusión:** resulta que un ingrediente utilizado en la preparación tiene como efecto incrementar la acidez, y simultáneamente incrementar la vida útil del producto.
  - **Moraleja:** como no estamos midiendo la proporción del ingrediente en el producto, podemos incorrectamente interpretar una asociación entre acidez y vida útil.

En fin, en SPAC FL quizás sea provechoso indicar cuando un data set es “experimental” y cuando es “histórico/observacional”, y en este segundo caso restringir los resultados analíticos, focalizándose mucho más en la información gráfica... ¿Opiniones?

## Cuidado con los modelos lineales

*Siempre trata de interpretar el modelo físico que está detrás de los datos que analizas.*

A pesar de su tenor dogmático, esta frase no fue copiada del sermón de un pastor evangélico trasnochado de un canal de televisión... es un concepto muy importante que se puede perder de vista cuando nos concentramos sólo en la salida del software y su representación matemática.


Generalmente se busca primero la adecuación con un modelo lineal, de la forma:

$$y=a+b_1x_1+b_2x_2+b_3x_3+...+\varepsilon$$

---

Usemos un ejemplo para aclarar que significa cada uno de los componentes de esta ecuación.

Supongamos que trabajamos en la industria automotriz, y uno de nuestros vehículos tiene un problema en el pedal de aceleración. En algunos casos cuando presionamos el pedal, este se queda trabado al fondo, generando un “efecto Fangio” que nos acelera el vehículo descontroladamente<sup>1</sup>



Luego de una investigación determinamos que el problema se ocasiona cuando una variable que podemos medir, llamada “adhesividad”, supera cierto valor crítico y hace que el pedal permanezca pegado al fondo con la subsecuente aceleración descontrolada.

En nuestro modelo, la “y” o variable de respuesta es la adhesividad, e intentamos investigar cuáles son los factores o “x” que afectan esta adhesividad.

Luego de un ceñudo análisis – en paralelo a un millón más de autos llamados a revisión y una explosión mediática-, utilizando herramientas como diagrama causa-efecto, paretos, etc. Encontramos tres factores que nos parece afectan la adhesividad:

- 1- Viscosidad del fluido del pedal.
- 2- Angulo final que alcanza el pedal
- 3- Presión a la cual comienza a moverse el pedal

Entonces aquí tenemos las tres X candidatas en nuestro modelo, que ahora podemos escribir como:

$$y(\text{Adhesividad}) = a + b_1x_1(\text{Visc}) + b_2x_2(\text{Angulo}) + b_3x_3(\text{Presión}) + \varepsilon$$

Es decir, la adhesividad tiene un valor base (a) y varia en proporción a los valores de nuestras tres variables X. En resumen, llamamos modelo a la ecuación **sin** el componente final  $\varepsilon$ .

---

<sup>1</sup> ¿tendría que decir “Todo parecido con la realidad es pura coincidencia”? Este ejemplo está inspirado en la crisis que está atravesando en estos momentos la empresa Toyota a partir de un problema similar (información [aquí en inglés](#) y [aquí en español](#))

¿Son estas tres X los únicos factores que influyen en la adhesividad?... NO! eso solo pasa en las películas o en los cursos berretas de estadística!

Para tomar en cuenta todos los otros efectos (que consideramos pequeños y no tan importantes como nuestras tres X) usamos el último factor  $\varepsilon$ , que representa “la resaca” de efectos que no quiero estudiar porque sería “gastar pólvora en chimango”<sup>2</sup>.

¿Y cómo medimos esta resaca? Simplemente restando a cada observación lo que nuestro modelo indicaría:

$$\varepsilon_i = y_i - [\text{Predicción de mi Modelo}]$$

Técnicamente cada una de estas diferencias entre lo que “predice mi modelo” y lo que “mide mi instrumento” se denomina “residuo”. Cuanto más pequeños estos residuos, mejor me explica el modelo el comportamiento de la variable Y en cuestión.

Si estos residuos resultan muy grandes, pueden pasar diferentes cosas:

- 1- Que nos estemos **olvidando** uno o más factores importantes.
- 2- Que la variable Y tenga una **relación no lineal de orden superior**.  
Por ejemplo, que la verdadera relación sea:

$$(\text{Adhesividad}) = a + b_1(\text{Visc})^4 + b_2(\text{Angulo}) + b_3(\text{Presión})$$

Por ejemplo, la relación podría graficarse así:



<sup>2</sup> Para los que no conocen el dicho, [aquí](#) la explicación.



Mirando este gráfico. ¿Podés identificar el tamaño del tercer residuo?

RESPUESTA: trazamos una línea vertical uniendo el tercer punto con la línea de nuestro modelo: el tamaño de este segmento es la magnitud del tercer residuo.

Vemos que los residuos son mayores que si usamos una curva (lo que significa elevar el factor a un cierto exponente)

### 3- Que la variable Y tenga una **relación no lineal por interacción entre factores**.

Por ejemplo, que la verdadera relación sea:


$$(Adhesividad) = a + b_1(Visc)(Angulo) + b_3(Presión)$$

El hecho que dos factores se multipliquen entre sí indica el fenómeno llamado interacción: ¿Qué significa? Simplemente que el efecto de la viscosidad en la adhesividad depende de cuál es el valor del ángulo (o viceversa).

Cuando **NO HAY interacción**, podemos olvidarnos de todos los demás factores menos uno, y decir por ejemplo: subo dos unidades en la viscosidad, y esto implica subir en 4 unidades la adhesividad.

Cuando **HAY interacción**, si subo dos unidades en la viscosidad, cuánto va a subir la adhesividad dependerá del ángulo. Moraleja: no puedo considerar los factores aislados, porque “interactúan”.

Gráficamente:



Mirando este gráfico se nota la acción de la viscosidad a ángulos pequeños (en ese caso a mayor viscosidad, menor adhesividad), y lo diferente que resulta su acción con ángulos grandes (mayor viscosidad incrementa la adhesividad).

Volviendo a nuestro dogma inicial. Siempre es importante buscar el significado físico del modelo, más allá de la relación matemática que encontremos. Nos debemos cuestionar: ¿por qué la viscosidad se comporta diferente en ángulos distintos?, o ¿qué está actuando para que este factor aparezca en el modelo? Si no nos hacemos estas preguntas, podemos caer en una patología que consiste en seguir ciegamente el modelo porque se adecúa muy bien, aunque la relación es ilógica y solo se debe al ruido o a otro factor oculto... podríamos llamar a esta patología “R-cuadratitis” por su énfasis a mirar sólo el valor de la métrica R-cuadrado que nos mide la adecuación del modelo elegido.

Pregunta: hasta ahora ¿tuvimos que hablar en algún momento de “normalidad”, “curva normal”, “gauss y su pandilla”, o términos semejantes?

La respuesta a tan complejo interrogante es no.

Moraleja: nada nos impide hacer gráficos y estudiar la magnitud de los residuos y la adecuación gráfica de nuestro modelo. Las suposiciones de normalidad y otras solo aparecen un poco más tarde...ahora.

Veamos dos preguntas que nos pueden surgir en este momento:

- 1) Dijimos que si los residuos son pequeños, esto es bueno porque significa que nuestro modelo explica bastante a nuestra variable Y. Sin embargo, en la realidad siempre habrá residuos... ¿Cómo puedo medir si un modelo es bueno respecto a otro, siendo que en **ambos** hay una cierta variación residual y la diferencia podría deberse quizás solo al ruido o factores aleatorios?

En nuestro ejemplo, si yo considero la Adhesividad como :

$$y(\text{Adhesividad}) = a + \varepsilon$$

Es decir, que es un valor constante más cierto ruido, voy a tener una serie de residuos. Llamemos a esto el Modelo REDUCIDO. Por otro lado, si considero la siguiente ecuación:

$$y(\text{Adhesividad}) = a + b_1x_1(\text{Visc}) + b_2x_2(\text{Angulo}) + b_3x_3(\text{Presión}) + \varepsilon$$

Aquí obtendré otro set de residuos. Llamemos a esta ecuación el Modelo AMPLIADO. Mi pregunta será: ¿hasta dónde el cambio en los residuos me permite decidirme por el modelo AMPLIADO porque me explica mucho más la

---



variación en la variable Y que el modelo reducido? Para responder a esta pregunta tenemos que pasar al mundo de los p-Values y verificar que se cumplen ciertos supuestos, entre ellos la normalidad de los residuos.

- 2) La segunda pregunta que podemos hacer es sobre los coeficientes  $a$ ,  $b_1$ ,  $b_2$ , etc. Nos gustaría saber en base a los datos que observamos, cuáles serían los valores razonables para estos coeficientes o que rango de valores podemos asumir con tranquilidad para estos valores. Esta es otra respuesta que requiere ciertas suposiciones estadísticas sobre el modelo y los residuos.

Aquí aparece otro error común: tratar de analizar la normalidad de la variable de respuesta. Cuando analizamos datos de un modelo, por ejemplo al hacer una regresión **no es necesario** chequear la normalidad de la variable de respuesta (Y), sino los **residuos** del modelo, es decir, la diferencia entre la variable Y observada, y la que nuestro modelo matemático sugiere.

Un modelo puede ser usado de tres modos:

- 1) **Buscando lograr un buen ajuste con los datos.** Es el menos útil pero el más frecuentemente encontrado (un test de bondad de ajuste trabaja en este plano).  
En nuestro ejemplo esto sería el interés por entender la relación funcional entre la adhesividad y los otros factores, tratando de buscar la mayor cantidad de factores hasta obtener un ajuste óptimo.
- 2) **Predecir futuras observaciones** (modelo de predicción o pronóstico)  
Por ejemplo una vez descubierto el modelo, usaríamos los datos históricos que tenemos de los tres factores (viscosidad, ángulo, presión) para identificar los lotes de vehículos que debemos ubicar y traer para su revisión en la planta, porque su adhesividad puede originar un problema.
- 3) **Revelar características para controlar la situación descripta**, como un modelo estructural. Trataríamos aquí de definir los valores óptimos de las tres variables X para que la adhesividad se comporte adecuadamente.

Desde el punto de vista práctico lo que interesan son los dos últimos puntos, sin embargo (Wilkinson, 1999): muchos investigadores que usan métodos estadísticos prestan más atención a la bondad de ajuste que al significado del modelo... ¿de qué lado de la vereda te encontrás vos?

Como último comentario para aquellos que hayan llegado hasta aquí: en nuestros análisis siempre debemos usar el método de la navaja de Ockham: entre

---



una colección de modelos posibles, el **modelo preferido** es el más simple que brinda la información necesaria.

Y entre los artículos del boletín, es mejor el que explique más claramente el concepto con el menor gasto de tinta digital. Esperemos que la navaja de Ockham nos haya acompañado hoy, y hasta la próxima.

---

## Bibliografía

van Belle, G.(2002): Statistical Rules of Thumb. Wiley, NY

Jepsen, P. et al (2004): "Interpretation of observational studies". *Heart*. August: 90(8): 956-960

Montgomery, D.(2006): Design and Analysis of Experiments. 6ta. Edición. Wiley.

Neter, J. & Wasserman, W (1974): Applied Linear Statistical Models, Irwin. US

---