

Estimados,

esperamos que no nos hayan olvidado, pedimos disculpas por el tiempo desde el último boletín.

Como comentábamos en el boletín N° 13, muchos de nosotros, ya sea por vocación, convicción, imposición o coerción, nos enfrentamos con información que debemos analizar estadísticamente. Una cosa es ver datos de manera superficial, y otra muy diferente observarlos tratando de determinar características salientes o relaciones de asociación o causalidad.

El analista de datos es un detective buscando los patrones ocultos en información recolectada, y como tal tiene que afrontar ciertos riesgos que pueden apartarlo del camino correcto llevándolo a conclusiones equivocadas.

Para aquellos “detectives estadísticos” que han tenido la suerte de toparse con la herramienta llamada Diseño de Experimentos (DOE), en este boletín describimos una serie de aspectos a considerar durante el diseño, implantación y análisis de experimentos.

Lograr descomponer las fuentes de variación de un proceso identificando aquellas más importantes, es sin dudas uno de los primeros pasos que debe buscar quien trabaje en la mejora continua. El gráfico multi-vari que describiremos en el segundo artículo, es una herramienta con gran potencial para alcanzar ese objetivo, por ser sencillo de confeccionar e interpretar y porque evita calcular estadísticos complejos. Se convierte entonces en un aliado indiscutido como técnica de pre-experimentación durante el análisis exploratorio, pero también como complemento gráfico en estudios confirmatorios tales como el diseño experimental.

Les mandamos un gran saludo y ya no les recordamos más que pueden sugerirnos temas o enviarnos ideas (esto suena a la famosa paradoja lógica planteada hace más de dos milenios por Eubulides de Mileto, que es la frase de nuestro boletín).

Hasta el informe Nro. 15 !!!

El equipo de Druida.

Frase del Boletín:

“Esta sentencia es falsa”.

Eubulides de Mileto



	Conferencia Gratuita
	“El concepto de Calidad, desde la percepción subjetiva a las métricas objetivas”
Organiza: Instituto Argentino para la Calidad	
Fecha: 18 de agosto de 2011 - 18:00 a 20:30 hrs.	
Disertantes: Fabián Perez (IAPC/InfoTools) Daniel Firka (IAPC/Druida)	

Descripción

La Calidad como concepto tiene facetas subjetivas: la idea sobre nuestro producto o servicio en la mente del cliente o consumidor. Esta subjetividad no sólo se aplica en productos de consumo masivo, sino en toda relación cliente-proveedor.

Para poder mejorar nuestros procesos y la ubicación de nuestros productos en la “imagen mental” de los clientes, estos atributos subjetivos deben transformarse de alguna manera en variables que podamos medir cuantitativamente; aquí entran los métodos estadísticos y las técnicas de traducción de atributos subjetivos a métricas objetivas.

En esta charla atravesaremos ambas dimensiones, comentando las técnicas utilizadas para “bucear” en la mente de los clientes, y las técnicas estadísticas con que podemos traducir estos atributos en factores medibles dentro de la empresa.

Disertantes

Fabián Perez Lic. Sociología (Univ. Salvador), Dr. Psicología Social (Univ. Kennedy) Director Regional para latinoamerica de Infotools.

Daniel Firka Ingeniero Industrial (ITBA), Magister en Ingeniería Biomédica (Universidad Favaloro), Lic. En Sociología (Univ. Del Salvador) Ingeniero Certificado en Calidad (CQE), Fiabilidad (CRE), Calidad de Software (CSQE) de la American Society for Quality (ASQ), CCT (Certified Calibration Technician/Metrology), CMQ/OE (Certified Manager of Quality/Organizational Excellence) (ASQ) CEO de Druida. Miembro del Consejo Directivo del IAPC. Senior Member de ASQ.

La conferencia será gratuita, pero siguiendo la misión del IAPC de contribuir a la Calidad de Vida, aquellos que lo deseen pueden ayudar con una contribución voluntaria, cuyo monto se distribuirá de la siguiente manera:

- **70% para una institución de caridad (Ejército de Salvación Argentina)**
- **30% para el IAPC, para fomentar futuras actividades de este tipo.**

La información para registrarse estará próximamente disponible en www.iapc.org.ar
Consultas a info@iapc.org.ar

El lugar (a confirmar) será el auditorio de la Universidad Tecnológica Nacional.



	Curso de Control Estadístico de Procesos
	Organiza: Aliar - Gestión Alimentaria Fecha: 26 de agosto de 9:30 a 17:00 hs. Docente: Javier Carrizo (Druida)

Destinado a: Analistas de laboratorio, Jefes en gestión de calidad, Supervisores e Ingenieros de proceso, líderes de línea, etc.

Introducción: El uso apropiado de los gráficos de control nos permite conocer la dispersión de los procesos productivos y colaboran en su reducción. A su vez, un correcto análisis de la capacidad o performance de los procesos nos ayuda a descubrir la aptitud de los mismos, para cumplir o determinar sus especificaciones.

Objetivos: Incorporar las herramientas básicas del control estadístico y capacidad de procesos con ejemplos de la industria alimentaria.

Contenidos:

- Principios del pensamiento estadístico.
- Conceptos estadísticos básicos.
- Interpretación y uso de Gráficos de Control (variables y atributos).
- Causas comunes y especiales de variación.
- Normalidad e Histogramas.
- Capacidad de Procesos (Indices Cp/Cpk y Pp/Ppk).

Requisitos: Se requiere el uso de una notebook o de al menos una cada dos asistentes, con MS Excel instalado.

Lugar: Thames 2293, Ciudad autónoma de Buenos Aires.

Arancel: \$630.- Más información e Inscripción en: <http://aliargestiona.com/>

Sugerencias para Detectives Estadísticos (2° Entrega)


Autor: Daniel Firka

El diseño experimental (comúnmente llamado DOE por sus siglas en inglés) es una herramienta muy poderosa para comprender y mejorar procesos, tanto productivos como transaccionales. Sin embargo y lamentablemente, su uso es bastante limitado en la práctica cotidiana de las organizaciones.

Este artículo contiene una introducción sobre experimentación y una serie de aspectos que sumarizan un trabajo publicado en el [TQM Journal](#). Una versión en español fue expuesta en el Encuentro 2010 de mejora continua de SAMECO, organización que gentilmente ha permitido al IAPC postear en su sitio la versión española del trabajo, disponible en la página del IAPC (www.iapc.org.ar), en la sección de novedades.

El diseño de experimentos es el estudio a través de uno o más ensayos del efecto de múltiples variables de entrada (X's) sobre una o más variables de respuesta (Y's). Recordemos el artículo del boletín pasado donde prevenimos sobre la confusión entre estudios experimentales y observacionales. Aquí estamos realmente manipulando el proceso para extraer información útil.

El proceso de experimentación sigue el método científico, consistente en un círculo iterativo, descrito por Shewhart en su libro "Statistical Method from the Viewpoint of Quality Control":



En general al inicio tenemos una gran cantidad de variables candidatas que afectan a nuestro proceso, y nuestra primera hipótesis se refiere al grado de influencia de estas variables (círculo superior). Realizamos un experimento de cribado variando simultáneamente estas variables candidatas y midiendo su

influencia sobre nuestra respuesta (circulo inferior derecho). Contrastamos luego el impacto de cada variable para descartar aquellas que son irrelevantes (circulo inferior izquierdo), y con esto cerramos el primer ciclo de investigación. El tipo de experimento usado en esta etapa generalmente corresponde a diseños fraccionales factoriales o esquemas de vectores ortogonales de Taguchi.

En muchos casos nos interesará investigar en mayor detalle las variables que resultaron importantes, iniciando un nuevo ciclo experimental donde nuestra hipótesis se referirá al modo en que varía la respuesta ante cambios de las variables críticas. En este caso plantearemos un modelo en forma matemática, por ejemplo:

“Considero que la variable Y varía de manera tal que hay una influencia lineal y cuadrática de las distintas X cuando X1 está entre A y B, X2 está entre C y D, etc.”

(notemos que además de la relación matemática establecemos también los intervalos de validez de las variables X, para no equivocarnos luego y pensar que nuestros resultados son válidos para cualquier valor de las X)

Así comenzamos la segunda iteración experimental, tomando datos y viendo la consistencia con nuestra hipótesis, identificando así la probable ecuación matemática que modela el comportamiento de nuestro proceso. Aquí se cierra el segundo círculo de investigación. El tipo de experimento usado aquí corresponde a los modelos de superficies de respuesta desarrollados por George Box.

Puede suceder que entonces nos damos cuenta que la variable Y mejora en un determinado sentido, por ejemplo al subir X1, y nos interesa ver si podemos mejorar aún más la respuesta. Entonces podemos “movernos” en los valores de X1 y analizar la respuesta Y en otro entorno que sigue la dirección de mejora. Si en el experimento previo X1 estaba entre 10 y 20, ahora estudiaremos que pasa cuando X1 varía entre 15 y 25. Esto da paso a un tercer ciclo experimental.

La validez de nuestros resultados y las conclusiones que saquemos no están determinadas por argumentos probabilísticos, sino por la verificación en la práctica de nuestras hipótesis.

A pesar del alto potencial de DOE para descubrir causas raíces de problemas y optimizar procesos, hay una serie de aspectos que se deben tener en cuenta para no equivocarse en la planificación, ejecución o análisis de los experimentos.

Una forma de agrupar estos aspectos es de acuerdo a la dimensión que abarcan:

- Dimensión Estadística: relacionada con los supuestos estadísticos y los métodos matemáticos que brindan validez a las técnicas DOE.
 - Dimensión Técnica/Metodológica: relacionada con la forma de llevar a cabo los experimentos para sacar el máximo provecho al DOE
 - Dimensión Sociológica/Gerencial: relacionada con la organización y administración del uso de la herramienta en el contexto organizativo.
-

Expondremos una selección de estos aspectos a considerar, orientándolos a una audiencia general sin pretender conocimientos específicos de estadística, simplificando así algunos de estos ítems cuya descripción detallada se encuentra en los artículos referidos.

Dimensión Estadística

A pesar de la existencia de numerosos paquetes informáticos que permiten evitar errores en los cálculos, existen otros problemas que pueden afectar negativamente los análisis en DOE.

No identificar los riesgos alfa y beta en la etapa de diseño para calcular el número de replicas

En el contexto de DOE, el riesgo alfa se relaciona con la **posibilidad de tener una falsa alarma**, es decir identificar un factor o variable como importante cuando en realidad no lo es.

Por ejemplo, supongamos un experimento donde mi variable de respuesta, que le interesa a mi cliente, es el **contenido neto del frasco**. Queremos diseñar un experimento porque pensamos que este contenido neto está influenciado por 3 variables:

- Velocidad de la máquina,
- Presión del líquido y
- Temperatura.

Al hacer el experimento, nosotros partiremos de las siguientes hipótesis:

- 1) La Velocidad de la máquina **NO influye** en el contenido neto.
- 2) La Presión del Líquido **NO influye** en el contenido neto.
- 3) La temperatura **NO influye** en el contenido neto.

NOTA: para simplificar, en este ejemplo no analizo las llamadas interacciones, que dejo para un próximo artículo - aunque quienes la curiosidad les impida esperar (teniendo en cuenta nuestra vagancia a la hora de enviar boletines), pueden consultar referencias como el libro de Montgomery o en la bibliografía.

En este contexto, el **riesgo alfa** me habla de tener una falsa alarma, es decir, por ejemplo, que en base a los datos medidos en el experimento, el análisis me indique que la velocidad de la maquina **SI influye** en el contenido neto, pero en la realidad esto no pasa, la velocidad no tiene una influencia importante en el llenado. El resultado obtenido fue una casualidad debida al azar y la variabilidad propia del contenido neto. Recordemos que no estamos censando el 100% del proceso, sino tomando muestras, o sea que existe siempre incertidumbre y riesgo.

Por supuesto, uno querría tener el menor riesgo alfa posible, pero aquí entramos en el **balance** de siempre: cuanto menos riesgo queremos asumir, más

veces tendremos que correr el experimento (es decir, tendremos que hacer más **réplicas**), y más caro nos costará y más tiempo nos llevará. Aquí el analista debe decidir, con los recursos que cuenta y con un análisis práctico, un riesgo razonable. En la práctica generalmente se establece un 5%, lo que se denomina **también Nivel de Significación**. La contrapartida del riesgo se llama Nivel de Confianza, que en este caso es $100-5 = 95\%$.

En resumen, cuanto más bajo es el riesgo alfa, más tranquilos estamos en que si el análisis me dice que un factor es importante, realmente lo sea y no haya sido resultado del azar (también llamado Ley de Murphy).

Por otro lado, el **riesgo beta** se refiere a perder señales, no detectando factores relevantes. En nuestro ejemplo, si tengo un alto riesgo beta, lo que puede pasar es que al analizar los datos del experimento concluya que la presión del líquido **NO influye** en el contenido neto, pero en realidad sí tiene influencia.

Fijémonos que el riesgo beta es lo opuesto del alfa. **Con el alfa arriesgamos considerar importante algo que no lo es (falsa alarma), con el beta arriesgamos considerar no importante algo que lo es (señal perdida)**

Definir los riesgos alfa y beta de antemano permite calcular el número de réplicas y define la sensibilidad del diseño, si se realizan muy pocas corridas experimentales, habrá mucha incertidumbre al identificar factores importantes, por otro lado excesivas corridas no sólo incurren en un costo muy alto en tiempo y dinero, sino también hacen el experimento demasiado sensible a factores poco relevantes.

Un error común es creer que cuantos más datos se incorporan en el análisis, mejor. Por ejemplo al comparar dos niveles de un factor (como velocidad de la máquina) cuyo efecto es muy leve, el analista toma datos de un PLC para todo un mes de producción en ambos factores, haciendo un test t con 1000 unidades en cada condición, resultando una diferencia estadísticamente significativa. El siguiente error del analista es pensar “este factor es importante porque resultó significativo”.

Ausencia de análisis de patrones en los residuos



Los residuos representan la **variación no explicada** mediante nuestro modelo experimental. Este nombre es un poco peyorativo; y en realidad los residuos son una fuente muy valiosa de información extra-experimental.


En los modelos más usados, el criterio para identificar factores relevantes **exige** que los residuos tengan un cierto comportamiento, por ejemplo que su histograma se asemeje a una distribución normal, que su variabilidad sea constante, etc.

Con el interés en identificar los factores más importantes es fácil olvidar la verificación del comportamiento de los residuos, lo que puede invalidar las conclusiones sobre significatividad estadística.



No identificar datos muy alejados (*outliers*)

Los datos muy alejados o *outliers* son una fuente muy rica de información sobre el proceso, generalmente representan “causas especiales” señalando oportunidades para profundizar nuestro conocimiento.



Cuando el analista se encuentra con un dato muy alejado, la reacción no debe ser de frustración ante una corrida experimental perdida, sino de curiosidad y expectativa para hallar la causa raíz de la discrepancia.

Dimensión Técnica / Metodológica

Tomar datos históricos (estudio observacional) y procesarlos como si fueran resultado de un experimento (estudio experimental)

No puedo evitar nombrar este problema que ya toqué en oportunidad del boleto Nro. 13.

La facilidad con que los modernos paquetes informáticos pueden digerir información y analizar cualquier set de datos puede tentar al analista a procesar incorrectamente un set de datos histórico como si se tratara del resultado de un experimento. Esto generalmente lleva a conclusiones erróneas, dado que la falta de control involucra mucha dispersión no explicada y fluctuaciones del proceso que luego incrementan la magnitud del ruido subyacente, disminuyendo el poder de la herramienta para identificar los factores de alto impacto.

Muchas veces los estudios observacionales son puramente exploratorios y se bucea en los datos tratando de identificar factores de interés. Esto es válido siempre y cuando se entiendan los riesgos de trabajar con datos del proceso en estado “salvaje”. Por ejemplo, puede haber variables no medidas que generan efectos en variables que sí medimos y que incorrectamente confundimos como causales.



Observación




Experimentación

Como vemos en la figura, altamente técnica, la observación nos permite observar el “hábitat natural” del proceso, y podemos analizar muchas más variables de entorno. La experimentación implica reducir la complejidad y concentrarnos en pocas variables de interés.

No atravesar etapas rigurosas de Planificación y Diseño, pasar directamente a la experimentación

Muchas veces se olvida definir claramente el problema que se quiere atacar; dado que esta tarea previa requiere la coordinación de esfuerzos entre todos los involucrados en el problema, operativamente resulta más fácil definir los factores e informar que se va a realizar el experimento, que pasar por las etapas previas de definir la variable de respuesta, los factores y sus niveles y el tipo de problema a resolver. Este riesgo de aislacionismo es mayor cuando el practicante no tiene recursos de coaching o acompañamiento disponible y está presionado a mostrar resultados concretos en cortos plazos.

No asegurar que las variables no incluidas en el experimento se mantienen controladas durante la ejecución del experimento



La ejecución del experimento puede considerarse una “mesa de operaciones” donde —a excepción de los factores que estamos estudiando— se debe buscar un estado “ceteris paribus”, que es artificial del punto de vista práctico pero es funcional a nuestro objetivo de identificar el efecto de factores.

Es recomendable que el analista esté presente durante la ejecución de las corridas experimentales, y preste especial atención al control de las condiciones ambientales.

Dimensión Sociológica/Gerencial

Gastar excesivos recursos en el primer set de experimentos.

El entusiasmo inicial en el uso de DOE puede llevar a planificar experimentos con gran cantidad de factores y niveles. En los estadios tempranos del uso de DOE se tiene poca práctica en la identificación y determinación de niveles de factores, esta situación es problemática porque:

- la falta de experiencia puede generar problemas en la forma de planificar, llevar a cabo o interpretar los resultados.
- DOE en un contexto industrial o transaccional es siempre un proceso iterativo y secuencial, donde cada sucesivo experimento va disparando nuevas preguntas y respondiendo otras, hasta que el equipo determina que el conocimiento adquirido permite alcanzar un nivel aceptable de excelencia en el proceso involucrado.

Aplicar DOE por razones ajenas a la mejora del proceso o producto

La currícula estándar de black-belts en la metodología Seis Sigma tiene generalmente una descripción de métodos de diseño experimental, que en muchos casos se da fugazmente y en conjunto con muchas otras herramientas en el marco de la semana 2 o 3 de entrenamiento, para ser utilizado en las fases de análisis o mejora del esquema DMAIC. Esta situación a pesar de ser beneficiosa por enseñar la herramienta, conlleva el peligro de intentar aplicarlo sólo para atravesar satisfactoriamente los “peajes” establecidos para el proyecto de mejora.

En otros casos la motivación para el DOE es jugar con el software recientemente adquirido. El diseño experimental y el software asociado siempre es un medio para lograr el fin de optimizar procesos, nunca un fin en sí mismo.

Una persona del área de Investigación y Desarrollo puede recibir una capacitación intensiva en DOE y luego tener una presión para mostrar rápidamente los resultados prácticos. El objetivo se convierte en demostrar lo aprendido más que optimizar un proceso.

No comunicar claramente los resultados del experimento a las partes interesadas.

Siempre tener en cuenta que parte de la audiencia que leerá las conclusiones del experimento no tiene el nivel de conocimientos para interpretar estadísticamente los datos. Esto exige basarse principalmente en gráficos de efectos e interacciones, explicando las razones por las cuales se llegaron a las conclusiones minimizando la jerga estadística y concentrándose en la relevancia práctica y la claridad conceptual.



Bibliografía

- Bisgaard, S (2008): "Must a Process be in Statistical Control before Conducting Designed Experiments?", *Quality Engineering*, ASQ, pp 143 - 176, Vol 20, Nr2
 - Box, G., Hunter & Hunter (2005): *Statistics for Experimenters: Design, Innovation, and Discovery*. (Wiley-Interscience; 2 edition. USA)
 - Corwin, Al (1999): "How to Institute DOE in Your Company" available at http://www.strategy4doe.com/Newsletters/BackIssues/Vol2/September_1999.htm
 - Costa, N (2006): "Guidelines to help practitioners of design of experiments". *The TQM Magazine*. Volume 18 Issue 4 pp. 386 – 399
 - Diamond (1981): *Practical Experimental Design*. (Lifetime learning Publications. USA)
 - Good, P. and Hardin, J. (2003): *Common Errors in Statistics and how to avoid them*. (Wiley. USA).
 - Hybarger, Jeff (2007): "The ten most common designed experiment errors" available at <http://www.dpnCanada.com/images/stories/2007/June/PDFs/dpn%20june%2007-26.pdf>
 - Ilzarbe, L (2008): "Practical applications of design of experiments in the field of engineering: a bibliographical review". *Quality and Reliability Engineering International*. Volume 24 Issue 4, pp 417 – 428
 - Kowalski, S. & Potcner, K (2004): "How to Analyze a Split-Plot Experiment" *Quality Progress*, Vol. 37, No. 12, December 2004, pp. 67-74
 - Lindsey and Lambert (1998): "On the appropriateness of marginal Models For Repeated Measurements in Clinical Trials", *Statistics in Medicine* 17, pp. 447-469
 - Montgomery (2008): *Design and Analysis of Experiments*. (Wiley. USA)
 - Novig, Peter (undated): "Warning Signs in Experimental Design and Interpretation" available at <http://norvig.com/experiment-design.html>
 - Tanco, E et al (2008): "How is experimentation carried out by companies? A survey of three European regions". *Quality and Reliability Engineering International*. Volume 24 Issue 8, pp 973 – 981
 - Van Belle, G (2002): *Statistical Rules of Thumb*. (Wiley Inter Science. USA)
 - Wheeler, Donald J. (1990). *Practical Experimental Design*. (SPC Press. Tennessee, USA)
 - Wheeler, Donald J. (2004). *The Six Sigma Practitioner's Guide to Data Analysis*. (SPC Press. Tennessee, USA)
 - Wu, J, Hamada, M (2000): *Experiments: Planning, Analysis, and Parameter Design Optimization*. (Wiley-Interscience. USA)
-

Gráfico Multi-Vari

Autor: Javier Carrizo

Introducción

En el Informe Druida N°11 comenté acerca de la obra que Charles Minard realizó en 1869¹, el que fue considerado el mejor gráfico estadístico de la historia, por su capacidad para resumir una gran cantidad de variables en un mismo gráfico.

Ya en el siglo XX, a finales de la década del 40, **Leonard Seder inventó la técnica multi-vari** y la desarrolló en un artículo llamado "Diagnosis with Diagrams"² publicado en la edición Industrial Quality Control de la ASQC (actual ASQ³).

Seder era un defensor acérrimo del análisis gráfico debido al poder de resumen que tiene una presentación gráfica eficaz y consideraba que, dentro de lo posible, se deberían usar gráficos en lugar de estadísticas analíticas. En sus propias palabras -"**Gran parte del éxito de las simples técnicas de control estadístico de la calidad, debe atribuirse a la fortaleza y concisión de la presentación gráfica**".

Según Leonard **el gráfico multi-vari permite desagregar la variación de un determinado proceso en sus diferentes fuentes** y la consideró una herramienta de diagnóstico similar a las usadas para el diagnóstico médico como las radiografías o los electrocardiogramas.

Por su parte, Dorian Shainin, colega y amigo de Leonard Seder, sostenía que el principio de Pareto⁴ popularizado por Joseph Juran, podía aplicarse para explicar las variaciones de un proceso, es decir, consideró **que pueden identificarse algunas pocas fuentes importantes que expliquen gran parte de la variación, mientras que el resto de las fuentes pueden considerarse triviales**. A la fuente o causa dominante de variación la denominó **Red X (X Roja)**.

Fue probablemente un cambio de paradigma para la época la propuesta de Shainin, ya que una vez enfocado en la búsqueda de la Red X, sin dudas **se simplificaba el problema al poder establecer un objetivo concreto**. Si bien debe reconocerse que hay muchas más causas potenciales de variación, el hecho de **encontrar y controlar la principal causa raíz, sin dudas producirá una importante mejora y reducción de la variación total del proceso**.

¹ Carte figurative des pertes successives en hommes de l'Armée Française dans la campagne de Russie 1812.

² Apareció en dos partes, en las ediciones de enero y marzo de 1950.

³ American Society for Quality


⁴ En los 40's Joseph Juran acuñó y popularizó la noción de "los pocos vitales y los muchos triviales", también conocido como "el Principio de Pareto", reconociendo el impacto desigual de los problemas en el desempeño de negocios, siendo el mismo fenómeno que Wilfredo Pareto había observado con respecto a la distribución de la riqueza.

Shainin, demostró que **la causa puede existir como una interacción entre variables independientes**, por lo que encontró en la **gráfica multi-vari** que diseñó su amigo Seder **una herramienta simple y poderosa para detectar la Red X**, es decir, encontrar rápidamente la causa raíz.


El caso del torno Incapaz!

Veamos una adaptación resumida de un ejemplo publicado por Shainin en 1966⁵, al que llamó “El caso del torno incapaz”.

Una de las piezas claves de los motores a reacción, es el eje del rotor. **El diámetro del eje es una variable de suma importancia** para el correcto funcionamiento del motor.



Un estudio realizado por el fabricante determinó que **el proceso no era capaz** de cumplir con las especificaciones exigidas $0.25'' \pm 0.001''$.



Un grupo de expertos examinó el problema y concluyó que el torno era viejo y estaba muy usado, por lo cual debería ser reemplazado. La gerencia no convencida con el estudio contrata los servicios de Dorian para que realice una investigación.

⁵ Industrial Quality Control (ASQC)

Una vez finalizado el proceso de producción de los ejes, estos eran depositados en un cesto, de donde luego el departamento de control de calidad realizaba mediciones del diámetro de una muestra de los mismos, sin embargo **con este método se perdía el orden de producción.**

Shainin comienza por **identificar las fuentes sospechosas de variación** que pueden presentarse en el proceso de producción de ejes. Tres importantes familias se combinan para producir la variación total observada:

a) variación dentro de la pieza;

...para evaluarla se midieron los diámetros máximos y mínimos alcanzados al inicio y al final de cada eje, con el fin de detectar las **diferencias dentro del mismo eje** que podrían producirse por un descentrado de la pieza de corte o un desacople en el soporte del eje, lo que podría dar una forma “ovalada” y no circular a cada unidad.

b) variación entre piezas;

...para analizar la variación entre piezas **se deben tomar las muestras de la misma fuente**, el torno en nuestro ejemplo. Si existieran más tornos, una nueva fuente o familia de variación debería contemplarse, es decir, la variación entre tornos. En nuestro caso, si descubriéramos diferencias entre partes, es decir entre ejes, **indicaría que el torno bajo estudio es inestable.**


c) variación entre diferentes períodos de tiempo.

...los procesos cambian en el tiempo por ajustes de los operadores, por cambios de lotes de materias primas, debido a condiciones ambientales, etc. **Deben seleccionarse muestras que permitan detectar cambios importantes que se producen en el proceso a lo largo del tiempo.**

Puesta en marcha de la máquina, cambio de la herramienta, de material, del operador, son buenos candidatos para tomar **muestras diferenciadas.** En este caso se decidió hacerlo cada una hora.

En definitiva, nuestras fuentes de variación para la construcción del gráfico multi-vari serán:

- Hora: **Hora en que se tomó la muestra** (entre las 8 am y las 12 pm).
 - Eje: **Número de eje seleccionado** (1 a 3).
 - Círculo: Si la medición corresponde al **círculo inicial del eje (I)** o al **círculo final (F)**. Para cada uno de los círculos se mensuró el **diámetro máximo y mínimo.**
-



La forma que adopte el multi-vari dependerá del orden en que se definan los diferentes factores. El nivel más elemental de agrupamiento corresponde a la hora, se tomaron muestras entre las 8 y las 12 (verde). Dentro de cada hora se evaluaron tres ejes diferentes (1 a 3) (rosa) y finalmente se midieron los diámetros máximos y mínimos en el inicio (I) y final (F) de cada uno de los ejes de la muestra (azul).

Observando el multi-vari se detectan algunos patrones de interés. Por ejemplo, es considerable la variación dentro de cada pieza, corresponde aproximadamente a la mitad del rango especificado en cada uno de los casos, sin embargo, no podemos decir que es la causante de tener un proceso no apto. Si sólo existiera esta variación, intuitivamente vemos que el Pp^6 no sería menor que 1 (la banda de variación es mucho más pequeña que la tolerancia especificada).

El multi-vari revela entonces que la fuente de variación más importante se observa entre las diferentes horas. Entre las 8 y las 10hs. se hace evidente una tendencia descendente, que vuelve a comenzar a partir de las 11hs. En este momento, podríamos dar por concluido el análisis estadístico y pasamos ahora a depender del conocimiento experto del proceso para explicar el fenómeno.

Se pudo averiguar que a las 10:30hs. el maquinista había tomado un descanso y detenido el torno. Mientras el operario trabajaba, la temperatura del equipo subía debido a la fricción y posterior expansión de metales.

Ante cada descanso o parada de máquina se daba tiempo para la refrigeración del torno, el que volvía a la situación inicial (8hs.). Se descubrió que el

⁶ $Pp = \frac{LSE - LIE}{6\sigma}$ - Índice de Performance de Proceso.

depósito de refrigerante se encontraba por debajo del nivel correspondiente, se adicionó el refrigerante faltante y **se eliminó la variación entre horas**, lo que derivó en un proceso apto para cumplir con las especificaciones exigidas.

Podemos concluir entonces, en que la potencia del gráfico multi-vari, radica en la **aplicación del principio de Pareto a las fuentes de variación de un proceso, de una manera simple y escapando a la rigurosidad de la estadística analítica. Bien usado, permitirá al investigador eliminar muchas fuentes triviales de variación del proceso, delimitando la búsqueda de la causa raíz.**

A lo largo del tiempo el gráfico multi-vari fue evolucionando e incorporando herramientas complementarias que fueron aumentando su potencial. Por ejemplo, en lugar de comparar valores individuales o promedios entre los diferentes niveles de cada fuente o factor de variación, **podría compararse además la dispersión entre estos niveles, por ejemplo graficando box plots, lo que transformaría al gráfico prácticamente en una aproximación a la comparación de grupos, similar a un análisis de variancia.**

En este caso al tratarse de una **técnica de pre-experimentación, se transforma en un interesante aliado para realizar un análisis exploratorio, que a posteriori podría derivar en un diseño de experimentos** para confirmar las sospechas observadas en el multi-vari.

Bibliografía

- Juran, Joseph M. (1962), *Quality Control Handbook* (2 ed.), New York: McGraw-Hill
 - Seder, Leonard (1950), "Diagnosis with Diagrams—Part I y II", *Industrial Quality Control* (New York: American Society for Quality Control)
 - Shainin, R. D. (2008): *Multi-Vari Charts: Encyclopedia of Statistics in Quality and Reliability*.
 - Box, G., Hunter & Hunter (2005): *Statistics for Experimenters: Design, Innovation, and Discovery*. (Wiley-Interscience; 2 edition. USA).
-

Relación entre ambas técnicas

<DOE y Multi-Vari>

Como vimos en el primer artículo, **es importante distinguir estudios observacionales de experimentales. Los gráficos multi-vari brillan como herramientas observacionales**, permitiéndonos una primera aproximación a los potenciales factores que pueden explicar la variabilidad de nuestro proceso. Sin embargo, su uso siempre requiere una instancia posterior de verificación y confirmación, donde es óptimo apelar a la experimentación.

La gran ventaja del multi-vari es que aprovecha la **inigualable capacidad humana de reconocer patrones visualmente**. Este reconocimiento de patrones debe complementar otras fuentes posibles de factores explicativos, como los diagramas de Ishikawa, AMFE, tormenta de ideas, etc. que nunca deben faltar en el bolsillo del caballero o la cartera de la dama que practiquen la mejora continua.

En determinados procesos estamos imposibilitados de experimentar (pensemos en procesos sociales o análisis en condiciones de alto riesgo, como condiciones de seguridad en una central nuclear). En estos casos el multi-vari nos ayuda a generar ideas sobre las posibles relaciones de causa efecto. Si tenemos un modelo matemático del sistema, podemos utilizar simulación para verificar nuestras hipótesis. Sin embargo, en muchos casos solo nos quedaremos con las hipótesis, cuya verosimilitud se irá consolidando a medida que sigamos observando el sistema.

Resumiendo, podemos decir que el multi-vari es un excelente “generador de hipótesis”, y el DOE un excelente “confirmador de hipótesis”.
