

Bienvenidos al Informe Druida Número 17, que aparece sólo 4 meses después del número 16. Esperemos no generar saturación informativa en nuestros lectores!

En este boletín tratamos dos temas: 1) Big Data y su relación con Calidad y 2) Axiomas del Análisis de Datos de Wheeler. Para hacer honor al nombre, tenemos un Big Boletín, porque es el de mayor cantidad de páginas de los 17 emitidos hasta ahora.

Vivimos rodeados de información y datos. Entender, procesar e interpretar esta avalancha de información es una tarea muy compleja, que requiere la ayuda de ordenadores. Big Data es la forma resumida de llamar a este nuevo paradigma, donde se buscan patrones en la información almacenada para ayudar en la toma de decisiones. En este boletín, Daniel sugiere algunas aplicaciones posibles en el área de Calidad, mostrando algoritmos populares de Big Data y como podrían usarse en la práctica de la Mejora Continua.

Tratamos de que el boletín este siempre exento de publicidad que distraiga de su contenido informativo, más allá de alguna referencia a la forma de resolver problemas con nuestro software SPAC. Pero en esta instancia relajaremos el puritanismo informativo para sucumbir a la seducción de un chivo¹. Sin embargo, no lo haremos de manera subrepticia ni subliminal.

<Chivo> *Druida fue fundada en 1993. Desde la incorporación de Javier en 1996, nunca en estos casi 20 años hemos dictado un curso abierto en forma conjunta, y decidimos que quizás es tiempo de hacerlo. Entonces en **Julio (días 24 y 25)** dictaremos un **curso sobre Proyectos de Mejora de Ingeniería Estadística**, donde [Daniel Firka](#) se concentrará en aspectos metodológicos/sociológicos, y [Javier Carrizo](#) en aspectos estadísticos. Si desea más información envíenos un mail a info@druida.biz* **</Chivo>**

Wheeler es un gigante en el área de Control Estadístico de Procesos, y la serie de axiomas que expuso en su libro sobre Seis Sigma es una excelente guía para el análisis de datos. Algo que debe estar tanto en la cartera de la dama, como en el bolsillo del caballero, si es que la dama o el caballero tengan que lidiar con datos. Javier se ocupa de ese tema en el presente boletín.

Los invitamos a seguirnos en [Linked in](#).

Hasta la próxima!!!. El equipo de [Druida](#).

Frase del Boletín:

“La combinación de algunos datos y un ferviente deseo por una respuesta, no asegura que una respuesta razonable se pueda extraer del conjunto de datos dado”.

John W. Tukey

¹ Nota: Chivo se refiere a publicidad embebida en mensajes que tienen otro objetivo.



Big Data y Calidad

Autor: Daniel Firka. Junio, 2014

Big Data y Calidad

Nuestras mentes tienen un sesgo subjetivo a buscar explicaciones unidimensionales, asignar a cualquier efecto una única causa: *"la culpa de todo esto la tiene X"*, *"...haceme caso, la cosa viene por ahí..."*. Nos cuesta a veces aceptar que muchos problemas resultan de múltiples causas relacionadas, que quizás se potencian entre sí (lo que llamamos en estadística interacción). Salimos con esfuerzo del concepto "1 causa -> 1 efecto", a trabajar con "Varias Causas -> Un efecto"... pero podemos marearnos al pensar en "Miles de Causas -> 1 efecto", el dominio del Big Data.

Cuando abandonamos los problemas de unas pocas variables y nos sumergimos en grandes depósitos de datos, los tradicionales métodos que estudiamos en la escuela/universidad empiezan a hacer agua. Hasta calcular el promedio es una tarea complicada cuando uno tiene un terabyte de datos (es decir 1.099.511.627.776 bytes, la información que mueve google en unos 2 segundos²)

El concepto de Big Data se refiere a estos monstruosos sets de datos que necesitamos estudiar, pero cuya magnitud escapa a las posibilidades de métodos tradicionales de análisis de datos.

Las primeras empresas que se toparon con los desafíos del Big Data fueron las compañías de internet: Yahoo, Facebook, LinkedIn, Google, etc. Los avances tecnológicos en adquisición de datos en tiempo real hacen que en el entorno industrial estemos llegando a una situación similar; ya es económicamente factible recolectar datos de sensores que monitorean procesos y productos a muy alta frecuencia.

El Control Estadístico de Procesos pronto va a cumplir 100 años de existencia, en 1924 W. Shewhart desarrolló primer gráfico de control en la planta de Hawthorn, USA. Continúa siendo una herramienta fundamental para controlar y asegurar la capacidad de procesos. Ahora bien, ¿qué pasa cuando en vez de una variable medida, tenemos 123 variables con datos tomados cada segundo durante todo un día?... estamos hablando de unos 10 millones de valores diarios. Los clásicos gráficos de control y sus extensiones multi-dimensionales no están preparados para lidiar con semejantes tamaños.

Por otro lado, si recortamos la información para quedarnos con una o dos variables y algunos pocos momentos del día nos arriesgamos a perder información valiosa... bienvenidos al mundo del Big Data, donde 10 millones de datos es todavía "baby Big Data".

¿Qué herramientas se han desarrollado para atacar estas situaciones?

² <http://www.complexmag.ca/tech/2013/02/50-things-you-didnt-know-about-google/20-petabytes>

Ninguna persona puede procesar manualmente la información contenida en Big Data, es decir que la única forma de analizar la información es mediante computadoras. Afortunadamente el incremento en la velocidad y capacidad de almacenamiento ha seguido un ritmo exponencial (algo que se conoce como la “Ley de Moore”, duplicación de la capacidad de incluir transistores en un determinado espacio físico cada 18 meses)

Como ejemplo de esta “segunda revolución industrial”, tomemos el Voyager I, que recientemente abandonó el Sistema Solar con un mensaje dirigido a extraterrestres. Fue lanzado en 1977, y su computadora interna era más débil que el procesador de un smartphone³ actual.



Figure 1 del Voyager I al iphone en 30 años.

Cuando iniciaba mi carrera como programador, allá por los 90, un término en boga era “sistemas expertos”. Se pensaba que estos sistemas revolucionarían el mundo a través de la inteligencia artificial, embebiendo una serie de reglas lógicas en los programas, y convirtiéndolos en “expertos” para resolver determinados problemas.

La idea era buena, pero el campo todavía no estaba fértil para que la semilla prendiera: las computadoras todavía no eran lo suficientemente poderosas y no se habían desarrollado algoritmos para realizar estos procesos decisorios. Pero no había que esperar mucho... 10 años después una computadora (Deep Blue) triunfa al ajedrez contra el maestro Kasparov, y 20 años después una computadora (Watson) gana en un concurso de preguntas y respuestas escuchando y hablando contra contrincantes humanos.



Figure 2: DeepBlue contra Kasparov



Figure 3: Watson en Jeopardy

³ <http://www.washingtonpost.com/blogs/the-switch/wp/2013/09/12/voyager-1-just-left-the-solar-system-using-less-computing-power-than-your-iphone/>

El campo de “Aprendizaje de Máquinas” o *Machine Learning* fue desarrollándose desde los 80 y su sinergia con la evolución de las computadoras fue lo que produjo un salto cualitativo en la capacidad algorítmica de reconocimiento de patrones. Las redes neuronales, inspiradas por nuestro cerebro, fueron tempranos algoritmos que mostraron características “expertas”, aunque poseían el grado de inteligencia de una lombriz bebe.

El campo de Minería de Datos o *Data Mining* surge cuando algoritmos de *Machine Learning* comienzan a aplicarse en los grandes volúmenes de datos presentes en las empresas. A pesar del progreso en este ámbito durante la primera década de este siglo, recién los últimos años vemos un cambio fundamental debido a la sinergia entre ordenadores y algoritmos. Algo que, como ejemplo, ha logrado un auto que maneja sin conductor⁴, que ya ha recorrido medio millón de kilómetros sin un accidente⁵.



Figure 4 Auto sin manubrio que fabricará Google en el 2015

Podríamos pensar que en el mundo del Big Data ya no hace falta la estadística, dado que si tenemos todos los datos, no es necesario tomar muestras, es sólo cuestión de mirar los datos y ver que se encuentra. No! *Muchos datos no significan mejores datos*. Tener millones de piezas de información complejiza el análisis y exige métodos estadísticos para separar “la paja del trigo”.

¿Qué buscamos al analizar la información? Buscamos comprender los **patrones de comportamiento** de los datos. ¿Para qué? Podemos tener los siguientes objetivos:

- 1) Entender lo que pasó... DESCRIPCIÓN.
- 2) Predecir lo que va a pasar... PREDICCIÓN.
- 3) Optimizar el funcionamiento del sistema... OPTIMIZACIÓN.

Una aclaración importante, recordemos la distinción fundamental entre **estudios observacionales** y **experimentales** (tema tratado en el boletín 10). Big Data trabaja sobre datos recolectados sin previa planificación, es decir, sobre información observacional. Esto significa que el poder predictivo es cuestionable, y siempre

⁴ <http://recode.net/2014/05/27/googles-new-self-driving-car-ditches-the-steering-wheel>

⁵ http://en.wikipedia.org/wiki/Google_driverless_car

debemos realizar una validación de las conclusiones si buscamos predecir u optimizar un proceso en base a estos análisis.

En el mundo del Big Data solicitamos a las computadoras que “aprendan” en base a lo que ven en los datos. Luego nosotros observamos los resultados para sacar nuestras propias conclusiones. El aprendizaje es guiado por algoritmos que pueden ser de dos tipos: supervisados y no supervisados (*supervised and unsupervised learning*).

El aprendizaje supervisado se refiere a algoritmos para modelar la relación entre variables predictoras y una respuesta. En el set de datos de entrenamiento sabemos cuáles son las variables que pueden influir (X) y cuál es la variable de respuesta (Y) resultante de cada observación.

Para ejemplificar, si estamos en un jardín de infantes, el aprendizaje supervisado corresponde a la siguiente situación:




Figure 5: Aprendizaje Supervisado, la imagen tiene líneas y colores, y la maestra dice cómo llamamos a esa combinación de líneas y colores

La maestra muestra a Jaimito una serie de cartas. En las cartas hay diferentes casas, modelos de auto y razas de perro. Cada vez que le muestra una carta, la maestra le dice “Jaimito, esta es una casa”, “Jaimito, este es un perro”, etc.

Luego del “entrenamiento”, Jaimito tiene en su cerebro la forma de identificar, en base a una figura, si corresponde a una casa, auto o perro. Un ejemplo de “predicción” sería: la maestra le muestra varias fotos y le pregunta: “Jaimito, ¿Cuáles de estas fotos son casas, autos o perros?” y Jaimito tiene que ordenarlas en tres pilas.

Si vamos al aprendizaje no supervisado, la maestra le da todas las cartas y le dice “agrupa las cartas en diferentes pilas”. Jaimito mira las cartas y arma tres pilas, una con casas, otra con perros y otra con autos. La maestra no le explicó previamente qué contenía cada una, pero Jaimito pudo distinguir que hay tres tipos de cosas diferentes en las figuras. Aquí no importa cómo se llaman las figuras (“casa”, “auto”, “perro”) sino el hecho que son grupos diferenciados.



Vamos ahora a ver algunos de los métodos usados en el mundo del Big Data, con ejemplos inventados pero inspirados en el mundo real de la Calidad.

Regresión LASSO

Recordemos que tenemos una variable Y, la respuesta; y una serie de variables que pueden influir en ella (Xs). Matemáticamente, la relación es:

Donde $f(X)$ es una función de X . En la regresión “lineal”, la ecuación es

Donde β_1, β_2 son los coeficientes, que miden cuánto afecta cada X en la variable de respuesta. Un valor alto de β_2 implica que un cambio en la variable x_2 tiene considerable efecto sobre la respuesta y.

¿Qué pasa si en vez de 3 variables X , tenemos 3000? Usando el modelo de regresión múltiple, obtendremos 3000 coeficientes beta, algunos muy pequeños, lo que hace muy difícil interpretar el modelo. Otro problema es que necesitamos esperar mucho tiempo para obtener todos los coeficientes.

La regresión LASSO alivia estos problemas, porque además de buscar la combinación de coeficientes que mejor explican la variable Y, también busca la combinación con la menor cantidad de coeficientes. Es decir, “penaliza” el exceso de



coeficientes. Entonces, luego de la regresión, quizás sólo 20 de las 3000 Xs resultan seleccionadas como parte del modelo, y esto permite entender mejor el fenómeno.

Ejemplo: producción de azúcar a partir de caña de azúcar, industria muy activa en Brasil y en la provincia de Tucumán, en Argentina. Esquemáticamente el proceso es el siguiente:

- 1) La caña es triturada y “lavada”, el agua de este lavado es el jugo que contiene el azúcar.
- 2) Este jugo es procesado químicamente con dos procesos: sulfitado y encalamiento. El segundo proceso busca llevar la acidez (ph) a un nivel óptimo de 7.
- 3) El jugo se calienta y se deja en tanques para que sedimenten los sólidos, obteniendo el “jugo clarificado”
- 4) El jugo clarificado se calienta hasta que se va evaporando, dejando una melaza con gran contenido de sólidos.
- 5) La melaza va al cocimiento, donde se aprovecha la propiedad que tienen los productos azucarados que al ser concentrados cristalizan. La cristalización produce el azúcar que todos conocemos.

En el paso 2, es muy importante que el pH llegue a 7. El pH es nuestra variable de respuesta (Y), y queremos investigar cómo depende de factores del proceso y el producto. Entre las variables X, tenemos:

- Propiedades de la caña: rendimiento, pureza, grados brix, etc.
- Características de la difusión o lavado: temperaturas, tiempos, etc.
- Características del jugo: grados brix resultantes, temperaturas, viscosidad.
- Características del sulfitado: cantidad de ingredientes adicionados, tiempos, velocidades de rotación, etc.
- Características del proceso: caudales, tiempos, temperaturas, estado del tanque, etc.

La zafra, que es el proceso de cosecha de azúcar, comienza generalmente en mayo (en Argentina) y se extiende por varios meses. Sensores continuos miden valores de todas las variables involucradas. Otras mediciones son manuales sobre la caña de azúcar o tomando muestras del proceso. En dos meses se genera un set de datos con 42 variables X y 3400 filas, cada una indicando el pH obtenido.

Usando la regresión LASSO, de estas 42 variables, la mayoría da como resultado coeficientes cero, y sólo quedan 4 con coeficientes mayores que cero. Estas son las variables que más influyen en el pH del jugo.

Antes de pasar a controlar estas variables, debemos hacer un estudio experimental con estas cuatro variables, para validar que realmente son las que impactan en el pH, y determinar sus valores óptimos. Para esto podemos usar un diseño de experimentos factorial (DOE)... pero este es un tema de otro boletín.



Arboles clasificatorios

Los arboles clasificatorios están compuestos por una serie de ramas, cada rama consiste en una decisión en base a los datos que vemos, hasta llegar a la última rama donde se toma una decisión. En cada nodo del árbol, uno examina una variable y dependiendo del valor se decide por una u otra rama. En general se utilizan para problemas de clasificación, donde en función de una serie de variables X , buscamos una Y que es un atributo o una serie de valores posibles.

Observemos el siguiente árbol:




Gráfico 1: árbol clasificatorio

Una vez construido, a partir de una nueva muestra del proceso, vemos la temperatura y chequeamos si es mayor o menor a 23 °C. Si es menor, nos ubicamos en el nodo derecho, y el árbol nos indica mirar la presión, a ver si es mayor o menor a 2 psi. Si la presión es mayor a 2 psi, el árbol predice que el producto será defectuoso. Supongamos que la temperatura medida es mayor que 23 °C, en ese caso no es necesario seguir examinando valores, porque todas las ramas conducen a resultados OK del producto.

Una nota terminológica: frecuentemente se habla de Regresión cuando la variable Y es continua, y de clasificación cuando es discreta. Sin embargo hay excepciones, como la regresión logística. Los árboles se utilizan en problemas de clasificación, porque sus decisiones son discretas en vez de valores continuos.

Las forestas aleatorias (*random forests*) usan el mismo principio, pero en vez de tener un solo árbol, se generan múltiples árboles, y para cada árbol se hace un recorte aleatorio de las variables X a considerar para abrir las ramas. Esto hace que haya arboles dando distinto peso a diferentes variables. Una vez construida la "foresta" de, digamos, 200 árboles, para tomar una decisión se utiliza una votación entre todos los arboles construidos, y la opción más votada es seleccionada.

Redes Neuronales

Como comentamos antes, las redes neuronales buscan imitar el funcionamiento de nuestro cerebro, a través de neuronas virtuales que reaccionan

ante estímulos. Los estímulos son las X , y la reacción de la red neuronal es la variable Y predicha.

¿Cómo se entrena una red neuronal? Resumiendo: se la expone a un gran número de ejemplos de varias X y cuál es la Y correspondiente. A medida que se van mostrando estos ejemplos a la Red, ésta va modificando ciertos parámetros de sus neuronas adaptándolas a lo que ve (usando métodos como *backpropagation*).

Al final del proceso, cuando la red está entrenada (es decir, cuando podemos confiar en los parámetros), podemos pasar a la etapa de predicción, donde le mostramos a la Red una serie de X s y vemos cual es la Y que nos devuelve.

Recordemos que en la regresión múltiple podíamos entender cómo cada X influía en la Y . En las redes neuronales perdemos la capacidad de interpretación: los parámetros de las neuronas no nos dicen nada sobre cuales X son más importantes. Es decir, que la red neuronal nos permite predecir valores de la Y , pero no nos deja entender la causa de obtener una determinada Y a partir de las X .

Ejemplo: envoltura de caramelos. Los caramelos se envuelven en máquinas que trabajan a muy alta velocidad, miles de golpes por minuto. A veces, la máquina envuelve incorrectamente los caramelos, generando defectos que disminuyen la calidad del producto.



Figure 7: Caramelo mal envuelto

Muchas variables pueden influir:

- Características del flexible utilizado
- Velocidad, temperaturas de operación de la maquina
- Consistencia del caramelo, forma, etc.

La variable de respuesta consiste en un atributo “ok”, “no ok”, que mide si el caramelo está envuelto correctamente. Alternativamente se pueden identificar distintas formas de “mal envoltura” y en cada medición de las X , asignar uno de estos valores.

Tenemos datos de todo el mes, donde en ciertas situaciones se descubrió que aparecieron caramelos mal envueltos. Los registros incluyen un 99.98% de datos donde los caramelos salieron bien, y un 0.02% de datos con caramelos mal envueltos, con 140000 filas y 23 variables de producto y proceso para cada observación.

Presentamos estos datos y entrenamos una red neuronal. Para evaluar si la red hace un buen trabajo, primero dividimos los 140000 registros en dos bloques: un

bloque de entrenamiento, con 120000 datos, con el cual la red aprende, y otro bloque de Validación con los 2000 restantes.

Una vez terminado el entrenamiento, usamos el bloque de validación para ver que tan bien funciona la Red. Le presentamos los 20000 datos restantes, pidiéndole que nos diga como saldrá el caramelo en cada una de las observaciones, y como sabemos la Y verdadera podemos medir cuántas veces se equivoca.

Ante cualquier dato se puede equivocar de dos maneras: puede predecir que el caramelo va a ser defectuoso, aunque el caramelo este Ok (falso positivo), o se puede equivocar diciendo que el caramelo va a estar Ok, siendo defectuoso (falso negativo). Esto se llama un test de validación de la red, y de acuerdo a los porcentajes de error obtenido podemos decidir si la red es útil.

Supongamos que obtenemos un 2% de falsos positivos, y un 1% de falsos negativos. Esto implica que la red detectará correctamente el 98% de las veces que las variables van a producir defectuosos (en medicina esto se llama sensibilidad), y correctamente dejará Ok el 99% de los caramelos Ok (en medicina esto es la especificidad). Si nos gusta... podemos empezar a usar la Red.

Modelos de aprendizaje no supervisado

En estos modelos no existe una variable respuesta, lo que nos interesa son los patrones de comportamiento de un grupo de variables: cuáles van siempre juntas, cuáles varían mucho más que otras, etc. Es una forma de “entender” la variación presente en los datos sin buscar explicar un efecto.

Clustering

Los modelos de agrupamiento o *clustering* buscan determinar grupos de datos similares entre sí. Para ello se debe definir una medida de distancia entre cada variable; esto es fácil cuando todas las variables son numéricas, pero si hay mezcla variables categóricas y numéricas el desafío es cómo medir la “distancia” entre variables categóricas, o entre categorías y números.

Un ejemplo de estos métodos es “*K-Means*”, que va agrupando en base a la distancia que separa los promedios de los grupos, realizando sucesivas iteraciones. En el siguiente gráfico:




Gráfico 2: Clustering

Usando $K=3$, el algoritmo se acercaría a distinguir tres grupos de datos, coloreados en rojo, verde y azul. Cuando el algoritmo empieza, todos los datos son iguales, y se “siembran” tres puntos, que a medida que progresa el algoritmo se van acercando a los centros de los tres grupos.

Ejemplo: camisas de pistón. En una fábrica de motores hay un proceso donde se inserta una camisa de acero en un cuerpo de aluminio. En algunos casos, esta camisa se desprende luego de 10 o 20000 km de uso, destruyendo el motor y posiblemente arriesgando la vida de los ocupantes del vehículo.

No se sabe la causa de este problema y solo puede determinarse si está bien o mal insertada la camisa destruyendo el bloque y para exponer la inserción. La frecuencia de aparición del problema es muy baja –fue reportado sólo en 5 oportunidades de los miles de vehículos usando estos motores. Si diseñamos un plan de muestreo para tan baja frecuencia, deberíamos destruir inspeccionando un alto porcentaje de la producción, lo que no es viable económicamente.



Figure 8; cuerpo de aluminio del motor de un BMW serie 6

Al no poder inspeccionar para ver si la camisa es defectuosa (la Y), sólo nos queda ver las X, es decir las variables que podemos medir del proceso y del producto, para ver si hay una segregación en varios grupos de variación. Si identificamos dos “clusters”, o grupos de datos, quizás uno de los grupos sea responsable del problema.

Existen sensores en la máquina que permiten medir dos variables: distancia y presión ejercida. El proceso de inserción genera un perfil de distancia y presión ejercida. La distancia no aporta mayor información, pero la fuerza ejercida genera un perfil que puede graficarse:




Gráfico 3: fuerza ejercida a través del tiempo



Estas curvas pueden transformarse en variables a estudiar, por ejemplo seleccionando 100 puntos equidistantes sobre el eje de abscisas, el valor de fuerza en cada punto corresponde a una X . Lo que hacemos es discretizar la curva generando variables que podemos estudiar:




Gráfico 4: fuerza ejercida a través del tiempo

Tenemos datos de los últimos 3 meses, cada día se insertan 400 válvulas, o sea que tenemos 37200 curvas, cada una con 100 variables X . Un set de 372.000 datos, bastante difícil de entender con un histograma o un gráfico de control!!

Utilizando el algoritmo no supervisado de K-Means encontramos que hay dos *cluster* bien diferenciados: un *cluster* con el 99.9% de las curvas y otro mucho más reducido. Estos *clusters* se ubican en un espacio de 100 dimensiones (las 100 variables X que discretizan la curva) lo que nos impide “observar” esta situación gráficamente.

El próximo paso es ver si los dos *clusters* nos ayudan a encontrar la causa del problema. Realizamos una inserción de camisa, midiendo la curva y discretizándola en los 100 valores de X . A partir de los valores de las X , vemos que el dato se ubica en el primer *cluster*, luego inspeccionamos la pieza y vemos que la camisa está OK, con lo cual concluimos que el primer *cluster* no ayuda a identificar el problema.

Ahora esperamos hasta que una inserción genere un patrón como el del segundo *cluster* (hay que esperar bastante, porque recordemos que ese patrón solo aparece en un 0.01% de las inserciones). Una vez que lo tenemos, hacemos la prueba destructiva y VOILA! , se encuentra un ínfimo defecto en la camisa originado por un rozamiento excesivo durante la inserción, que está asociado al problema de rotura a los 20000 km. Estudiando la curva del segundo *cluster*, se nota una leve alteración en el segmento inicial:



Gráfico 5: fuerza ejercida a través del tiempo

Ahora podemos usar las curvas para seleccionar cuando la inserción fue correcta o cuando es incorrecta, determinando en cuál de los *cluster* se ubica. También podemos buscar la causa de esa alteración en la curva para eliminar la causa

raíz. Sin los métodos de *clustering*, este análisis sería mucho más complicado debido a la cantidad de curvas y el diminuto cambio en el perfil que producía el defecto.

Análisis de Componentes Principales (PCA)

Otro mecanismo usado para entender datos con muchas variables (llamados también multidimensionales) es la “reducción de dimensionalidad”, que se refiere a encontrar un set reducido de variables que expliquen la mayoría de lo que pasa en los datos.

Uno de estos métodos es PCA, método de los componentes principales (Principal Component Analysis), que divide los datos en componentes; estos componentes son nuevas variables que combinan varias de las variables originales, como se ve en el siguiente gráfico, donde tenemos una X y una Y, y dos componentes principales:




Gráfico 6: componentes principales

PCA busca variables que explican la variación en los datos. En este ejemplo, si rotamos los ejes como vemos en la figura, generando dos variables v_1 y v_2 . La variable v_2 contiene la mayor variación en los datos (la campana es más ancha) mientras que la variable v_1 no muestra mucha variabilidad.

¿Cómo se usa? Ejemplo: en un proceso de pasteurización de leche, se miden 50 variables de proceso y de producto, entre ellas:

- Nivel del tanque
- Presión de la bomba
- Velocidad de centrifugado en 3 momentos
- Temperatura en 5 puntos, etc.



Figure 9: Planta de Pasteurización

Tenemos una base de datos del año pasado, con 30000 mediciones de las 50 variables. Haciendo un análisis de PCA, encontramos que el primer componente principal es una variable compuesta por:

$$V1=0.25 \text{ (Temperatura máxima)}+0.23 \text{ (tiempo de pasteurización)}$$

Y ese componente explica un 80% de la variabilidad en los datos.

Esto nos dice que en el set de datos, la temperatura y tiempo de pasteurización están relacionadas, y el efecto conjunto de ambas explica el 80% de la variación que se observa.

Muchas veces es interesante ver los últimos componentes principales, que nos informan aquellas variables que se mantienen constantes o no tienen gran influencia sobre lo que observamos en el set de datos.

Big Data y estrategias de control de procesos

Operar un proceso satisfactoriamente, implica establecer los valores de las variables de proceso que permitan generar producto dentro de especificaciones. ¿Cómo lo hacemos? Necesitamos saber algo sobre el proceso para poder controlarlo, y según el grado de conocimiento se pueden establecer diferentes estrategias de control.

Caja Blanca (white box): en esta situación conocemos las ecuaciones que rigen el proceso. Es decir, podemos usar las leyes físicas o químicas para determinar la ecuación $y=f(X)$ para las variables involucradas.

Caja Gris (grey box): establecemos un modelo que explica gran parte de la variación, pero deja cierta variación no explicada como error $y=f(X)+e$

Caja Negra (black box): descubrimos los patrones de variación de las X y la Y, para predecir el funcionamiento del proceso. No buscamos explicar ni interpretar las variables, sólo predecirlas para controlarlas. Aquí entran algunos de los métodos explicados previamente de aprendizaje, como las redes neuronales.

Y quizás deberíamos agregar...

Sin Caja (no box): un operador experto maneja el proceso modificando las variables de acuerdo a lo que le parece. Se va el operador, nos quedamos sin control.

Procesos simples pueden usar el método de la caja blanca, pero la realidad es que en la mayoría de las industrias los procesos tienen un grado de complejidad que impiden modelar exactamente la relación matemática entre las variables. Esto lleva al uso de los modelos de caja gris: Control Estadístico de Procesos, Regresión, modelos estocásticos, etc.

Finalmente, cuando la complejidad llega a niveles de Big Data, tenemos que rescindir interpretabilidad en pos de factibilidad de control, terminando en un modelo de caja negra, que funcione, aunque en cierto sentido no sepamos porque.

Todo muy lindo, pero... ¿cómo hacemos estos análisis de Big Data?

Todavía el análisis de sets de datos grandes es dominio de paquetes de software especializados.

Sin embargo, la creciente popularidad del programa R de estadística (un programa/lenguaje gratuito desarrollado en el mundo académico) hace que cualquiera con voluntad de aprendizaje pueda procesar datos.

Para aquellos interesados, el programa R está disponible en <http://www.r-project.org/> , un video para aprender a usarlo está en <https://www.youtube.com/watch?v=IV5Aj94JFbE> .

En R, distintos investigadores desarrollan paquetes que pasan a ser públicos. Por ejemplo, el paquete randomForest para forestas aleatorias, gbm para regresión Lasso, rpart para árboles clasificatorios, etc.

Cuando la cantidad de datos llega a niveles de petabytes (1000 terabytes), una sola computadora no alcanza, y necesitamos paralelizar y aprovechar procesamiento en paralelo. Aquí entran en juego los algoritmos de procesamiento paralelo, de los cuales el más famoso, llamado “Map Reduce” (mapeo y reducción) fue el que llevó a la fama a dos estudiantes de Stanford. Lo publicaron a fines de los 90 y lo implementaron en unas cuantas PC viejas trabajando en paralelo; fue el inicio de Google.

Otro algoritmo de popularidad creciente es GraphLab. En vez de trabajar sobre datos en forma de tabla, procesa información almacenada en gráficos compuestos de nodos y conectores. Un ejemplo de gráfico es Facebook o LinkedIn, donde cada persona (nodo en cada gráfico) está conectada con otras personas (otros nodos), esto genera gráficos de "amistad" donde uno puede buscar relaciones y realizar recomendaciones.

Para los usuarios de SPAC tenemos el SPAC EL (en línea) con datos de procesos productivos online, y el SPAC FL (fuera de línea) para experimentación y análisis estadístico avanzado. Pero todavía ninguna de las dos herramientas tiene incorporados algoritmos de *Machine Learning*.

Nuestra idea es desarrollar un nuevo módulo SPAC BD (Big Data) –el nombre puede cambiar, y se aceptan sugerencias- que tome datos de SPAC EL y otras fuentes

(PLCs, Bajadas de ERPs) y permita aplicarles estos algoritmos para determinar patrones, y llevar a la realidad los ejemplos que describí en este informe, aunque no creo que pueda lidiar con terabytes de datos, podrá manejar una escala suficiente para aplicaciones industriales. Moraleja, no creo que Google nos compre el SPAC BD.

Nota: hay muchos más algoritmos, pero en el informe preferí dedicarme a algunos importantes para dejar el “gustito” de cómo se atacan problemas de Big Data. Quizás en futuros informes describiremos otras técnicas, o profundizaremos en las tratadas aquí.

El lado oscuro de la revolución digital.

No quería terminar el artículo sin comentar “la otra cara de la moneda”.

La “revolución digital” está transformando nuestra sociedad, pero toda transformación cualitativa tiene asociados costos. Hasta hace pocas décadas se suponía que las computadoras sólo podrían reemplazar tareas repetitivas y monótonas; la línea de montaje de una planta, el procesamiento rutinario de datos masivos, etc.

Sin embargo, los últimos años están cambiando esta visión.

- Cuando vemos autos que manejan sin conductor, la pregunta es: ¿qué será en el futuro mediato con los taxistas?
- Cuando vemos algoritmos que detectan mejor la enfermedad en base a diagnósticos e información genética del paciente, teniendo como base de datos toda la información médica disponible a nivel mundial, nos preguntamos: ¿qué será de los patólogos, médicos, etc.?

Sigue habiendo profesiones cuyo reemplazo suena improbable: todas aquellas tareas que requieren empatía y relaciones interpersonales, así como creatividad. Hablamos de maestras de jardín de infante o primaria, niñeras, enfermeras, diseñadores de moda, etc. Casualmente las profesiones con mayor potencial de sobrevivir son dominio tradicional del sexo femenino.

El hombre va perdiendo el trabajo... Las máquinas pueden reemplazar la fuerza del hombre o parte de su capacidad analítica, pero están muy lejos (quizás a infinita distancia) de reemplazar una sonrisa o una lágrima.

Para los interesados en este “lado oscuro”, recomiendo el libro del profesor E. Brynjolfsson, de MIT: “The Second Machine Age: Work, Progress, and Prosperity in a Time of Brilliant Technologies”.



Análisis e interpretación de los Axiomas del Análisis de Datos definidos por Donald Wheeler

Autor: Javier Carrizo. Junio, 2014

En la *Guía para el Análisis de Datos del profesional en Seis Sigma*⁶, el reconocido estadístico, matemático y físico *Donald Wheeler*⁷ enuncia ocho axiomas, que como tales, los considera principios fundamentales para encarar el análisis de los datos.

Considero que el autor logra, a través de su visión, romper con esa frontera implícita entre la teoría y la práctica, desmitificando en no pocas oportunidades conceptos estrictamente teóricos y flexibilizándolos, entiéndase en este caso recurriendo a ejemplos empíricos y no pisoteando la teoría☺, para que nos sean útiles en nuestros procesos que son mundanos y no tan armoniosos como en libros y cursos de estadística.

Wheeler rompe con una visión clásica de la estadística que en ocasiones abrumba a más de un osado que intenta recurrir a las técnicas que la estadística ofrece. Frecuentemente, este osado e incipiente investigador naufraga en su intento, llegando a veces al límite de dar vida a un ser imaginario similar a Wilson⁸, compañero de Tom Hanks en la película *Náufrago*, esperando que este le aporte una luz en el camino y así recordar que tenía que hacer, por ejemplo, con los supuestos que la teoría exige ante determinado estudio; o cómo hacer para que su proceso se asemeje al menos a una deformada campana de Gauss; o cómo interpretar algo más allá que el promedio de los datos, entre los innumerables estadísticos y gráficos que hoy en día cualquier software estadístico ofrece.

Un capítulo aparte merece el software, que suponemos debería ser algo bueno, por todas las herramientas que nos acerca, aunque si no aparece Wilson para salvarnos, quizás hubiese sido mejor que no aparezca el software, lo cual habría permitido que la estadística permanezca lejos de nosotros, tan lejos como allá por el 1^{er} o 2^{do} año de la universidad y “mejor” aún, lejos de nuestros procesos. Pero bueno, la estadística está, el software está!! Y nuestros procesos no son lo buenos que nosotros pretendemos, entonces, - ¿Qué hacemos?

La conclusión decanta por sí sola, tenemos que analizar los datos. Por lo tanto, y sin extenderme más en esta introducción, pasemos a comentar los axiomas que Wheeler propone.

⁶ *Six Sigma Practitioner's Guide to Data Analysis*

http://www.spcpress.com/book_six_sigma_practitioners_guide_to_data_analysis.php

⁷ *Dr. Donald J. Wheeler Website*

<http://www.spcpress.com/index.php>

⁸ *El Nacimiento de Wilson (Película Náufrago)*

http://www.youtube.com/watch?v=1mt_grPXuQ

Axioma N° 1: Ningún estadístico tiene otro significado más allá del contexto de los datos originales.

Lo que nos dice este axioma, es que el estadístico que calculemos solo puede interpretarse en el contexto de los datos de los cuales se obtuvo. Además, si decimos que depende de los datos, estos tienen que presentar cierto grado de homogeneidad, por ejemplo, ¿Podemos realmente saber cuál es la dispersión natural de nuestro proceso si se encuentra totalmente fuera de control?, la respuesta, lamentablemente, es NO. La homogeneidad en un conjunto de datos es sumamente importante e imprescindible si pretendemos inferir a una población.

Gracias a Walter Shewhart⁹ tenemos a nuestro alcance una herramienta tan sencilla como efectiva para trabajar en la homogeneidad de nuestros procesos industriales, pero Ojo!!, también en nuestro procesos de servicios. Como la mayoría ya lo dedujo, me refiero a los gráficos de control, entonces, ¿Necesitamos homogeneidad en los procesos?, SI!!, por lo tanto recurramos a los gráficos de control!!, den por seguro que Wheeler y Shewhart estarán felices con esa decisión.




Gráfico 7: Control de °Bx en un proceso de fermentación de alcohol

Axioma N° 2: Los modelos de probabilidad no generan datos.

Excelente!!!, este axioma es tan evidente como lo es también el hecho de que los estadísticos, matemáticos y otros fanáticos de los numeritos a veces parecemos olvidarlo, espero no recibir represalias por el comentario ☺. Que lindo sería que la

⁹ Walter A. Shewhart Father of statistical quality control - ASQ

http://asq.org/about-asq/who-we-are/bio_shewhart.html

distribución normal o alguna de sus distribuciones amigas, léase binomial, poisson, gamma y compañía, nos entreguen unos maravillosos datos para que luego todo nuestro análisis salga redondito!!.

Si esto sucediera, sería la victoria de la teoría por sobre la realidad, y si alguna vez sucede, será en Melmac, el planeta de Alf¹⁰, que ante la necesidad de datos normales, solamente debemos pedirlos y él nos los enviará diciendo su clásico - No hay problema!!.

Ahora bien, ¿Debemos ignorar entonces las distribuciones teóricas conocidas? Por supuesto que NOOOOOOOOO!!!, gracias a ellas y en particular a quienes las descubrieron, podemos entender comportamientos y estimar que pasa o pasará en nuestros procesos, recordando que las distribuciones viven en el plano de la teoría, con lo cual a lo sumo serán aproximaciones de esa realidad, siempre y cuando, cumplamos con los supuestos que la teoría nos exige en cada caso, para poder decir que nuestro proceso o set de datos es consistente con la distribución normal o con la que corresponda. Continuemos con el axioma tres.

Axioma N° 3: Todos los histogramas tienen cola finita.

Claro que sí!!!, sin embargo, ¿Cuántas veces hemos escuchado en nuestras clases de estadística que las colas del histograma son asintóticas al eje de abscisas? Eso solo sucede en la teoría..... si se aplicara a la práctica y la variable bajo estudio fuera el peso neto de un chocolate con media 5 g y desvío estándar de 1 g, estaría mañana mismo golpeando a las puertas de la teoría para que me de él chocolate de 50 kg que alguna vez habrá salido de la máquina, si es verdad que la cola derecha de la variable es asintótica!!!




Gráfico 8: histograma del Peso Neto del Chocolate con $\mu=5$ y $\sigma=1$

¹⁰ Gordon Shumway (ALF) extraterrestre proveniente del planeta Melmac

<http://www.alftv.com/>

Como ya lo habrán deducido, este es un ejemplo más de que los datos reales inevitablemente difieren de los modelos de probabilidad, estos datos son finitos y de tamaño limitado, mostrando algún grado de robustez en sus medidas. Continuemos ahora al axioma cuatro.

Axioma N° 4: No se puede decir que ningún histograma sigue un modelo de probabilidad particular.

Este axioma es un corolario de los dos anteriores, confirmando que no es posible que un conjunto de datos finito se distribuya como un modelo de probabilidad particular.

Y entonces ...¿Para qué hacemos pruebas de bondad de ajuste?, estás pruebas nos sirven para confirmar que un conjunto de datos es inconsistente con un modelo de probabilidad pero nunca servirán para afirmar que nuestros datos se distribuyen como un modelo teórico conocido, probablemente Wilson y Alf dirían lo contrario, por lo tanto recurramos a alguien que sabe un poco más del tema, me refiero a George Box¹¹ quién un día se iluminó y compartió con nosotros el siguiente pensamiento "*Todos los modelos están equivocados. Algunos modelos son más útiles que otros.*", y no se quedó ahí, ya que en otro acto de inspiración y para seguir generando enemigos entre mis colegas dijo que "*Los estadísticos, como los artistas, tienen la mala costumbre de enamorarse de sus modelos.*"

Con este axioma Wheeler nos recuerda entonces, que afirmar, por ejemplo, algo como "*estos datos se distribuyen normalmente*" es incorrecto, la inferencia inductiva nos permitirá eliminar algunas posibilidades, pero no permitirá tener una respuesta única, es decir, si se rechaza la prueba de bondad de ajuste respecto de una distribución normal, se nos permite decir que nuestros datos - *Ni Loco son como la distribución normal!!!*, y en el mejor de los casos, si no se rechaza la prueba de bondad de ajuste, podemos apenas susurrar, - *Aún no hay evidencia suficiente para decir que estos datos no son consistentes con la distribución normal* y de esta forma seguir adelante con nuestro análisis, en un silencio de misa ☺. Sigamos con el quinto axioma.

Axioma N° 5: Sus datos son generados por un proceso o sistema que, como todo en este mundo, está sujeta a cambios.

Todo cambia!!, ya lo decía Mercedes Sosa¹² en su canción, y tenemos que convivir con nuestros datos que son el resultado de una operación o de un proceso, esto nos recuerda el primer axioma, los datos provienen de un contexto, inclusive si

¹¹ **George E.P. Box - Accomplishments in statistics - ASQ**

http://asq.org/about-asq/who-we-are/bio_box.html

¹² **Todo Cambia – Mercedes Sosa**

<http://www.youtube.com/watch?v=hf2cnIDyKL8>

durante un período de ensueño nuestro proceso es consistente con la distribución normal, calculamos felices el promedio y la dispersión, pero ¿Qué nos garantiza que estos parámetros se mantendrán en el tiempo?ahora bien, ¿Conocemos alguna herramienta que colabore en ese sentido?, alguna herramienta que nos permita mantener un proceso previsible y estable a lo largo del tiempo. Claro que si!!, y la mencionamos con anterioridad, el gran legado que nos dejó Shewhart, los fantásticos gráficos de control, que tienen sus variantes en los gráficos Cusum, EWMA, Rangos Móviles, etc. Creo que en cualquier momento Druida hará remeras alentando el uso de los gráficos de control, pueden suscribirse a la posible venta anticipada!!.

En definitiva, recurramos a los gráficos para mantener la estabilidad de nuestros procesos, para luego intentar reducir su dispersión si es necesario, pero no podemos reducir algo que aún no conocemos y solo conoceremos la verdadera variación del proceso cuando hagamos el esfuerzo previo de mantenerlo controlado, lo que significa que sea lo más homogéneo y previsible posible.

Y salvo que Wilson diga lo contrario, permítame recurrir a un tal Edwards Deming¹³ quien realmente no merece presentación. Deming enunció una de mis frases favoritas, quienes me sufrieron en algún curso ya lo saben bien😊, y que incluye una pregunta que parece una paradoja, pero que no lo es en absoluto.

“En la vida real, no hay nada como la constancia. Sin embargo, existe algo así como un sistema de causas constantes. Los resultados producidos por él varían, pudiendo hacerlo según intervalos de muy diversa amplitud. Varían pero exhiben una característica importante denominada estabilidad. ¿Por qué se aplican los términos “constante” y “estabilidad” a un sistema de causas cuyos resultados varían? Porque el mismo porcentaje de estos resultados quedaba continuamente entre cualquier par dado de límites hora a hora, día a día, tanto más cuanto más tiempo siga operando el sistema de causas. Es la distribución de resultados la que es constante o estable. Cuando un proceso de fabricación actúa como un sistema de causas constantes, produciendo unos resultados estables, se dice que está bajo control estadístico. El gráfico de control indicará al usuario si su proceso está bajo control estadístico”.

Buscamos en primer lugar una distribución estable en el tiempo, pero cuidado, ese es solo el primer paso, quizás no sea suficiente lograr la estabilización de un proceso y debamos recurrir a reducir su variación, este segundo paso no es otra cosa que volver a buscar señales separándolas del ruido, aunque ahora deberemos recurrir a otras técnicas estadísticas para descubrir aquellas variables independientes que expliquen la variación excesiva en relación a nuestros requerimientos o especificaciones, estas técnicas serán el diseño de experimentos, el análisis de regresión o las adecuadas de acuerdo al proceso bajo estudio. Vamos con alegría al sexto axioma!.

¹³ **W. Edwards Deming A mission pursued on two continents - ASQ**

http://asq.org/about-asq/who-we-are/bio_deming.html




Axioma N° 6: Todos los outliers son evidencia a primera vista de falta de homogeneidad


Los outliers, ...los pobres outliers o valores atípicos que arrastran una nefasta fama, enemigos públicos que solo aparecen para arruinar nuestros hermosos modelos probabilísticosquien trabajó alguna vez con un set de datos y vio que un desagradable outlier viene a molestar, sin dudas, tuvo una imperiosa necesidad de destruirlo, mirando hacia los costados, para que nadie lo observe mientras lo hace, sin embargo, Wilson aparece mirándonos entre enojado y decepcionado, indicándonos que ese no debe ser ese el camino a seguir,Wheeler nos obliga a reflexionar y nos dice *“mientras que eliminar los outliers puede ayudarnos a caracterizar el potencial de nuestro proceso, la realidad es que no nos ayudará a alcanzar ese potencial”*, y así, simplemente con esas palabras nos genera un remordimiento interior y nos lleva a preguntarnos, bueno, ¿Qué hacemos con ese outlier?, ese maldito outlier nos está brindando información, ...cuando lo vemos de esa forma, quizás empezamos a tomarle cariño, nos está diciendo que algo especial apareció en el proceso, es una señal de alerta!!, y por lo tanto un claro indicio de falta de homogeneidad, entonces, sonreímos porque si descubrimos que generó ese outlier, podríamos alcanzar la tan preciada homogeneidad de los datos. Una forma de detectar ese outlier, y permítanme que sea recurrente, consiste en el uso de los gráficos de control, que indicarán que una causa especial ha aparecido y si la detección es en forma online con la ayuda de un software, se puede incluso solicitar a la persona que está en la línea o en el laboratorio registrando los datos, que incorpore una observación con la certeza o al menos una sospecha de lo que podría generar ese desvío excepcional. Se tendrá, de esta manera, la información necesaria para actuar en consecuencia y eliminar esa causa especial y lograr un proceso homogéneo. No odiamos a los outliers, son en realidad nuestros aliados para comunicarnos que algo no está bien y recurramos a nuestro ingenio para saber identificar en la práctica que los generó. Pasemos al penúltimo de los axiomas.

Axioma N° 7: Cada conjunto de datos contiene ruido.

Puede resultar curioso, pero todos los procesos tienen ruido, que no es otra cosa que la variación natural del proceso, además algunos procesos tienen señales, asociadas en este caso a la variación especial. En definitiva, todos los procesos varían, pero podemos descomponer esa variación en variación de corto plazo (o local) y variación de largo plazo (o global), aquí los indicadores de aptitud de procesos resultan de gran utilidad para diferenciarlas, indicadores como C_p y C_{pk} consideran el desvío de corto plazo, o “ruido”, mientras que indicadores como P_p y P_{pk} consideran el de largo plazo, es decir, “ruido más señales”. Un proceso bajo control estadístico, afectado solo por causas comunes, sólo presenta ruido, es decir, datos homogéneos en donde C_{pk} y P_{pk} son iguales, si el P_{pk} es mucho menor que el C_{pk} es un indicio de ausencia de control.



Desvío de Corto Plazo	11.44
Cp	0.8314
Cpk	0.8301
Desvío de Largo Plazo	13.92
Pp	0.7183
Ppk	0.7172



Ejemplo de proceso fuera de control donde se observa que el Ppk es menor al Cpk.

Un proceso fuera de control presenta un mayor desvío de largo plazo debido a la falta de homogeneidad de los datos. Hay señales que debemos identificar y eliminarlas. En palabras de Wheeler “Hasta que no sepamos cómo separar lo excepcional de lo natural estaremos irremediablemente confundidos en cualquier intento de análisis”. Llegamos al último de los axiomas!!

Axioma N° 8: Se debe detectar la diferencia antes de que se pueda legítimamente estimar esa diferencia, y sólo entonces se puede evaluar la importancia práctica de esa diferencia.

Bien!!, veamos este axioma con un ejemplo, supongamos que queremos evaluar si existen diferencias entre dos líneas de producción de tres plantas diferentes en una variable crítica del proceso que es la carbonatación de una gaseosa

En la planta A, tomamos dos muestras de cada proceso, calculamos promedios muestrales, representados por los triángulos invertidos y si directamente comparamos los promedios obtenidos, alegremente podríamos decir que el proceso 1 es mejor, sin embargo, Wilson nos observaría una vez más decepcionado por no haber considerado las dispersiones de cada proceso, y no respetar el axioma ocho, que nos dice que se debe detectar la diferencia antes de estimarla. Al realizar una prueba T por ejemplo, confirmaríamos que no tenemos evidencia para decir que las muestras obtenidas de cada proceso presentan una diferencia significativa, es decir, que provienen de diferentes poblaciones. Lo podemos ver visualmente en la figura, donde las distribuciones de los procesos de ambas plantas prácticamente no presentan diferencias en su forma, posición y dispersión, con lo cual no tiene sentido estimar una diferencia que en realidad no podemos detectar que efectivamente exista.




Figura 10: carbonatación en Gaseosas de Líneas de Planta A



En la planta B, vemos que si hay una diferencia significativa, visualmente y olvidándonos de toda rigurosidad estadística, podemos evidenciarlo al observar que las distribuciones de ambos procesos no se “solapan”, es decir, claramente son diferentes y pertenecen a poblaciones distintas, sin embargo, carece de importancia práctica estimar esa diferencia, debido a que ambos procesos se encuentran dentro de especificación (líneas rojas punteadas), por lo que podemos seguir produciendo normalmente ya que se encuentra garantizado el cumplimiento de las especificaciones en ambos procesos. Solo podría existir interés en detectar la diferencia, si alguno de los límites es más crítico que el otro.




Figura 11: carbonatación en Gaseosas de Líneas de Planta B

Finalmente, en la planta C observamos que existe una diferencia estadísticamente significativa, si bien las colas apenas se solapan, si realizáramos un test de hipótesis corroboraríamos que hay evidencia suficiente para constatar esta diferencia, y en este caso además existe una importancia práctica, ya que el proceso 1 se encuentra prácticamente fuera de especificación, mientras que el proceso 2 dentro de los límites. Supongamos que en el proceso 1 se trabajó a una velocidad de máquina X y en el proceso dos a una velocidad de máquina Y, definitivamente deberemos optar por la velocidad Y, que nos permite que nuestra variable de interés, en este caso la carbonatación, se encuentre dentro de los parámetros requeridos.




Figura 12: carbonatación en Gaseosas de Líneas de Planta C

En definitiva y recurriendo una vez más a Wheeler, quién estableció estos axiomas, “Cuando el ruido de la variación de rutina oscurece una diferencia (Planta A) es un error tratar de estimar esa diferencia. Con técnicas estadísticas una diferencia perceptible es la que comúnmente se conoce como “significativa”. La significación estadística no tiene nada que ver con la importancia práctica de la diferencia (Planta B), sino simplemente con si es o no detectables. Si es detectable, entonces podemos obtener una estimación confiable de esa diferencia (Planta C).”



El análisis de datos, consiste en última instancia en discriminar el ruido de la variación de rutina en forma sistemática, pero no pretendamos que este filtrado sea perfecto, es imposible, sólo necesita ser lo suficientemente bueno como para dejarnos identificar las señales.

Sustentar nuestro análisis en la teoría de las probabilidades da lugar a técnicas de la estadística inferencial que son razonables y que serán las encargadas de discriminar el ruido y detectar las señales. Mientras que las técnicas estadísticas sólo pueden ser aproximadas, son hoy en día más confiables, más precisas y más reproducibles que la interpretación de los datos basada en la “experiencia”.